SKRIPSI

Perluasan Dataset IndQNER melalui Penyelarasan Lintas Bahasa menggunakan Metode *Similarity Matching* dan *Large Language Models* sebagai *Labeler*

Disusun Oleh:

Muhammad Fadhillah Akbar

11230910000023

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS SAINS DAN TEKNOLOGI

UNIVERSITAS ISLAM NEGERI SYARIF HIDAYATULLAH

JAKARTA

1448 H/2026 M

COVER DALAM
KATA PENGANTAR
UCAPAN TERIMA KASIH
PERNYATAAN BEBAS PLAGIARISME
LEMBAR PENGECEKAN PLAGIARISME
LEMBAR PERSETUJUAN PEMBIMBING DAN PENGUJI
ABSTRAK
PEDOMAN TRANSLITERASI ARAB-LATIN

DAFTAR ISI

COVER LUAR .....**Error! Bookmark not defined.**
COVER DALAM..... 2
KATA PENGANTAR..... 2
UCAPAN TERIMA KASIH..... 2
PERNYATAAN BEBAS PLAGIARISME 2
LEMBAR PENGECEKAN PLAGIARISME..... 2
LEMBAR PERSETUJUAN PEMBIMBING DAN PENGUJI 2
ABSTRAK 2
PEDOMAN TRANSLITERASI ARAB-LATIN..... 2
DAFTAR ISI 3
DAFTAR TABEL..... 5
DAFTAR GAMBAR..... 5
DAFTAR ISTILAH/SINGKATAN 5
BAB I PENDAHULUAN 6
A. Latar Belakang 6
B. Identifikasi Masalah 13
C. Batasan Masalah..... 14
D. Rumusan Masalah 15
E. Tujuan Penelitian 15
F. Kontribusi Penelitian..... 15
1. Kontribusi Metodologis..... 15
2. Kontribusi Dataset..... 16
3. Kontribusi Evaluasi 16
G. Manfaat Penelitian..... 16
1. Manfaat Teoritis 16
2. Manfaat Praktis 17
BAB II TINJAUAN PUSTAKA 18
A. Penelitian Terdahulu..... 18
B. Natural Language Processing 18

C. Named Entity Recognition 18
D. Konstruksi Dataset NER 18
E. NER Pada Domain Terjemahan AL-Qur'an Berbahasa Indonesia 18
F. Quranic Arabic Corpus 18
G. Cross-Lingual Annotation Projection 18
H. LLM-*as-Labeler* 18
I. Evaluasi Kualitas Dataset NER 18
J. Kerangka Berpikir Penelitian 18
BAB III METODOLOGI PENELITIAN 19
A. Tahapan Penelitian 19
B. Sumber Data Penelitian 19
C. Perangkat Penelitian 19
D. Arsitektur Metodologi Penelitian 19
E. Persiapan Dataset 19
F. Cross-Lingual Alignment 19
G. Entity Labelling 19
H. Evaluasi 19
BAB IV HASIL DAN PEMBAHASAN 19
BAB V PENUTUP 19
DAFTAR PUSTAKA 19
LAMPIRAN 21

DAFTAR TABEL
DAFTAR GAMBAR
DAFTAR ISTILAH/SINGKATAN

BAB I
PENDAHULUAN

A. Latar Belakang

Perkembangan *Natural Language Processing* (NLP) telah mendorong kemajuan berbagai teknologi berbasis bahasa, seperti *machine translation*[1], *question answering*[2], *information retrieval*[3], hingga *chatbot*[4]. Meskipun demikian, keberhasilan pengembangan teknologi tersebut tidak hanya ditentukan oleh kemajuan arsitektur model, tetapi juga oleh ketersediaan sumber daya bahasa yang berkualitas. Berbagai penelitian menunjukkan bahwa dataset beranotasi memiliki peran yang sangat penting dalam proses pelatihan, validasi, dan evaluasi model NLP, khususnya pada bahasa atau domain[5] yang masih tergolong *low-resource*[6]

---

[1] merupakan cabang kecerdasan buatan dan linguistik komputasional yang berfokus pada penerjemahan teks atau ucapan secara otomatis dari satu bahasa alami ke bahasa alami lainnya menggunakan model komputasi. Lihat Philipp Koehn, *Neural Machine Translation* (Cambridge: Cambridge University Press, 2020), hlm. 1–3 (Jooste et al., 2021).

[2] adalah sub-bidang pemrosesan bahasa alami yang bertujuan membangun sistem komputer yang mampu memberikan jawaban langsung dan tepat atas pertanyaan yang diajukan oleh pengguna dalam bahasa alami, alih-alih hanya mengembalikan daftar dokumen relevan. Rujuk Dan Jurafsky dan James H. Martin, *Speech and Language Processing*, ed. ke-3 (Draft, 2024), bab 23 (Jurafsky & Martin, 2024).

[3]adalah proses pencarian dan penemuan kembali material atau dokumen (biasanya berupa teks tidak terstruktur) yang relevan terhadap kebutuhan informasi pengguna dari kumpulan koleksi data berskala besar. Lihat Christopher D. Manning, Prabhakar Raghavan, dan Hinrich Schütze, *An Introduction to Information Retrieval* (Cambridge: Cambridge University Press, 2008), hlm. 1 (Manning et al., 2009) .

[4]adalah perangkat lunak yang dirancang untuk berinteraksi dan menyimulasikan percakapan dengan manusia melalui input teks atau suara menggunakan aturan terprogram maupun pemodelan bahasa alami. Rujuk Ethem Alpaydin, *Introduction to Machine Learning*, ed. ke-4 (Cambridge, MA: The MIT Press, 2020), hlm. 512 https://mitpress.mit.edu/books/introduction-machine-learning-fourth-edition.

[5]dalam konteks pembelajaran mesin dan pemrosesan bahasa alami merujuk pada lingkungan distribusi data tertentu yang dicirikan oleh kesamaan topik, ragam bahasa, terminologi khusus, gaya penulisan, atau sumber dokumen (seperti domain medis, hukum, berita, atau teks klasik). Perbedaan antar-domain kerap memicu pergeseran distribusi (*domain shift*) yang memengaruhi kemampuan generalisasi suatu model komputasi. Lihat Dan Jurafsky dan James H. Martin, *Speech and Language Processing*, ed. ke-3 (Draft, 2024), bab 6; bandingkan dengan Shai Ben-David et al., "A Theory of Learning from Different Domains," *Machine Learning* 79, no. 1–2 (2010): 151–154.

[6]dalam konteks pemrosesan bahasa alami atau komputasi linguistik, merujuk pada kondisi bahasa atau domain yang memiliki keterbatasan sumber daya digital, seperti kelangkaan korpus teks beranotasi, data paralel untuk pelatihan, leksikon komprehensif, maupun alat pemrosesan dasar yang memadai. Lihat Colin Raffel et al., "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer," *Journal of Machine Learning Research* 21, no. 140 (2020): 1–67; bandingkan dengan Graham Neubig et al., "Handling Low-Resource Languages in NLP," dalam *Proceedings of the 57th Annual Meeting of the ACL* (Florence: Association for Computational Linguistics, 2019), hlm. 1–12.

(Ding et al., 2024; Drozdov & Pavlyshenko, 2025). Oleh karena itu, penyediaan dataset yang representatif dan konsisten menjadi salah satu tantangan utama dalam pengembangan NLP modern (Armaijn et al., 2024; Khairunnisa et al., 2024).

Salah satu tugas mendasar dalam NLP adalah *Named Entity Recognition* (NER), yaitu proses mengidentifikasi dan mengklasifikasikan entitas[1] bernama, seperti nama orang, lokasi, organisasi, waktu, maupun entitas lain yang disesuaikan dengan karakteristik suatu domain (Idi Mohammed & Habiba Idi Idriss, 2026; Tarmizi & Saad, 2025) . Berbeda dengan banyak tugas NLP lain, performa sistem NER sangat dipengaruhi oleh kualitas anotasi[2] data yang digunakan (Basir, Qabulio, et al., 2026; Gusmita et al., 2023). Dataset yang memiliki cakupan terbatas, anotasi yang tidak konsisten, atau distribusi entitas yang kurang representatif akan berdampak langsung terhadap kemampuan model dalam mengenali entitas pada data baru. Dengan demikian, pada penelitian NER, tantangan yang dihadapi tidak hanya berkaitan dengan pengembangan model, tetapi juga dengan bagaimana membangun dan memperluas dataset anotasi yang mampu merepresentasikan karakteristik domain secara memadai (Armaijn et al., 2024) .

Salah satu domain yang masih memiliki keterbatasan sumber daya adalah teks keagamaan, khususnya terjemahan Al-Qur'an berbahasa Indonesia Kementerian Agama Republik Indonesia[3] (selanjutnya akan disebut sebagai teks terjemahan)

---

[1]merujuk pada objek, konsep, individu, atau rujukan konkret maupun abstrak di dunia nyata yang memiliki batas semantik jelas dan dapat diidentifikasi secara unik di dalam teks (misalnya orang, lokasi, organisasi, waktu, atau kuantitas). Dalam tugas *Named Entity Recognition* (NER), entitas didefinisikan sebagai rentang token teks yang dikategorikan ke dalam kelas-kelas makna yang telah ditentukan sebelumnya. Rujuk Dan Jurafsky dan James H. Martin, *Speech and Language Processing*, ed. ke-3 (Draft, 2024), bab 18; lihat pula David Nadeau dan Satoshi Sekine, "A Survey of Named Entity Recognition and Classification," *Lingvisticae Investigationes* 30, no. 1 (2007): 3–26.

[2]merujuk pada proses penambahan informasi linguistik, metadata, atau label semantik terstruktur pada teks mentah (seperti penandaan kelas kata, batas sintaksis, atau kategori entitas bernama) untuk dijadikan data latih (*training data*) maupun acuan kebenaran (*ground truth*) dalam evaluasi model komputasi. Rujuk Nancy Ide dan James Pustejovsky, ed., *Handbook of Linguistic Annotation* (Dordrecht: Springer, 2017), hlm. 1–5; bandingkan dengan Stefanie Dipper, "XML-Based Stand-Off Representation and Exploitation of Multi-Level Linguistic Annotation," dalam *Proceedings of the EACL Workshop on XML-Based Tools for NLP* (Budapest: Association for Computational Linguistics, 2005), hlm. 39–46.

[3] https://quran.kemenag.go.id/

(Khairunnisa et al., 2024; Tarmizi & Saad, 2025). Berbeda dengan korpus[1] bahasa umum, teks terjemahan memiliki karakteristik linguistik yang khas karena memuat istilah teologis, nama tokoh, nama tempat, peristiwa sejarah, serta konsep-konsep religius yang tidak selalu ditemukan pada korpus bahasa Indonesia sehari-hari (Gusmita et al., 2023, 2024, 2026) . Selain itu, gaya penerjemahan yang digunakan juga mengikuti kaidah tertentu sehingga menghasilkan struktur kalimat, pilihan diksi, dan hubungan semantik yang berbeda dengan teks umum. Karakteristik tersebut menyebabkan pendekatan NER yang dikembangkan pada domain umum belum tentu dapat diterapkan secara optimal pada teks terjemahan, sehingga dibutuhkan sumber daya bahasa yang secara khusus dibangun untuk domain tersebut (Basir, Vighio, et al., 2026).

Sebagai upaya awal dalam menyediakan sumber daya NER pada domain teks terjemahan, (Gusmita et al., 2023) mengembangkan IndQNER. Dataset ini menjadi *benchmark*[2] pertama yang dibangun melalui anotasi manual. Kehadiran IndQNER telah menjadi fondasi awal yang penting bagi penelitian NER pada korpus religius berbahasa Indonesia, meskipun cakupannya masih terbatas. Dataset tersebut hanya mencakup delapan surah dari keseluruhan 114 surah Al-Qur'an, sehingga variasi kemunculan entitas, konteks linguistik, maupun pola penyebutan entitas pada keseluruhan teks terjemahan belum sepenuhnya terwakili (Gusmita et al., 2023) . Keterbatasan tersebut tidak mengurangi peran IndQNER sebagai *benchmark*, tetapi menunjukkan adanya ruang pengembangan untuk memperluas cakupan dataset. Bahkan, penelitian IndQNER secara eksplisit menyatakan rencana untuk

[1]adalah kumpulan rekaman teks atau ujaran alami berskala besar yang terstruktur, autentik, dan representatif, yang disimpan dalam format digital dan kerap dilengkapi dengan anotasi linguistik untuk kebutuhan analisis bahasa, pelatihan permodelan komputasi, atau evaluasi empiris. Lihat Douglas Biber, Susan Conrad, dan Randi Reppen, *Corpus Linguistics: Investigating Language Structure and Use* (Cambridge: Cambridge University Press, 1998), hlm. 1–4; bandingkan dengan Tony McEnery dan Andrew Hardie, *Corpus Linguistics: Method, Theory and Practice* (Cambridge: Cambridge University Press, 2011), hlm. 1–6.

[2]dalam konteks kecerdasan buatan dan pemrosesan bahasa alami adalah kumpulan dataset terstandarisasi yang dilengkapi dengan protokol evaluasi dan metrik kuantitatif tertentu, yang digunakan sebagai instrumen acuan untuk menguji, memvalidasi, serta membandingkan performa berbagai model komputasi secara objektif. Rujuk Alex Wang et al., "GLUE: A Multi-Task Benchmark and Analysis Platform for Natural Language Understanding," dalam *Proceedings of the 2018 EMNLP Workshop BlackboxNLP* (Brussels: Association for Computational Linguistics, 2018), hlm. 353–355; lihat pula Ian Goodfellow, Yoshua Bengio, dan Aaron Courville, *Deep Learning* (Cambridge, MA: The MIT Press, 2016), hlm. 102–104.

mengembangkan dataset agar mencakup seluruh surah Al-Qur'an pada pekerjaan selanjutnya (Gusmita et al., 2023) .

Berbagai penelitian telah menunjukkan bahwa anotasi manual memerlukan waktu, biaya, dan keterlibatan anotator yang memahami domain secara mendalam agar kualitas anotasi tetap terjaga (Basir, Qabulio, et al., 2026; Gusmita et al., 2023; Tarmizi & Saad, 2025). Sebaliknya, pendekatan otomatis juga memiliki keterbatasannya masing-masing. Pendekatan berbasis aturan *(rule-based)* umumnya memiliki presisi yang tinggi pada pola tertentu, tetapi kurang adaptif terhadap variasi bahasa. Pendekatan berbasis pembelajaran mesin membutuhkan data berlabel dalam jumlah besar, sedangkan pendekatan berbasis *Large Language Model* (LLM) mampu menghasilkan anotasi secara otomatis, tetapi masih berpotensi menghasilkan *hallucination*[1], inkonsistensi label[2], maupun ketidaksesuaian terhadap skema anotasi yang telah ditetapkan (Armaijn et al., 2024; Ye et al., 2024).

Salah satu sumber daya yang berpotensi dimanfaatkan untuk mendukung proses perluasan dataset adalah *Quranic Arabic Corpus*[3] (QAC), yaitu korpus Al-Qur'an

[1]dalam model bahasa besar (*Large Language Models* / LLM) merujuk pada fenomena ketika model menghasilkan luaran teks yang terdengar meyakinkan, fasih, dan koheren secara sintaksis, namun secara faktual tidak akurat, tidak bersumber dari konteks masukan, atau sepenuhnya menyimpang dari kebenaran dunia nyata (*unfaithful* atau *factually incorrect*). Fenomena ini umumnya berakar pada sifat bawaan model yang bekerja berdasarkan probabilitas distribusi token, bukan pemahaman pengetahuan deterministik. Lihat Ziwei Ji et al., "Survey of Hallucination in Natural Language Generation," *ACM Computing Surveys* 55, no. 12 (2023): 1–38; bandingkan dengan Lei Huang et al., "A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions," *ACM Transactions on Information Systems* (2024), hlm. 1–10.

[2]dalam pembelajaran terarah/*supervised learning* dan anotasi data pemrosesan bahasa alami adalah nilai target atau penanda kategori semantik terstruktur yang diasosiasikan dengan suatu unit data masukan (seperti dokumen, kalimat, frasa, atau rentang token). Pada tugas klasifikasi teks, label mewakili kelas sentimen atau kategori topik, sedangkan pada tugas penandaan sekuens (*sequence labeling*) seperti *Named Entity Recognition* (NER), label merepresentasikan tipe entitas (misalnya PER, LOC, ORG) yang umumnya diformat menggunakan skema penandaan rentang seperti IOB (*Inside-Outside-Beginning*). Lihat Ian Goodfellow, Yoshua Bengio, dan Aaron Courville, *Deep Learning* (Cambridge, MA: The MIT Press, 2016), hlm. 103–105; bandingkan dengan Dan Jurafsky dan James H. Martin, *Speech and Language Processing*, ed. ke-3 (Draft, 2024), bab 5 & 18.

[3] https://corpus.quran.com/

berbahasa Arab yang telah dianotasi secara linguistik[1] dan semantik[2]. QAC menyediakan informasi mengenai kategori gramatikal, analisis morfologi[3], relasi sintaksis[4], serta anotasi berbagai *Proper Noun*[5] (PN).QAC dimanfaatkan sebagai knowledge source terstruktur untuk menyediakan informasi linguistik dan semantik teks sumber sebelum diproyeksikan ke teks target. Meskipun demikian, proses lintas bahasa tidak dapat dilakukan secara langsung tanpa mempertimbangkan perbedaan karakteristik linguistik antara bahasa Arab pada teks Al-Qur'an dan bahasa Indonesia. Lebih lanjut, (Gusmita et al., 2023) menemukan teknik terjemahan tersendiri pada teks terjemahan yang salah satunya berdampak pada munculnya entitas baru. Dengan demikian, proses penyelasaran lintas bahasa untuk menemukan entitas pada teks terjemahan membutuhkan mekanisme khusus.

Berdasarkan uraian tersebut, penelitian ini mengusulkan sebuah *pipeline*[6] perluasan dataset IndQNER dengan pendekatan *token-based similarity matching*[7]

---

[1]bidang ilmu yang mengkaji bahasa secara ilmiah dan sistematis. Dalam linguistik komputasional, prinsip teoretisnya diintegrasikan dengan algoritma untuk memodelkan bahasa alami. Lihat David Crystal, *A Dictionary of Linguistics and Phonetics*, ed. ke-6 (Malden, MA: Blackwell Publishing, 2008), hlm. 283–285.

[2]adalah cabang linguistik yang mempelajari sistem pemaknaan pada satuan bahasa (kata, frasa, wacana). Dalam NLP, pemodelan semantik digunakan untuk mengekstraksi representasi makna kontekstual dan relasi entitas di balik teks. Lihat John I. Saeed, *Semantics*, ed. ke-4 (Chichester: Wiley-Blackwell, 2016), hlm. 3–5.

[3]cabang linguistik yang mempelajari struktur internal dan pola pembentukan kata dari morfem. Dalam prapemrosesan teks NLP, analisis morfologi mendasari proses segmentasi, lematisasi, dan *stemming*. Lihat Francis Katamba dan John T. Stonham, *Morphology*, ed. ke-2 (Basingstoke: Palgrave Macmillan, 2006), hlm. 3–15.

[4]cabang linguistik yang mengkaji kaidah penyusunan kata menjadi frasa, klausa, dan kalimat gramatikal. Pada NLP, analisis sintaksis diterapkan melalui *POS-tagging* dan penguraian struktur gramatikal (*parsing*). Lihat Andrew Carnie, *Syntax: A Generative Introduction*, ed. ke-4 (Hoboken: Wiley-Blackwell, 2021), hlm. 3–18.

[5]nomina khas yang merujuk secara spesifik pada entitas unik (seperti nama orang, lokasi, atau lembaga) tanpa makna deskriptif umum. Pada NER, identifikasi *proper noun* menjadi fondasi penentuan batas token (*boundary*) dan tipe kelas entitas. Lihat Randolph Quirk et al., *A Comprehensive Grammar of the English Language* (London: Longman, 1985), hlm. 288–291.

[6]merupakan rangkaian tahapan komputasi sekuensial terstruktur di mana luaran suatu modul secara langsung menjadi masukan bagi tahap berikutnya. Dalam NLP, alur kerja ini mengintegrasikan prapemrosesan, penyejajaran (*alignment*), pelabelan, hingga evaluasi akhir. Lihat Aurélien Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, ed. ke-3 (Sebastopol, CA: O'Reilly Media, 2022), hlm. 72–75.

[7]merupakan metode komputasi untuk mengukur kemiripan antar-teks dengan mengevaluasi bobot tumpang-tindih (*overlap*) himpunan token leksikal diskret menggunakan metrik kesamaan (misalnya Jaccard atau Dice Coefficient) tanpa bergantung pada kekakuan sintaksis penuh. Lihat Christopher D. Manning, Prabhakar Raghavan, dan Hinrich Schütze, *An Introduction to Information Retrieval* (Cambridge: Cambridge University Press, 2008), hlm. 118–123.

dan LLM sebagai pelabel (*LLM-as-labeler*) yang berorientasi pada pemeliharaan kompatibilitas secara ketat terhadap *benchmark* IndQNER. Alur kerja *pipeline* ini dirancang melalui empat tahapan utama, yaitu persiapan dataset, perolehan entitas, pelabelan entitas, dan evaluasi dataset. Tahap pertama, persiapan dataset, difokuskan pada ekstraksi token[1] berlabel *Proper Noun* (PN) dari *syntactic treebank*[2] QAC sebagai korpus sumber, tokenisasi teks terjemahan target, serta penyiapan Kamus Entitas IndQNER[3]. Tahap kedua, perolehan entitas, dilakukan melalui penyelarasan lintas bahasa (*cross-lingual alignment*) dengan metode *token-based similarity matching* untuk memproyeksikan entitas dari QAC ke teks terjemahan, serta penerapan ekspresi reguler (*regular expression* / RegEx)[4] untuk mendeteksi entitas baru yang muncul akibat gaya selingkung tanda kurung penjelasan pada teks terjemahan. Tahap ketiga, pelabelan entitas, menerapkan mekanisme modular bertingkat; pelabelan deterministik[5] dilakukan terlebih dahulu dengan mencocokkan entitas ke Kamus Entitas IndQNER, dan apabila entitas tidak ditemukan di dalam kamus, proses pelabelan dialihkan kepada model bahasa lokal Llama-3-8B (*LLM-as-labeler*) melalui skenario *Zero-Shot*[6] dan *Few-Shot*

[1]merupakan unit teks diskret terkecil hasil segmentasi (*tokenization*)—berupa kata, subkata (*subword*), atau tanda baca—yang siap dipetakan ke dalam representasi numerik/vektor untuk diproses algoritma komputasi. Lihat Dan Jurafsky dan James H. Martin, *Speech and Language Processing*, ed. ke-3 (Draft, 2024), bab 2.

[2]merupakan korpus teks teranotasi struktur gramatikal formalnya dalam bentuk diagram pohon (*parse tree*), baik berbasis konstituensi maupun ketergantungan (*dependency*), yang berfungsi sebagai data latih dan acuan baku (*ground truth*) analisis sintaksis. Lihat Mitchell P. Marcus et al., "Building a Large Annotated Corpus of English: The Penn Treebank," *Computational Linguistics* 19, no. 2 (1993): 313–330.

[3]merupakan leksikon dan pedoman baku pelabelan 20 kelas entitas bernama pada terjemahan Al-Qur'an berbahasa Indonesia yang diadaptasi dari ontologi konsep Al-Qur'an Universitas Leeds sebagai acuan tolak ukur (*benchmark*) sistem NER. Lihat Gusmita et al., "Pedoman Pelabelan Entitas Bernama pada Terjemahan Al-Qur'an Berbahasa Indonesia" (Dokumen Teknis IndQNER, n.d.), hlm. 1–5.

[4]adalah pola karakter formal yang digunakan algoritma pencarian string untuk mencocokkan, memvalidasi format, atau mengekstrak pola teks tertentu secara deterministik. Lihat Jeffrey E. F. Friedl, *Mastering Regular Expressions*, ed. ke-3 (Sebastopol, CA: O'Reilly Media, 2006), hlm. 1–18.

[5]karakteristik proses atau algoritma yang selalu menghasilkan luaran identik yang konsisten untuk masukan yang sama, tanpa melibatkan unsur probabilitas acak atau stokastik. Lihat Stuart Russell dan Peter Norvig, *Artificial Intelligence: A Modern Approach*, ed. ke-4 (Hoboken: Pearson, 2020), hlm. 43–45.

[6]paradigma inferensi di mana model menyelesaikan tugas atau mengklasifikasikan data masukan murni berdasarkan instruksi tanpa diberikan contoh (*exemplars*) spesifik sebelumnya. Lihat Tom B.

prompting[1] yang dibatasi secara ketat pada 20 kategori kelas IndQNER. Sebagai tahap akhir, evaluasi kualitas dataset dilakukan melalui evaluasi intrinsik[2] untuk mengukur *precision*[3], *recall*[4], dan *F1-score*[5] secara *strict entity-level matching*[6] pada data acuan, serta evaluasi ekstrinsik melalui *downstream task*[7] pemodelan NER. Melalui serangkaian tahapan *pipeline* tersebut, luaran utama yang dihasilkan dari penelitian ini adalah **Extended IndQNER**, yaitu dataset anotasi NER terjemahan Al-Qur'an berskala penuh 114 surah yang tetap mempertahankan kompatibilitas skema label dan format BIO[8] dari *benchmark* IndQNER aslinya.

Brown et al., "Language Models are Few-Shot Learners," dalam *NeurIPS 2020*, vol. 33 (2020), hlm. 1877–1901.

[1]teknik rekayasa konteks masukan pada LLM dengan menyertakan sejumlah kecil contoh demonstrasi pasangan masukan-keluaran guna memandu model menghasilkan luaran sesuai format target tanpa memperbarui bobot model (*in-context learning*). Lihat Tom B. Brown et al., "Language Models are Few-Shot Learners," dalam *NeurIPS 2020*, vol. 33 (2020), hlm. 1877–1901.

[2]merupakan metode pengujian performa subsistem atau representasi model secara terisolasi terhadap metrik objektif dan dataset acuan baku (*ground truth*) tanpa mengukur performa aplikasi hilir akhir. Lihat Dan Jurafsky dan James H. Martin, *Speech and Language Processing*, ed. ke-3 (Draft, 2024), bab 3 & 8.

[3]rasio antara jumlah prediksi positif yang benar (*true positives*) terhadap seluruh item yang diprediksi positif oleh model ($TP/(TP + FP)$). Menunjukkan tingkat ketepatan hasil deteksi sistem. Lihat Christopher D. Manning et al., *An Introduction to Information Retrieval* (Cambridge: Cambridge University Press, 2008), hlm. 155–158.

[4]rasio antara jumlah prediksi positif yang benar (*true positives*) terhadap seluruh item positif riil pada data acuan ($TP/(TP + FN)$). Menunjukkan sensitivitas sistem dalam menjaring seluruh entitas target tanpa terlewat. Lihat Christopher D. Manning et al., *An Introduction to Information Retrieval* (Cambridge: Cambridge University Press, 2008), hlm. 155–158.

[5]merupakan rata-rata harmonik (*harmonic mean*) antara presisi dan *recall* ($2 \times \frac{P \times R}{P+R}$) yang berfungsi sebagai metrik tunggal seimbang saat mengevaluasi data dengan distribusi kelas tidak berimbang. Lihat C. J. van Rijsbergen, *Information Retrieval*, ed. ke-2 (London: Butterworths, 1979), bab 7.

[6]adalah protokol evaluasi ketat pada NER di mana prediksi entitas hanya dinilai benar (*true positive*) jika rentang batas token (*span/boundary*) dan kelas label entitas cocok sempurna (*exact match*) dengan data acuan. Lihat Erik F. Tjong Kim Sang dan Fien De Meulder, "Introduction to the CoNLL-2003 Shared Task," dalam *Proceedings of CoNLL-2003* (Edmonton, 2003), hlm. 142–147.

[7]adalah tugas aplikasi komputasi terapan (seperti klasifikasi, NER, atau ekstraksi informasi) yang memanfaatkan representasi bobot fitur dari model prapelatihan hulu (*upstream pre-trained model*). Lihat Jacob Devlin et al., "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," dalam *Proceedings of NAACL-HLT 2019*, hlm. 4171–4186.

[8] Merupakan skema penandaan sekuens standar penanda batas entitas per-token: **B-** (*Beginning*) untuk token awal entitas, **I-** (*Inside*) untuk token lanjutan entitas yang sama, dan **O-** (*Outside*) untuk token di luar entitas. Lihat Lance A. Ramshaw dan Mitchell P. Marcus, "Text Chunking using Transformation-Based Learning," dalam *Third Workshop on Very Large Corpora* (1995), hlm. 82–94.

B. Identifikasi Masalah

Berdasarkan uraian pada latar belakang, penelitian ini mengidentifikasi beberapa permasalahan sebagai berikut.

1. Cakupan dataset *benchmark* IndQNER saat ini baru mencakup 8 dari total 114 surah Al-Qur'an (3.117 kalimat dan 62.027 token[1]). Keterbatasan korpus ini mengakibatkan tingginya tingkat kata di luar kosakata (*Out-of-Vocabulary* / OOV), sehingga model NER gagal menggeneralisasi konteks linguistik dan entitas teologis pada 106 surah sisanya secara utuh.
2. Proses perluasan korpus Al-Qur'an melalui anotasi manual seutuhnya membutuhkan waktu bertahun-tahun, biaya yang sangat tinggi, serta terkendala oleh ketersediaan ahli Al-Qur'an dan tafsir manusia yang sangat terbatas. Oleh karena itu, diperlukan mekanisme semiotomatis yang efisien tanpa mengurangi presisi *ground truth*[2]
3. Penggunaan *Large Language Model* (LLM) secara generatif bebas (*prompting* bebas) memiliki risiko tinggi memicu halusinasi teologis (*hallucination*). Selain itu, LLM murni rentan melanggar konsistensi format BIO dan menyebabkan kesalahan penentuan batas kata (*span boundary error*[3]), sehingga LLM tidak diperkenankan bertindak sebagai pelabel tunggal tanpa bimbingan kamus terstruktur dan aturan deterministik.

---

[1] https://github.com/dice-group/IndQNER

[2] dalam pembelajaran mesin dan pemrosesan bahasa alami merujuk pada data empiris yang telah diverifikasi secara definitif kebenarannya—biasanya dihasilkan melalui anotasi manual oleh pakar domain—yang berfungsi sebagai target pelatihan (*target label*) serta tolak ukur objektif (*gold standard*) untuk mengevaluasi kinerja prediksi model. Rujuk Dan Jurafsky dan James H. Martin, *Speech and Language Processing*, ed. ke-3 (Draft, 2024), bab 4 & 5; bandingkan dengan Ian Goodfellow, Yoshua Bengio, dan Aaron Courville, *Deep Learning* (Cambridge, MA: The MIT Press, 2016), hlm. 102–104.

[3] adalah galat evaluasi NER akibat ketidaktepatan model dalam menentukan token awal atau akhir suatu entitas (terlalu sempit atau terlalu luas), meskipun tipe kelasnya terprediksi benar. Pada evaluasi *strict matching*, ketidakcocokan batas ini dihitung sebagai kegagalan ganda (*false positive* sekaligus *false negative*). Lihat Erik F. Tjong Kim Sang dan Fien De Meulder, "Introduction to the CoNLL-2003 Shared Task," dalam *Proceedings of CoNLL-2003* (Edmonton, 2003), hlm. 142–147; bandingkan dengan Dan Jurafsky dan James H. Martin, *Speech and Language Processing*, ed. ke-3 (Draft, 2024), bab 18.

4. Pendekatan proyeksi lintas bahasa (*cross-lingual projection*) tradisional rentan mengalami ketidakakuratan penentuan batas entitas (*span boundary error*) akibat divergensi struktur sintaksis Arab-Indonesia serta penanganan anomali gaya selingkung tanda kurung penjelasan pada teks terjemahan Kemenag RI.
5. Berdasarkan kajian literatur, belum terdapat kerangka *pipeline* konstruksi dataset yang secara khusus mengintegrasikan QAC, *Token Similarity Matching*, RegEx, dan *LLM-as-Labeler* untuk korpus religius.

C. Batasan Masalah

Agar penelitian memiliki ruang lingkup yang jelas dan terarah, penelitian ini dibatasi pada beberapa aspek berikut.

1. Objek penelitian adalah perancangan *pipeline* perluasan dataset IndQNER.
2. Dataset acuan yang digunakan adalah IndQNER sebagai *benchmark*, dengan skema anotasi BIO, kategori entitas, pedoman anotasi, dan format data yang tersedia pada versi dataset yang digunakan dalam penelitian ini.
3. Sumber pengetahuan yang digunakan untuk memperoleh kandidat entitas berasal dari QAC yang diproyeksikan ke dalam teks terjemahan melalui penyelarasan lintas bahasa.
4. *Pipeline* yang diusulkan terdiri atas tahapan persiapan dataset, *cross-lingual alignment*, pelabelan entitas menggunakan kamus IndQNER dan *LLM-as-Labeler*, serta evaluasi kualitas dataset.
5. Penelitian ini tidak bertujuan untuk mengubah, mendefinisikan ulang, atau menambah skema kategori anotasi dari *benchmark* IndQNER. Apabila ditemukan kasus entitas baru yang tidak tercakup dalam pedoman IndQNER, kasus tersebut akan didokumentasikan sebagai kasus di luar pedoman *(Out-of-Vocabulary)* guna menjaga kompatibilitas dataset hasil perluasan secara ketat

6. Evaluasi penelitian difokuskan pada kualitas *pipeline* dan mengusulkan anotasi yang konsisten terhadap *benchmark*, sedangkan model NER hanya digunakan sebagai alat evaluasi terhadap kualitas dataset yang dihasilkan, bukan sebagai fokus utama penelitian.

D. Rumusan Masalah

Berdasarkan identifikasi masalah yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana merancang suatu *pipeline* perluasan dataset IndQNER yang mampu mempertahankan kompatibilitas terhadap *benchmark* IndQNER?
2. Bagaimana mengevaluasi efektivitas *pipeline* yang diusulkan dalam menghasilkan dataset dengan kualitas anotasi yang mendekati *benchmark* IndQNER?

E. Tujuan Penelitian

Penelitian ini bertujuan merancang *pipeline* perluasan dataset NER pada teks terjemahan dengan mengacu pada *benchmark* IndQNER, menghasilkan dataset hasil perluasan yang mempertahankan kompatibilitas terhadap skema anotasi dan format data IndQNER, serta mengevaluasi kualitas anotasi yang dihasilkan melalui prosedur evaluasi yang dirancang dalam penelitian ini.

F. Kontribusi Penelitian

Penelitian ini diharapkan memberikan kontribusi pada aspek metodologis, sumber daya, dan evaluasi dalam pengembangan NER pada domain teks terjemahan. Kontribusi tersebut dijabarkan sebagai berikut.

1. Kontribusi Metodologis

Penelitian ini mengusulkan sebuah pipeline konstruksi dan perluasan dataset NER yang mengintegrasikan sumber pengetahuan terstruktur yaitu QAC, *cross-lingual annotation projection*, *rule-based refinement*, dan

semantic verification berbasis *Large Language Model (LLM).* Integrasi keempat komponen tersebut dirancang untuk mewujudkan alur konstruksi dataset yang lebih sistematis dan terukur, sehingga proses anotasi tidak sepenuhnya bergantung pada anotasi manual yang memakan biaya dan waktu, maupun model generatif murni yang rentan terhadap isu *hallucination*.

2. Kontribusi Dataset

Penelitian ini menghasilkan dataset hasil perluasan IndQNER yang disebut *Extended IndQNER* dengan cakupan korpus yang lebih luas dibandingkan *benchmark* awal. Dataset ini dikembangkan dengan tetap mempertahankan kompatibilitas terhadap skema anotasi BIO, kategori entitas, serta format pelabelan *benchmark* asli yang digunakan sebagai acuan, sehingga dapat berfungsi sebagai sumber daya bahasa *(language resource)* yang lebih representatif bagi pengembangan model NER pada domain Al-Qur'an berbahasa Indonesia.

3. Kontribusi Evaluasi

Penelitian ini menyediakan prosedur evaluasi kualitas anotasi hasil perluasan melalui pembandingan secara *entity-level* terhadap anotasi acuan pada subset evaluasi yang divalidasi, serta dilengkapi dengan analisis kesalahan *(error analysis)* anotasi. Kerangka evaluasi ini disusun untuk memberikan gambaran yang transparan dan objektif mengenai efektivitas *pipeline* yang diusulkan, sekaligus menjadi referensi metodologis bagi penelitian lanjutan dalam pengembangan dataset pada korpus religius maupun domain *low-resource* lainnya.

G. Manfaat Penelitian

1. Manfaat Teoritis

Penelitian ini diharapkan dapat memberikan kontribusi terhadap pengembangan kajian *Natural Language Processing*, khususnya pada bidang konstruksi dataset *Named Entity Recognition* untuk domain religius. Selain itu, penelitian ini diharapkan dapat memperkaya kajian mengenai pemanfaatan

penyelarasan lintas bahasa, sumber pengetahuan terstruktur, serta pendekatan hibrida dalam proses anotasi semiotomatis pada korpus *low-resource*.

2. Manfaat Praktis

Penelitian ini diharapkan memberikan manfaat praktis sebagai berikut.

a. Menghasilkan Pipeline yang dapat digunakan sebagai acuan dalam proses perluasan dataset NER pada teks terjemahan.
b. Menyediakan dataset hasil perluasan yang tetap mempertahankan kompatibilitas terhadap benchmark IndQNER sehingga dapat dimanfaatkan sebagai sumber daya bagi penelitian lanjutan.
c. Memberikan alternatif pendekatan konstruksi dataset yang memadukan sumber pengetahuan terstruktur, penyelarasan lintas bahasa, dan validasi otomatis untuk mendukung pengembangan dataset pada domain low-resource lainnya.

BAB II
TINJAUAN PUSTAKA

A. Penelitian Terdahulu

B. Natural Language Processing

C. Named Entity Recognition

D. Konstruksi Dataset NER

E. NER Pada Domain Terjemahan AL-Qur'an Berbahasa Indonesia

F. Quranic Arabic Corpus

G. Cross-Lingual Annotation Projection

H.* LLM-*as-Labeler

I. Evaluasi Kualitas Dataset NER

J. Kerangka Berpikir Penelitian

BAB III
METODOLOGI PENELITIAN

A. Tahapan Penelitian

B. Sumber Data Penelitian

C. Perangkat Penelitian

D. Arsitektur Metodologi Penelitian

E. Persiapan Dataset

F. Cross-Lingual Alignment

G. Entity Labelling

H. Evaluasi

BAB IV HASIL DAN PEMBAHASAN
BAB V PENUTUP

DAFTAR PUSTAKA

Armaijn, L., Darmayanti, D., Sonia, B., & Rochmat, H. (2024). PENINGKATAN KINERJA NAMED ENTITY RECOGNITION BAHASA INDONESIAMELALUI AUGMENTASI DATA BERBASIS LARGE LANGUAGE MODELS. *Jurnal Informatika Teknologi Dan Sains (JINTEKS)*, *2*(2005), 306–312.

Basir, N., Qabulio, M., Memon, M. S., Arain, D. N., Nizamani, S. B., & Nizamani, S. (2026). Expanded Entity Coverage and Machine-Annotated Pre-Training for Urdu Named Entity Recognition. *The Asian Bulletin of Big Data Management*, *6*(1), 77–93. https://doi.org/10.62019/gypnn177

Basir, N., Vighio, R. A., Ansari, B., Patoli, N., Arain, D. N., & Ali, A. (2026). Low-Resource Balochi Named Entity Recognition: Corpus Construction and Multilingual Transformer Evaluation. *The Asian Bulletin of Big Data Management*, *6*(1), 153–167. https://abbdm.com/index.php/Journal/article/view/462

Ding, B., Qin, C., Zhao, R., Luo, T., Li, X., Chen, G., Xia, W., Hu, J., Luu, A. T., & Joty, S. (2024). *Data Augmentation using Large Language Models: Data Perspectives, Learning Paradigms and Challenges*. http://arxiv.org/abs/2403.02990

Drozdov, I., & Pavlyshenko, B. (2025). NAMED ENTITY RECOGNITION USING GENERATIVE TRANSFORMER MODELS WITH SENTENCE-

LEVEL DATA AUGMENTATION APPROACHES. *Electronics and Information Technologies*, *31*. https://doi.org/10.30970/eli.31.1

Gusmita, R. H., Abshar, M. F. A., Moussallem, D., & Ngomo, A. C. N. (2024). IndEL: Indonesian Entity Linking Benchmark Dataset for General and Specific Domains. *Lecture Notes in Computer Science*, *14762 LNCS*, 500–513. https://doi.org/10.1007/978-3-031-70239-6_34

Gusmita, R. H., Firmansyah, A. F., Moussallem, D., & Ngonga Ngomo, A. C. (2023). IndQNER: Named Entity Recognition Benchmark Dataset from the Indonesian Translation of the Quran. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, *13913 LNCS*, 170–185. https://doi.org/10.1007/978-3-031-35320-8_12

Gusmita, R. H., Firmansyah, A. F., Zahera, H. M., & Ngonga Ngomo, A. C. (2026). ELEVATE-ID: Extending Large Language Models for End-to-End Entity Linking Evaluation in Indonesian. *Data and Knowledge Engineering*, *161*, 102504. https://doi.org/10.1016/j.datak.2025.102504

Idi Mohammed, & Habiba Idi Idriss. (2026). Transformer-Based Model for Named Entity Recognition in Hausa Language Texts. *International Journal of Latest Technology in Engineering Management & Applied Science*, *15*(5), 2840–2856. https://doi.org/10.51583/ijltemas.2026.150500232

Jooste, W., Haque, R., & Way, A. (2021). Philipp Koehn: Neural Machine Translation. *Machine Translation*, *35*(2), 289–299. https://doi.org/10.1007/s10590-021-09277-x

Jurafsky, D., & Martin, J. H. (2024). *Speech and Language Processing An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models Third Edition draft*.

Khairunnisa, S. O., Chen, Z., & Komachi, M. (2024). Improving Domain-Specific NER in the Indonesian Language Through Domain Transfer and Data Augmentation. *Journal of Advanced Computational Intelligence and Intelligent Informatics*, *28*(6), 1299–1312. https://doi.org/10.20965/jaciii.2024.p1299

Manning, C. D. ., Raghavan, Prabhakar., & Schütze, Hinrich. (2009). *Introduction to information retrieval*. Cambridge University Press.

Tarmizi, S. A., & Saad, S. (2025). Named Entity Recognition on Islamic Texts: A Systematic Review. *International Journal of Advanced Science Computing and Engineering*, *7*(3), 98–111. https://doi.org/10.62527/ijasce.7.3.265

Ye, J., Xu, N., Wang, Y., Zhou, J., Zhang, Q., Gui, T., & Huang, X. (2024). LLM-DA: Data Augmentation via Large Language Models for Few-Shot Named Entity Recognition. *ArXiv*. http://arxiv.org/abs/2402.14568

LAMPIRAN