PROPOSAL PENELITIAN TUGAS AKHIR

Perluasan Dataset IndQNER melalui Penyelarasan Lintas Bahasa Menggunakan Metode Similarity Matching dan Large Language Models sebagai Labeler

MUHAMMAD FADHILLAH AKBAR
11230910000023

PROGRAM STUDI TEKNIK INFORMATIKA, FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI SYARIF HIDAYATULLAH JAKARTA

FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA

Agenda Presentasi

01.

BAB I PENDAHULUAN

Latar Belakang & Urgensi, Terminologi Utama, Identifikasi Masalah, Batasan, Rumusan Masalah, dan Tujuan Riset.

02.

BAB II TINJAUAN PUSTAKA

Sintesis Tema, Penelitian Terdahulu (State of the Art), dan Peta Analisis Research Gap.

03.

BAB III METODOLOGI PENELITIAN

Sumber Data, Pipeline, Studi Kasus Teknis, dan Skenario Evaluasi Kualitas Dataset.

Terminologi Utama

Natural Language Processing (NLP)

Pemrosesan Bahasa Alami; cabang AI yang menjembatani komunikasi bahasa manusia dengan komputer. Peran di penelitian ini sebagai fondasi pengolahan korpus keagamaan.

IndQNER

Dataset benchmark NER terjemahan Al-Qur'an bahasa Indonesia pertama (Gusmita et al., 2023) berskema BIO dengan 18 kelas teologis. Peran di penelitian ini menjadi benchmark dan target perluasan.
Dalam IndQNER terdapat Pedoman Pelabelan Entitas Bernama pada Terjemahan Al-Qur'an Berbahasa Indonesia yang selanjutnya akan kita sebut sebagai **Kamus Entitas IndQNER**

Named Entity Recognition (NER)

NER merupakan salah satu tugas ekstraksi informasi paling mendasar dalam NLP yang bertujuan untuk mengidentifikasi dan mengklasifikasikan entitas bernama di dalam teks (seperti nama tokoh, lokasi, organisasi, atau istilah khusus keagamaan). Tugas ini menjadi krusial karena performa generalisasi model NER sangat dipengaruhi oleh konsistensi batas (span boundary) dan akurasi label pada data pelatihannya

Large Language Model (LLM)

LLM adalah model bahasa modern berbasis arsitektur Transformer yang dilatih menggunakan korpus teks berskala raksasa sehingga memiliki pemahaman semantik mendalam dan kemampuan menyelesaikan berbagai tugas bahasa melalui instruksi (prompting).

Quranic Arabic Corpus (QAC)

Korpus bahasa Arab Al-Qur'an beranotasi morfologi dan sintaksis terstruktur (syntactic treebank). Peran di penelitian sebagai Knowledge Source

FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA

Latar Belakang & Urgensi Penelitian

Data Beranotasi sebagai Kunci

Keberhasilan sistem NLP modern sangat bergantung pada ketersediaan dataset latih beranotasi berkualitas, terutama pada domain dengan keterbatasan sumber daya (low-resource domain).

Signifikansi Sosial-Demografis

Indonesia memiliki porsi penganut agama Islam terbesar di dunia, memicu tingginya urgensi penyediaan sistem pengolah teks keagamaan digital yang andal.

Kompleksitas Teks Terjemahan

Teks Al-Qur'an terjemahan bahasa Indonesia resmi Kementerian Agama RI (selanjutnya secara ringkas disepakati untuk disebut sebagai "**teks terjemahan**") memiliki karakteristik morfosintaksis yang khas.

Gaya Linguistik Khas

Sarat istilah teologis, sapaan ketokohan, nama lokasi kuno, dan gaya selingkung tanda kurung penjelasan yang menyulitkan model NER domain umum biasa.

FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA

Baseline Penelitian & Dataset Gap

Celah Riset (Dataset Gap)

Sangat terbatas karena baru mencakup 8 dari total 114 surah Al-Qur'an (3.117 kalimat, 62.027 token)

Konsekuensi Metodologis

Menyebabkan tingginya tingkat kesalahan kata di luar kosakata (Out-of-Vocabulary - OOV) sehingga model gagal menggeneralisasi konteks 106 surah sisa secara utuh.

IndQNER sebagai Baseline

Benchmark dataset pertama untuk tugas NER pada teks terjemahan.

Kualitas Ground Truth

Dianotasi manual skema BIO dengan 18 kategori kelas entitas teologis yang divalidasi langsung oleh ahli Al-Qur'an dan Tafsir.

FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA

DILEMA METODOLOGI & DILEMA OTOMATISASI LLM

- Ekspansi Manual Tidak Skalabel: Memerlukan waktu bertahun-tahun, biaya yang sangat tinggi, serta ketersediaan ahli tafsir manusia yang sangat terbatas.
- Kelemahan LLM Generatif Murni: Penggunaan model generatif secara bebas (prompting bebas) memiliki risiko halusinasi teologis (hallucination) yang tinggi.
- Pelanggaran Aturan Format: LLM murni rentan melanggar konsistensi tag sekuensial BIO dan memicu kekacauan penentuan batas kata (span boundary error) akibat perbedaan struktur tata bahasa Arab-Indonesia.
- Kesimpulan Kontrol: LLM tidak diperkenankan melakukan pelabelan secara sepenuhnya mandiri tanpa bimbingan database terstruktur dan aturan deterministik.

SOLUSI YANG DIUSULKAN

- **Penelitian ini secara tegas mengusulkan solusi pipeline hibrida semiotomatis yang dirancang untuk mengatasi kendala perluasan dataset IndQNER dengan tetap mengakomodasi dan menjaga kesucian teks Al-Qur'an secara mutlak.**
- Akar Pengetahuan yang Sahih (QAC): Menyaring kata benda khusus (Proper Noun) asli dari bahasa Arab melalui QAC sebagai jangkar keaslian teologis.
- Batas Kata Deterministik: Penjajaran lintas bahasa diselesaikan menggunakan metode Token Similarity Matching dan penyaringan RegEx untuk menangani anomali gaya kurung terjemahan (selingkung pada teks terjemahan).
- LLM-as-Labeler: Model bahasa kecil Llama-3-8B dijalankan lokal dan dilarang keras menyusun kalimat sendiri, melainkan hanya bertindak sebagai pemeta label kategori kaku IndQNER asli.

FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA

IDENTIFIKASI, BATASAN, & RUMUSAN MASALAH

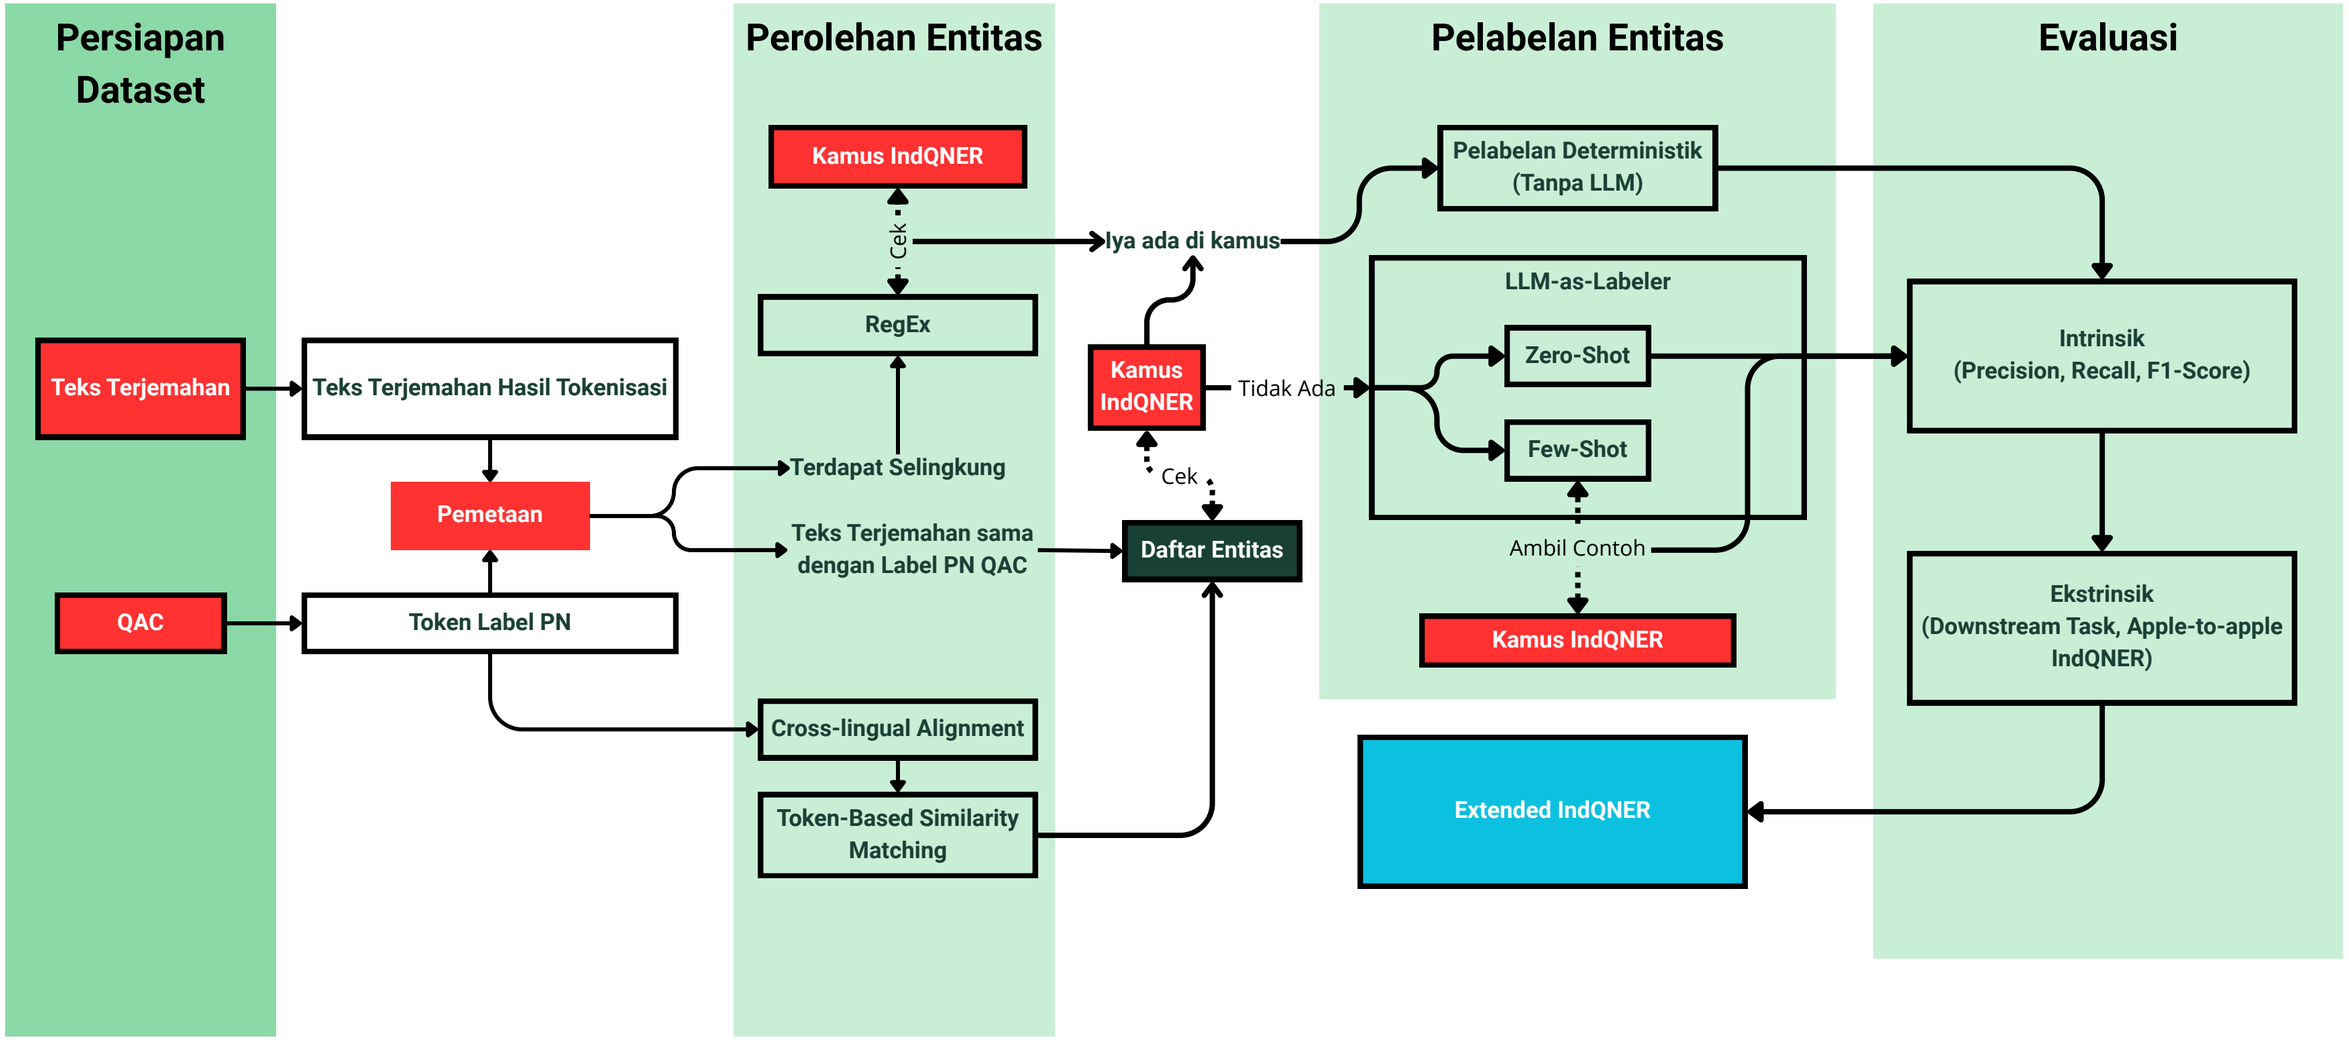
- Identifikasi Masalah: Cakupan benchmark IndQNER terbatas; ekspansi manual tidak skalabel; LLM rentan halusinasi; proyeksi tradisional rentan span boundary error.
- Batasan Masalah: Fokus pada pipeline perluasan (bukan membuat model NER baru); mempertahankan secara kaku 18 kategori kelas dan format BIO IndQNER; menggunakan Llama-3-8B.
- Rumusan Masalah (RQs):
  - Bagaimana merancang suatu Pipeline perluasan dataset IndQNER yang mampu mempertahankan kompatibilitas terhadap benchmark IndQNER? 2.
  - Bagaimana mengevaluasi efektivitas Pipeline yang diusulkan dalam menghasilkan dataset dengan kualitas anotasi yang mendekati Benchmark IndQNER?

TINJAUAN PUSTAKA & STATE OF THE ART (SOTA)

- Gusmita et al. (2023): Anotasi manual BIO pada 8 surah Al-Qur'an. Kualitas tinggi, namun sangat terbatas secara cakupan.
- Chen et al. (2024): Membuktikan bahwa memfungsikan LLM sebagai pemeta kelas (LLM-as-labeler) terpandu mampu mereduksi halusinasi secara drastis.
- Armaijn et al. (2024): Pemanfaatan small LLMs (seperti Llama-3-8B) sangat efisien dalam menekan biaya komputasi dan noise dibandingkan model parameter besar.
- Posisi Penelitian: **Menggabungkan kekuatan data gramatikal Arab (QAC), penjajaran lintas bahasa (similarity matching), dan pelabelan terkendali small LLM lokal (Llama-3-8B) tanpa mengubah skema kelas asli.**

FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA

Pipeline Penelitian



FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA

Alur Pipeline

Persiapan Dataset

Menyiapkan teks Quranic Arabic Corpus (QAC) sebagai sumber pengetahuan terstruktur, teks terjemahan, serta pedoman anotasi dari benchmark IndQNER. Melakukan ekstraksi data sintaksis dari Quranic Arabic Corpus (QAC) sebagai korpus sumber, mengintegrasikan teks Al-Qur'an bahasa Indonesia, serta memosisikan Annotation Guideline IndQNER sebagai standar acuan utama (gold standard).

Mengambil token dengan label Proper Noun (PN) dari tabel Syntactic Treebank QAC

Syntactic treebank QAC

adalah korpus teks yang dianotasi secara sintaksis dan morfologis tingkat kata secara sangat presisi, lengkap dengan informasi kelas kata (Part-of-Speech), fitur morfologi, relasi gramatikal, dan pohon dependensi kalimat

Translation	Arabic word	Syntax and morphology
(2:9:1) yukhādiʿūna They seek to deceive	يُخَٰدِعُونَ PRON V	V – 3rd person masculine plural (form III) imperfect verb PRON – subject pronoun فعل مضارع والواو ضمير متصل في محل رفع فاعل
(2:9:2) l-laha Allah	ٱللَّهَ PN	PN – accusative proper noun → Allah لفظ الجلالة منصوب
(2:9:3) wa-alladhīna and those who	وَٱلَّذِينَ REL CONJ	CONJ – prefixed conjunction *wa* (and) REL – masculine plural relative pronoun الواو عاطفة اسم موصول
(2:9:4) āmanū believe[d],	ءَامَنُواْ PRON V	V – 3rd person masculine plural (form IV) perfect verb PRON – subject pronoun فعل ماض والواو ضمير متصل في محل رفع فاعل

Kenapa mengambil label Proper Noun?

PN scara linguistik merupakan konsep entitas bernama. mewakili entitas bernama objektif (seperti nama tokoh/nabi, malaikat, lokasi, kitab suci, atau konsep teologis) yang memiliki jaminan keaslian teologis langsung dari naskah asli bahasa Arab. Jadi entitas bernama itu secara default kelas morfologi nya adalah proper noun

- Tokenisasi Teks Target:
  - Teks Terjemahan sebagai teks target penelitian akan ditokenisasi menjadi urutan token tingkat kata (word-level).
  - Setiap token menyimpan informasi indeks offset karakter asli di dalam kalimat.

FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA

Alur Pipeline

Perolehan Entitas

Proses ini terbagi menjadi 2:

1. **Proses dari data QAC**
2. **Deteksi Kasus Tanda Kurung Menggunakan RegEx (Proses untuk mengakomodir karakteristik selingkung pada teks terjemahan)**

- Proses Alignment Lintas Bahasa (Cross-Lingual Alignment) pada dataset QAC:
  a. Membaca makna Proper Noun (PN) bahasa Arab **dalam bahasa Inggris** pada QAC.
  b. Mencari pasangannya dalam teks terjemahan
  c. Menerjemahkan nama entitas bahasa Inggris tersebut ke bahasa Indonesia.
  d. Melakukan **Token-Based Similarity Matching** (perhitungan kemiripan string leksikal dan semantik) antara token terjemahan bahasa Indonesia dengan nilai transliterasi tersebut.

Contoh Penerjemahan (menggunakan LLM)

seperti contoh:
Torah → Taurat
Injeel → Injil



Contoh Token-Based Similarity Matching

1. Data dari QAC (Syntactic Treebank)
   - Koordinat Ayat: 2:136 (Surah Al-Baqarah, Ayat 136).
   - Token Arab QAC: مُوسَىٰ yang secara gramatikal berlabel Proper Noun (PN).
   - Terjemahan Inggris QAC: "Moses".
2. Teks Terjemahan
   - Kalimat Ayat: "...dan apa yang diberikan kepada Musa..."
   - Sistem melakukan tokenisasi pada teks target menjadi deretan token kata: ["dan", "apa", "yang", "diberikan", "kepada", "Musa"]
3. Eksekusi Token-Based Similarity Matching

Sistem akan menerjemahkan nama "Moses" menjadi kata jembatan Indonesia "Musa", lalu menghitung kemiripan string (similarity score) antara kata jembatan "Musa" dengan setiap token dalam kalimat target:

- Match("Musa", "dan") → Skor kemiripan: 0.00
- Match("Musa", "apa") → Skor kemiripan: 0.00
- Match("Musa", "yang") → Skor kemiripan: 0.00
- Match("Musa", "diberikan") → Skor kemiripan: 0.05
- Match("Musa", "kepada") → Skor kemiripan: 0.00
- Match("Musa", "Musa") → Skor kemiripan: 1.00 (Match Sempurna)

4. Hasil Penguncian Boundary

Karena token ke-6 ("Musa") memiliki nilai kemiripan tertinggi, sistem secara otomatis mengunci posisi koordinat karakter awal dan akhir token tersebut. Batas rentang kata (span boundary) untuk entitas tokoh ini berhasil diidentifikasi tanpa eror pergeseran karakter

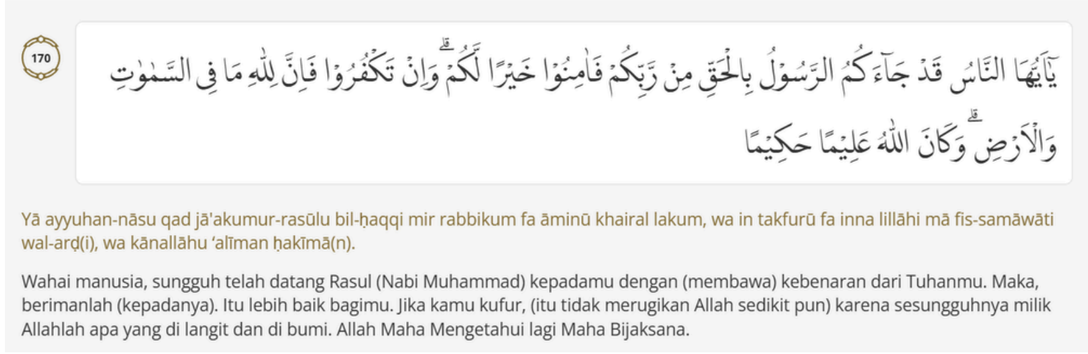
FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA

Alur Pipeline

Perolehan Entitas

- Deteksi Kasus Tanda Kurung Menggunakan RegEx:
  - **Karakteristik Teks Terjemahan**:
    - Teks Terjemahan sering kali menyisipkan kata penjelas di dalam tanda kurung untuk membantu pemahaman tafsir.
    - Contoh: "...ke bukit **(Sinai)**..." atau "...hari **(Kiamat)**...".
  - **Pipeline Penanganan Kasus Kurung**:
    i. Menerapkan ekspresi reguler (**Regex**) secara deterministik untuk menangkap teks yang berada di dalam tanda kurung: \((.*?)\).
    ii. Melakukan pemeriksaan silang teks hasil tangkapan tersebut ke dalam **Kamus Entitas IndQNER** asli.





Contoh Proses Regex (Tanda Kurung):

- Teks Target: "...ke bukit (Sinai)..."
- Regex Extraction: Pola \((.*?)\) mengekstrak kata "Sinai".
- Dictionary Lookup: Kata "Sinai" dicari di Kamus IndQNER. Ditemukan berlabel LOCATION.
- Hasil Akhir: Kata "Sinai" dideklarasikan sebagai entitas B-LOC.

Output dari proses Perolehan Entitas
kita sebut sebagai **Daftar Entitas**

FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA

Alur Pipeline

Pelabelan Entitas (Entity Labeling)

- Dasar Pemikiran: Efisiensi komputasi dan pencegahan kesalahan teologis (theological error) dilakukan dengan memisahkan entitas yang sudah dikenal (known entities) dari entitas baru (unmapped entities).
- Proses Input: Menerima input berupa Daftar Entitas mentah yang berhasil dikumpulkan dari Tahap 2 (Perolehan Entitas).
- Lapis 1 – Filtrasi Kamus (Dictionary Lookup):
  - Sistem melakukan pencocokan string secara langsung (dashed line "Cek") ke Kamus IndQNER.
  - Jika entitas ada di kamus (Iya): Sistem langsung menyematkan label kategori secara Deterministik (Tanpa LLM). Contoh: kata "Allah" otomatis dilabeli GOD dan "Musa" otomatis dilabeli PROPHET.
  - Manfaat: Menjamin keakuratan teologis 100% dan menghemat biaya komputasi API/LLM.
- Lapis 2 – Modular LLM-as-Labeler:
  - Jika entitas tidak ditemukan di kamus (Tidak Ada): Tugas pelabelan dialihkan ke agen kecerdasan buatan, yaitu Llama-3-8B secara lokal.

LLM-AS-LABELER & BATASAN MODEL

Model dilarang keras menyusun kalimat atau teks baru sendiri (generative pure). Tugas LLM murni sebagai klasifikator sekuensial untuk memilih satu dari 18 kategori kelas IndQNER yang sah.

Komparasi Dua Skenario Prompting:

- Zero-Shot Prompting:
  - LLM langsung diminta menebak kelas entitas berdasarkan kalimat konteks dan 18 definisi kategori tanpa contoh acuan.
  - Tujuan: Menguji kapasitas penalaran semantik dasar (zero-shot capabilities) dari model Llama-3-8B.

- Few-Shot Prompting:
  - Prompt LLM dibekali dengan 3 hingga 5 pasang contoh kalimat asli yang diambil langsung dari Kamus IndQNER (dashed line "Ambil Contoh").
  - Tujuan: Memberikan analogi logika penandaan bagi LLM untuk meminimalkan ambiguitas semantik pada struktur ayat Al-Qur'an.

CONTOH Pelabelan Entitas (Entity Labeling)

Daftar entitas mentah dari Tahap 2 kini dipetakan ke dalam 18 kelas kategori IndQNER melalui arsitektur keputusan dua lapis:

- Lapis 1 (Cek Kamus IndQNER - Deterministik):
  - Sistem mencocokkan kata "Allah" dan "Musa" ke dalam basis data Kamus IndQNER asli.
  - Karena ditemukan cocok, kata "Allah" otomatis diberi label teologis GOD dan "Musa" diberi label PROPHET secara deterministik. Langkah bypass ini menghemat biaya komputasi dan menjamin akurasi teologis 100%.
- Lapis 2 (Modular LLM-as-Labeler Llama-3-8B):
  - Jika sistem menemukan entitas baru yang "Tidak Ada" di kamus, pelabelan didelegasikan secara lokal kepada Llama-3-8B.
  - LLM dikunci secara ketat murni sebagai klasifikator (dilarang menyusun kalimat sendiri).
  - LLM diuji dengan dua skenario prompting: Zero-Shot (menganalisis berdasarkan definisi 18 kelas) dan Few-Shot (dibekali 3-5 contoh kalimat nyata dari Kamus IndQNER untuk mereduksi ambiguitas)
  -

FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA

Skenario Evaluasi

Evaluasi Intrinsik

- Metode Evaluasi Intrinsik: Pengujian dilakukan secara kaku dengan menghitung jumlah entitas yang diperoleh secara otomatis oleh pipeline khusus pada 8 surah yang dicakup oleh dataset IndQNER asli.
- Hipotesis Nol (H0): Kualitas anotasi entitas otomatis yang dihasilkan oleh pipeline hibrida sekuensial adalah sama (setara) dengan hasil anotasi manual IndQNER asli.
- Hipotesis Alternatif (H1): Kualitas data hasil otomatisasi pipeline hibrida ini diharapkan lebih tinggi (bahkan melampaui) akurasi manual manusia. Hal ini didorong oleh stabilitas kognitif dan kemampuan penalaran semantik kontekstual dari modular LLM-as-Labeler .
- Metrik Pengukuran: Menggunakan metrik tingkat entitas kaku (strict entity-level matching) untuk menghitung Strict F1-score, Precision, dan Recall .

Evaluasi Ekstrinsik

- Evaluasi Ekstrinsik (Downstream Task): Mengukur kegunaan praktis dataset dengan melatih model NER (seperti IndoBERT atau BiLSTM-CRF) menggunakan dataset perluasan Extended IndQNER.
- Skenario Apple-to-Apple (Adil & Tanpa Bias): Pengujian performa model NER hasil perluasan secara kaku dibatasi hanya dievaluasi pada data uji (test set) dari 8 surah yang ada di IndQNER asli.
- Prospek Pengajuan ke BRIN:
- Riset tugas akhir menggunakan model bahasa kecil lokal (small LLM Llama-3-8B) ini difungsikan sebagai studi kelayakan (feasibility study) fundamental.
- Arah Proposal BRIN: Mengajukan perluasan riset dengan memanfaatkan model parameter raksasa (seperti Qwen 2.5 72B atau Llama-3-70B) menggunakan klaster superkomputer GPU BRIN.
- Visi Riset Nasional: Menghasilkan model fondasi (foundation model) NER keagamaan nasional dengan akurasi F1-Score yang melampaui seluruh baseline manusia terdahulu

Kontribusi Penelitian

Metodologis

Menciptakan kerangka hibrida yang mensinergikan Knowledge Source (QAC), Cross-lingual projection, dan verifikator LLM untuk mengatasi kelangkaan data NLP.

Dataset Output

Menghasilkan Extended IndQNER Dataset berskala penuh (114 surat) dengan menjaga kompatibilitas format BIO dari benchmark aslinya.

Evaluasi Objektif

Menyediakan prosedur evaluasi terukur yang menguji validitas ekspansi data otomatis dengan performa downstream model yang sesungguhnya.

Terima Kasih