PROPOSAL PENELITIAN TUGAS AKHIR

Perluasan Dataset IndQNER melalui Penyelarasan Lintas Bahasa Menggunakan Metode *Similarity Matching* dan *Large Language Models* sebagai *Labeler*

Disusun Oleh:

Muhammad Fadhillah Akbar

11230910000023

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS SAINS DAN TEKNOLOGI

UNIVERSITAS ISLAM NEGERI SYARIF HIDAYATULLAH

JAKARTA

1447 H / 2026 M

LEMBAR PERSETUJUAN PROPOSAL TUGAS AKHIR

PROPOSAL TUGAS AKHIR

Perluasan Dataset IndQNER melalui Penyelarasan Lintas Bahasa Menggunakan Metode *Similarity Matching* dan *Large Language Models* sebagai *Labeler*

Proposal Tugas Akhir
Diajukan sebagai salah satu syarat untuk mengikuti
Seminar Proposal Tugas Akhir

Oleh:
Muhammad Fadhillah Akbar
NIM: 11230910000023

Menyetujui,

Dosen Pembimbing Proposal I	Dosen Pembimbing Proposal II
Ria Hari Gusmita M.Kom.	Khodijah Hulliyah, MSi, Ph.D.
NIP. 198208172009122002	NIP. 197304022001122001

DAFTAR ISI

LEMBAR PERSETUJUAN PROPOSAL TUGAS AKHIR ii
DAFTAR ISI iii
DAFTAR TABEL vi
DAFTAR GAMBAR vii
BAB I PENDAHULUAN 1
A. Latar Belakang 1
B. Identifikasi Masalah 4
C. Batasan Masalah 5
D. Rumusan Masalah 6
E. Tujuan Penelitian 6
F. Kontribusi Penelitian 7
G. Manfaat Penelitian 8
BAB II TINJAUAN PUSTAKA 9
A. Penelitian Terdahulu 9
1. Sintesis Penelitian Berdasarkan Tema 10
2. Tabel Penelitian Terdahulu 13
3. Analisis Tren Penelitian 15
4. Analisis Research Gap 16
5. Posisi Penelitian (State of the Art) 18
B. Natural Language Processing (NLP) 20
C. Named Entity Recognition (NER) 22
1. Definisi 22
2. Skema Anotasi BIO (BIO tagging scheme) 24
3. Evaluasi Named Entity Recognition 25
D. Konstruksi Dataset NER 27
1. Dataset sebagai Sumber Daya NLP 27
2. Gold Standard Annotation 28
3. Benchmark Dataset 29
4. Tantangan Perluasan Dataset 30

5. Prinsip Kualitas Dataset 31
6. Tantangan Konstruksi Dataset pada Domain Low-Resource 32
E. Named Entity Recognition pada Domain Al-Qur'an 33
F. Quranic Arabic Corpus (QAC) 37
1. Definisi Quranic Arabic Corpus 37
2. Struktur Informasi pada Quranic Arabic Corpus 38
3. Informasi Entitas pada Quranic Arabic Corpus 38
4. Pemanfaatan Quranic Arabic Corpus pada Penelitian NLP 39
5. Relevansi Quranic Arabic Corpus terhadap Penelitian 40
G. Cross-Lingual Annotation Projection 40
1. Konsep Cross-Lingual Annotation Projection 40
2. Word Alignment pada Korpus Paralel 41
3. Tantangan Cross-Lingual Annotation Projection 42
4. Relevansi terhadap Penelitian Dalam penelitian ini, ... 43
H. Large Language Model sebagai Pelabel (LLM-as-Labeler) 44
1. Konsep Large Language Model 44
2. Large Language Model pada Tugas NLP 44
3. Large Language Model sebagai Semantic Verifier 45
4. Prompt Engineering untuk Validasi Anotasi 46
5. Relevansi terhadap Penelitian 46
I. Evaluasi Kualitas Dataset NER 47
1. Konsep Evaluasi Kualitas Dataset NER 47
2. Evaluasi Berbasis Entity-Level 48
3. Precision, Recall, dan F1-Score 49
4. Validasi Kualitas Anotasi 50
5. Relevansi terhadap Penelitian 50
J. Kerangka Berpikir Penelitian 51
BAB III METODOLOGI PENELITIAN 54
A. Tahapan Penelitian *(Pipeline)* 54
B. Sumber Data Penelitian 55
1. IndQNER sebagai Benchmark 55

2. Quranic Arabic Corpus sebagai *Knowledge Source* 56
3. Teks Terjemahan 56
4. Peran Sumber Data dalam Penelitian 57
C. Perangkat Penelitian 58
1. Perangkat Keras 58
2. Perangkat Lunak 59
D. Arsitektur Metodologi Penelitian 59
E. Persiapan Dataset 61
1. Ekstraksi Data Syntax dan Morphology QAC 61
2. Pemrosesan Teks Terjemahan 62
3. *Adopsi Pedoman Anotasi* (Annotation Guideline) 63
F. Penyelarasan Lintas Bahasa (*Cross-Lingual Alignment*) 63
G. Pelabelan Entitas (*Entity Labeling*) 64
1. Pencocokan Kamus Entitas IndQNER *(Dictionary Lookup)* 64
2. Pendekatan Modular *LLM-as-Labeler* 64
H. Evaluasi Kualitas Dataset 65
1. Evaluasi Intrinsik (Entity-Level Annotation Matching) 65
2. Evaluasi Ekstrinsik / *Downstream Task Evaluation* (Pengujian Performa Model NER) 66
DAFTAR PUSTAKA 67

DAFTAR TABEL

Tabel 1 Komparatif Penelitian Terdahulu 13
Tabel 2 Analisis Research Gap 16
Tabel 3 Posisi Sumber Data dan Perannya dalam Penelitian 36
Tabel 4 Peran Sumber Data Penelitian..... 57
Tabel 5 Perangkat Keras Penelitian 58
Tabel 6 Perangkat Lunak Penelitian 59

DAFTAR GAMBAR

Gambar 1 Arsitektur Metodologi Penelitian 60
Gambar 2 Tab-Separated Values pada QAC 62
Gambar 3 Laman quran.kemenag.go.id 63

BAB I
PENDAHULUAN

A. Latar Belakang

Perkembangan *Natural Language Processing* (NLP) telah mendorong kemajuan berbagai teknologi berbasis bahasa, seperti *machine translation*, *question answering*, *information retrieval*, hingga *chatbot*. Meskipun demikian, keberhasilan pengembangan teknologi tersebut tidak hanya ditentukan oleh kemajuan arsitektur model, tetapi juga oleh ketersediaan sumber daya bahasa yang berkualitas. Berbagai penelitian menunjukkan bahwa dataset beranotasi memiliki peran yang sangat penting dalam proses pelatihan, validasi, dan evaluasi model NLP, khususnya pada bahasa atau domain yang masih tergolong *low-resource* (Ding et al., 2024; Drozdov & Pavlyshenko, 2025). Oleh karena itu, penyediaan dataset yang representatif dan konsisten menjadi salah satu tantangan utama dalam pengembangan NLP modern (Armaijn et al., 2024; Khairunnisa et al., 2024).

Salah satu tugas mendasar dalam NLP adalah *Named Entity Recognition* (NER), yaitu proses mengidentifikasi dan mengklasifikasikan entitas bernama, seperti nama orang, lokasi, organisasi, waktu, maupun entitas lain yang disesuaikan dengan karakteristik suatu domain (Idi Mohammed & Habiba Idi Idriss, 2026; Tarmizi & Saad, 2025). Berbeda dengan banyak tugas NLP lain, performa sistem NER sangat dipengaruhi oleh kualitas anotasi data yang digunakan (Basir, Qabulio, et al., 2026; Gusmita et al., 2023). Dataset yang memiliki cakupan terbatas, anotasi yang tidak konsisten, atau distribusi entitas yang kurang representatif akan berdampak langsung terhadap kemampuan model dalam mengenali entitas pada data baru. Dengan demikian, pada penelitian NER, tantangan yang dihadapi tidak hanya berkaitan dengan pengembangan model, tetapi juga dengan bagaimana membangun dan memperluas dataset anotasi yang mampu merepresentasikan karakteristik domain secara memadai (Armaijn et al., 2024).

Salah satu domain yang masih memiliki keterbatasan sumber daya adalah teks keagamaan, khususnya terjemahan Al-Qur'an berbahasa Indonesia Kementerian

Agama Republik Indonesia[1] (selanjutnya akan disebut sebagai teks terjemahan) (Khairunnisa et al., 2024; Tarmizi & Saad, 2025). Berbeda dengan korpus bahasa umum, teks terjemahan memiliki karakteristik linguistik yang khas karena memuat istilah teologis, nama tokoh, nama tempat, peristiwa sejarah, serta konsep-konsep religius yang tidak selalu ditemukan pada korpus bahasa Indonesia sehari-hari (Gusmita et al., 2023, 2024). Selain itu, gaya penerjemahan yang digunakan juga mengikuti kaidah tertentu sehingga menghasilkan struktur kalimat, pilihan diksi, dan hubungan semantik yang berbeda dengan teks umum. Karakteristik tersebut menyebabkan pendekatan NER yang dikembangkan pada domain umum belum tentu dapat diterapkan secara optimal pada teks terjemahan, sehingga dibutuhkan sumber daya bahasa yang secara khusus dibangun untuk domain tersebut (Basir, Vighio, et al., 2026).

Sebagai upaya awal dalam menyediakan sumber daya NER pada domain teks terjemahan, (Gusmita et al., 2023) mengembangkan IndQNER. Dataset ini menjadi *benchmark* pertama yang dibangun melalui anotasi manual. Kehadiran IndQNER telah menjadi fondasi awal yang penting bagi penelitian NER pada korpus religius berbahasa Indonesia, meskipun cakupannya masih terbatas. Dataset tersebut hanya mencakup delapan surah dari keseluruhan 114 surah Al-Qur'an, sehingga variasi kemunculan entitas, konteks linguistik, maupun pola penyebutan entitas pada keseluruhan teks terjemahan belum sepenuhnya terwakili (Gusmita et al., 2023). Keterbatasan tersebut tidak mengurangi peran IndQNER sebagai benchmark, tetapi menunjukkan adanya ruang pengembangan untuk memperluas cakupan dataset. Bahkan, penelitian IndQNER secara eksplisit menyatakan rencana untuk mengembangkan dataset agar mencakup seluruh surah Al-Qur'an pada pekerjaan selanjutnya(Gusmita et al., 2023).

Berbagai penelitian telah menunjukkan bahwa anotasi manual memerlukan waktu, biaya, dan keterlibatan anotator yang memahami domain secara mendalam agar kualitas anotasi tetap terjaga (Basir, Qabulio, et al., 2026; Gusmita et al., 2023; Tarmizi & Saad, 2025). Sebaliknya, pendekatan otomatis juga memiliki

[1] https://quran.kemenag.go.id/

keterbatasannya masing-masing. Pendekatan berbasis aturan (rule-based) umumnya memiliki presisi yang tinggi pada pola tertentu, tetapi kurang adaptif terhadap variasi bahasa. Pendekatan berbasis pembelajaran mesin membutuhkan data berlabel dalam jumlah besar, sedangkan pendekatan berbasis *Large Language Model* (LLM) mampu menghasilkan anotasi secara otomatis, tetapi masih berpotensi menghasilkan *hallucination,* inkonsistensi label, maupun ketidaksesuaian terhadap skema anotasi yang telah ditetapkan (Armaijn et al., 2024; Ye et al., 2024). Berdasarkan kajian pustaka yang dilakukan dalam penelitian ini, belum ditemukan pendekatan yang secara khusus merancang pipeline perluasan dataset IndQNER hingga mencakup keseluruhan korpus Al-Qur'an berbahasa Indonesia dengan tetap mempertahankan kompatibilitas terhadap skema anotasi benchmark tersebut.

Salah satu sumber daya yang berpotensi dimanfaatkan untuk mendukung proses perluasan dataset adalah Quranic Arabic Corpus (QAC)[2], yaitu korpus Al-Qur'an berbahasa Arab yang telah dianotasi secara linguistik dan semantik. QAC menyediakan informasi mengenai kategori gramatikal, analisis morfologi, relasi sintaksis, serta anotasi berbagai *Proper Noun* (PN) yang muncul pada teks Al-Qur'an dengan memanfaatkan Quranic Arabic Corpus (QAC) sebagai sumber pengetahuan terstruktur untuk memberikan informasi linguistik dan semantik mengenai entitas pada teks sumber Al-Qur'an sebelum proses proyeksi ke teks target. Meskipun demikian, proses lintas bahasa tidak dapat dilakukan secara langsung tanpa mempertimbangkan perbedaan karakteristik linguistik antara bahasa Arab pada teks Al-Qur’an dan bahasa Indonesia. Lebih lanjut, (Gusmita et al., 2023) menemukan teknik terjemahan tersendiri pada teks terjemahan yang salah satunya berdampak pada munculnya entitas baru. Dengan demikian, proses penyelasaran lintas bahasa untuk menemukan entitas pada teks terjemahan membutuhkan mekanisme khusus.

[2] https://corpus.quran.com/

Dalam konteks tersebut, penelitian ini mengusulkan suatu *Pipeline* perluasan dataset yang mengombinasikan tiga komponen dengan peran yang saling melengkapi.

Berdasarkan uraian tersebut, penelitian ini mengusulkan sebuah *pipeline* perluasan dataset NER semiotomatis yang berorientasi pada pemeliharaan kompatibilitas secara ketat terhadap *benchmark* IndQNER. Tahap pertama difokuskan pada persiapan dataset, yang meliputi penyiapan data gramatikal *Proper Noun* (PN) dari *syntactic treebank Quranic Arabic Corpus* (QAC), korpus teks target terjemahan, serta adopsi pedoman anotasi IndQNER. Tahap kedua memanfaatkan penyelarasan lintas bahasa (*cross-lingual alignment*) untuk memproyeksikan entitas PN Arab ke dalam teks terjemahan melalui proses pemadanan kemiripan token (*token similarity matching*). Selanjutnya, tahap ketiga berfokus pada pelabelan entitas dengan memetakan kategori menggunakan kamus entitas IndQNER yang diintegrasikan dengan pendekatan modular *LLM-as-labeler*. Pada tahap ini, *Large Language Model* Llama-3-8B dimanfaatkan melalui skenario *Zero-Shot* dan *Few-Shot prompting* untuk memvalidasi sekaligus menentukan label entitas secara presisi berdasarkan konteks kalimat. Sebagai tahap akhir, evaluasi kualitas dataset dilakukan secara empiris dengan mengukur performa model NER yang dilatih menggunakan dataset hasil perluasan (*Extended IndQNER*). Guna memastikan pembandingan performa yang adil (*apple-to-apple*), pengujian ini dibatasi secara ketat menggunakan 8 surah *gold standard* acuan asli dari dataset IndQNER. Luaran yang diharapkan bukan hanya berupa dataset dengan cakupan yang lebih luas, tetapi juga sebuah kerangka metodologis yang dapat direplikasi untuk mendukung pengembangan dataset NER pada korpus religius maupun domain *low-resource* lainnya

B. Identifikasi Masalah

Berdasarkan uraian pada latar belakang, penelitian ini mengidentifikasi beberapa permasalahan sebagai berikut.

1. Cakupan dataset *benchmark* IndQNER masih terbatas pada delapan surah, sehingga diperlukan perluasan korpus agar lebih representatif untuk model NER domain Al-Qur'an.
2. Berdasarkan kajian literatur, belum terdapat *pipeline* konstruksi dataset yang secara khusus mengintegrasikan penyelarasan lintas bahasa, aturan linguistik, dan validasi semantik untuk korpus religius.
3. Proses anotasi manual seutuhnya membutuhkan biaya dan waktu yang besar, sehingga diperlukan mekanisme semiotomatis yang tetap mampu mempertahankan kualitas dan kompatibilitas anotasi
4. Model LLM memiliki keterbatasan dalam melakukan proses pelabelan data secara sepenuhnya karena masih adanya risiko halusinasi informasi (hallucination) yang tinggi, sehingga memerlukan panduan kamus terstruktur dan tidak dapat digunakan sebagai generator pelabel tunggal yang mandiri (Gusmita et al., 2026)

C. Batasan Masalah

Agar penelitian memiliki ruang lingkup yang jelas dan terarah, penelitian ini dibatasi pada beberapa aspek berikut.

1. Objek penelitian adalah perancangan *Pipeline* perluasan dataset IndQNER.
2. Dataset acuan yang digunakan adalah IndQNER sebagai benchmark, dengan skema anotasi BIO, kategori entitas, pedoman anotasi, dan format data yang tersedia pada versi dataset yang digunakan dalam penelitian ini.
3. Penelitian ini tidak bertujuan mengubah atau mendefinisikan ulang skema anotasi IndQNER. Apabila ditemukan kasus yang belum terakomodasi secara eksplisit oleh pedoman anotasi, kasus tersebut akan didokumentasikan dan ditangani melalui prosedur yang ditetapkan dalam penelitian tanpa mengubah skema benchmark secara sembarangan
4. Sumber pengetahuan yang digunakan untuk memperoleh kandidat entitas berasal dari Quranic Arabic Corpus (QAC) yang diproyeksikan ke dalam teks terjemahan melalui penyelarasan lintas bahasa.

5. *Pipeline* yang diusulkan terdiri atas tahapan persiapan dataset, *cross-lingual alignment,* pelabelan entitas menggunakan kamus IndQNER dan *LLM-as-labeler,* serta evaluasi kualitas dataset.
6. Penelitian ini tidak bertujuan untuk mengubah, mendefinisikan ulang, atau menambah skema kategori anotasi dari *benchmark* IndQNER. Apabila ditemukan kasus entitas baru yang tidak tercakup dalam pedoman IndQNER, kasus tersebut akan didokumentasikan sebagai kasus di luar pedoman (*out-of-Vocabulary*) guna menjaga kompatibilitas dataset hasil perluasan secara ketat
7. Evaluasi penelitian difokuskan pada kualitas *Pipeline* dan mengusukan anotasi yang konsisten terhadap benchmark, sedangkan model NER hanya digunakan sebagai alat evaluasi terhadap kualitas dataset yang dihasilkan, bukan sebagai fokus utama penelitian.

D. Rumusan Masalah

Berdasarkan identifikasi masalah yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana merancang suatu *Pipeline* perluasan dataset IndQNER yang mampu mempertahankan kompatibilitas terhadap benchmark IndQNER?
2. Bagaimana mengevaluasi efektivitas *Pipeline* yang diusulkan dalam menghasilkan dataset dengan kualitas anotasi yang mendekati *Benchmark* IndQNER?

E. Tujuan Penelitian

Penelitian ini bertujuan merancang pipeline perluasan dataset NER pada teks terjemahan dengan mengacu pada benchmark IndQNER, menghasilkan dataset hasil perluasan yang mempertahankan kompatibilitas terhadap skema anotasi dan format data IndQNER, serta mengevaluasi kualitas anotasi yang dihasilkan melalui prosedur evaluasi yang dirancang dalam penelitian ini.

F. Kontribusi Penelitian

Penelitian ini diharapkan memberikan kontribusi pada aspek metodologis, sumber daya, dan evaluasi dalam pengembangan NER pada domain teks terjemahan. Kontribusi tersebut dijabarkan sebagai berikut.

1. Kontribusi Metodologis

   Penelitian ini mengusulkan sebuah *pipeline* konstruksi dan perluasan dataset NER yang mengintegrasikan sumber pengetahuan terstruktur (*structured knowledge source*), *cross-lingual annotation projection*, *rule-based refinement*, dan *semantic verification* berbasis *Large Language Model* (LLM). Integrasi keempat komponen tersebut dirancang untuk mewujudkan alur konstruksi dataset yang lebih sistematis dan terukur, sehingga proses anotasi tidak sepenuhnya bergantung pada anotasi manual yang memakan biaya dan waktu, maupun model generatif murni yang rentan terhadap isu *hallucination*.

2. Kontribusi Dataset

   Penelitian ini menghasilkan dataset hasil perluasan IndQNER (*Extended IndQNER Dataset*) dengan cakupan korpus yang lebih luas dibandingkan *benchmark* awal. Dataset ini dikembangkan dengan tetap mempertahankan kompatibilitas terhadap skema anotasi BIO, kategori entitas, serta format pelabelan *benchmark* asli yang digunakan sebagai acuan, sehingga dapat berfungsi sebagai sumber daya bahasa (*language resource*) yang lebih representatif bagi pengembangan model NER pada domain Al-Qur'an berbahasa Indonesia.

3. Kontribusi Evaluasi

   Penelitian ini menyediakan prosedur evaluasi kualitas anotasi hasil perluasan melalui pembandingan secara *entity-level* terhadap anotasi acuan pada subset evaluasi yang divalidasi, serta dilengkapi dengan analisis kesalahan (*error analysis*) anotasi. Kerangka evaluasi ini disusun untuk memberikan gambaran yang transparan dan objektif mengenai efektivitas

pipeline yang diusulkan, sekaligus menjadi referensi metodologis bagi penelitian lanjutan dalam pengembangan dataset pada korpus religius maupun domain *low-resource* lainnya.

G. Manfaat Penelitian

1. Manfaat Teoritis

   Penelitian ini diharapkan dapat memberikan kontribusi terhadap pengembangan kajian *Natural Language Processing,* khususnya pada bidang konstruksi dataset *Named Entity Recognition* untuk domain religius. Selain itu, penelitian ini diharapkan dapat memperkaya kajian mengenai pemanfaatan penyelarasan lintas bahasa, sumber pengetahuan terstruktur, serta pendekatan hibrida dalam proses anotasi semiotomatis pada korpus *low-resource.*

2. Manfaat Praktis

   Penelitian ini diharapkan memberikan manfaat praktis sebagai berikut.

   a. Menghasilkan *Pipeline* yang dapat digunakan sebagai acuan dalam proses perluasan dataset NER pada teks terjemahan.
   b. Menyediakan dataset hasil perluasan yang tetap mempertahankan kompatibilitas terhadap benchmark IndQNER sehingga dapat dimanfaatkan sebagai sumber daya bagi penelitian lanjutan.
   c. Memberikan alternatif pendekatan konstruksi dataset yang memadukan sumber pengetahuan terstruktur, penyelarasan lintas bahasa, dan validasi otomatis untuk mendukung pengembangan dataset pada domain *low-resource* lainnya.

BAB II
TINJAUAN PUSTAKA

A. Penelitian Terdahulu

Penelitian mengenai Named Entity Recognition (NER) telah mengalami perkembangan yang pesat dalam beberapa dekade terakhir seiring dengan kemajuan bidang *Natural Language Processing* (NLP) (Khurana et al., 2022a). Perkembangan tersebut tidak hanya ditandai oleh meningkatnya kemampuan model dalam mengenali entitas melalui pendekatan berbasis *Deep learning* dan *Transformer* (Jurafsky & Martin, n.d.), tetapi juga oleh meningkatnya perhatian terhadap pembangunan sumber daya bahasa *(language resources)* berupa korpus dan dataset beranotasi yang berkualitas (Khairunnisa et al., 2024). Ketersediaan dataset yang representatif menjadi faktor penting karena berpengaruh langsung terhadap kemampuan model dalam memahami karakteristik bahasa maupun domain tertentu (Mayhew et al., 2024).

Pada domain Al-Qur'an, penelitian NER berkembang melalui dua arah utama. Pertama, penelitian yang berfokus pada pengembangan model ekstraksi entitas dengan memanfaatkan korpus berbahasa Arab sebagai sumber daya utama (Tarmizi & Saad, 2025). Kedua, penelitian yang berfokus pada pembangunan dan perluasan dataset sebagai fondasi pengembangan sistem NER (Gusmita et al., 2023 Large Language Model). Seiring berkembangnya kebutuhan terhadap bahasa dengan sumber daya terbatas *(low-resource languages)*, berbagai penelitian mulai mengeksplorasi pendekatan seperti Cross-Lingual Annotation Projection, *Rule-Based Annotation Refinement*, serta pemanfaatan (LLM) untuk mendukung proses anotasi dan validasi semantik (Chen et al., 2024; Politov et al., 2025; Wen et al., 2020).

Berdasarkan hasil Systematic Literature Review (SLR) yang dilakukan pada penelitian ini, diperoleh sejumlah artikel ilmiah yang relevan dan selanjutnya dianalisis berdasarkan tema penelitian (Tarmizi & Saad, 2025). Analisis tersebut

bertujuan untuk mengidentifikasi perkembangan penelitian, pendekatan yang telah digunakan, keterbatasan penelitian sebelumnya, serta peluang pengembangan yang menjadi dasar penyusunan metodologi penelitian ini. Oleh karena itu, pembahasan penelitian terdahulu tidak disusun sebagai ringkasan setiap artikel secara terpisah, melainkan melalui sintesis berdasarkan tema agar hubungan antarpenelitian dapat dipahami secara lebih komprehensif.

1. Sintesis Penelitian Berdasarkan Tema

Pada bagian ini dibahas hasil kajian literatur berdasarkan enam tema utama, yaitu:

a. Perkembangan Metode Named Entity Recognition

Evolusi metode NER bergerak dari pendekatan *rule-based* dan statistik klasik menuju arsitektur *deep learning* seperti BiLSTM-CRF, hingga model *Transformer* mutakhir dan LLM (Jurafsky & Martin, 2024; Khurana et al., 2022b). Seiring dengan tren peningkatan performa model yang signifikan, literatur mutakhir menyoroti bahwa performa *state-of-the-art* sistem NLP sangat bergantung pada kualitas *gold standard* dataset yang digunakan (Mayhew et al., 2024). Kompleksitas arsitektur tidak akan optimal apabila dihadapkan pada anotasi yang inkonsisten (Khairunnisa et al., 2024).

b. Named Entity Recognition pada Domain Al-Qur'an

Pada domain teks religius, penelitian NER berhadapan dengan kompleksitas semantik teologis. Penggunaan *Quranic Arabic Corpus* (QAC) telah banyak dieksplorasi sebagai sumber analisis morfologis yang komprehensif untuk teks berbahasa Arab (Dukes et al., 2013). Namun, penelitian ekstraksi entitas pada teks terjemahan masih sangat terbatas. IndQNER hadir sebagai *benchmark* perintis untuk menjembatani hal tersebut dengan 18 kelas entitas standar (Gusmita et al., 2023), menjadikannya pijakan utama dalam mengevaluasi model pada domain teks terjemahan.

Terkait penyediaan *benchmark* dataset, Gusmita et al. (2023) mengembangkan IndQNER dengan menerapkan skema penandaan BIO (*Beginning-Inside-Outside*). Proses konstruksi dataset tersebut dilakukan melalui anotasi manual pada delapan surah teks terjemahan. Untuk menjaga kualitas *ground truth*, proses ini melibatkan anotator manusia yang dilanjutkan dengan verifikasi kandidat entitas dan kategori oleh ahli Al-Qur'an dan Tafsir. Lebih lanjut, eksperimen pada penelitian tersebut menunjukkan bahwa model *deep learning* maupun *transformer* seperti BiLSTM-CRF dan IndoBERT mampu memanfaatkan IndQNER sebagai data latih dengan performa yang kompetitif (Gusmita et al., 2023, 2024). Hal ini membuktikan validitas IndQNER sebagai acuan, yang dalam penelitian ini digunakan sebagai *benchmark* sekaligus titik tolak untuk proses perluasan dataset (*dataset expansion*)

c. Konstruksi dan Perluasan Dataset NER

Dalam membangun dataset NLP, *manual annotation* dapat menghasilkan anotasi acuan dengan tingkat validitas yang tinggi apabila dilakukan menggunakan pedoman anotasi yang jelas serta melalui proses validasi dan/atau *adjudication*, tetapi pendekatan ini memiliki keterbatasan dari sisi skalabilitas dan biaya (Olewniczak & Szymański, 2025).

d. Penyelarasan Lintas Bahasa (*Cross-Lingual Alignment*) dan *Similarity Matching*

Pemindahan informasi entitas dari bahasa sumber ke bahasa target (transfer anotasi lintas bahasa) terbukti efisien untuk mengatasi kelangkaan data pada *low-resource language* (Agić et al., 2016; Politov et al., 2025). Namun, proses *word alignment* dari bahasa Arab ke bahasa Indonesia sering terhambat oleh ketidaksesuaian struktur bahasa (*structural divergence*). Perbedaan urutan sintaksis membuat proyeksi langsung rentan meleset dari batas entitas (*span boundary*). Sebagai solusinya, metode *token similarity matching* (pemadanan kemiripan

token) diterapkan untuk mengevaluasi kemiripan leksikal guna mengunci batas rentang entitas secara akurat tanpa harus bergantung pada aturan urutan sintaksis yang kaku.

e. Ekstraksi Entitas dalam Tanda Kurung Menggunakan Ekspresi Reguler (RegEx)

Teks terjemahan Al-Qur'an, khususnya versi Kemenag, memiliki gaya selingkung yang unik, yaitu penggunaan tanda kurung untuk menyisipkan kata penjelas. Pendekatan statistik murni maupun proyeksi lintas bahasa sering kali gagal atau menghasilkan *noise* saat berhadapan dengan intrusi tanda baca ini (Hwa et al., 2005). Oleh karena itu, untuk mereduksi *error*, pendekatan deterministik menggunakan ekspresi reguler (RegEx) difungsikan secara khusus untuk mendeteksi, mengurai, dan mengunci entitas yang berada di dalam maupun beririsan dengan tanda kurung, sehingga batasan rentang (*span boundary*) diekstrak secara presisi.

f. Metode Pelabelan Entitas Berbasis Kamus dan *LLM-as-Labeler*

Pemanfaatan LLM sebagai generator anotasi mandiri sering kali terkendala isu *hallucination* dan ketidakpatuhan pada skema label (Li et al., 2024). Oleh karena itu, pendekatan modern mulai mereposisi LLM bukan sebagai generator tunggal, melainkan sebagai modul pelabel spesifik. Pendekatan ini mengadopsi konsep *LLM-as-labeler* yang memanfaatkan model bahasa berukuran kecil (*small LLMs*, seperti Llama-3-8B) melalui teknik *zero-shot* dan *few-shot prompting* (Armaijn et al., 2024; Chen et al., 2024). Dipandu oleh kamus entitas referensi, model ditugaskan secara eksklusif untuk memetakan kategori kelas entitas secara presisi, menjaga agar keluaran tetap taat pada pedoman anotasi tanpa menghasilkan teks generatif yang berlebihan.

2. Tabel Penelitian Terdahulu

Setelah sintesis tematik, disajikan tabel komparatif yang merangkum penelitian-penelitian paling relevan yang mendasari kerangka metodologi penelitian ini.

Tabel 1 Komparatif Penelitian Terdahulu

Penelitian	Tahun	Fokus Penelitian	Metode/ Pendekatan	Dataset	Temuan Utama	Keterbatasan	Relevansi Terhadap Penelitian
Gusmita et al.	2023	*Benchmark* NER teks terjemahan	Anotasi manual BIO *tagging scheme*, pemodelan sekuensial (*BiLSTM+ CRF, IndoBERT*)	IndQNER, 8 surah	Menghasilkan benchmark NER domain-spesifik dengan 2.475 named entities dan menyediakan pedoman serta kategori entitas untuk anotasi	Cakupan korpus terbatas pada 8 dari 114 surah	Menjadi **benchmark, acuan skema anotasi, dan dasar perluasan dataset** dalam penelitian ini
Politov et al.	2025	Transfer data lintas bahasa pada *low-resource language*	*Projection-based Data Transfer*, *Word Alignment*	Korpus multibahasa	Proyeksi sangat menekan biaya anotasi, namun akurasinya bergantung pada kedekatan struktur antarbahasa.	Belum memiliki solusi khusus untuk anomali gaya selingkung teks terjemahan.	Menjadi landasan metodologi pemetaan dari Arab (*QAC*) ke teks terjemahan.
Chen et al.	2024	LLM sebagai penentu kategori	*LLM-as-labeler* menggunakan model	Benchmark NER umum	Memfungsikan *small LLMs* sebagai	Masih memerlukan batasan ekstraksi	Menjadi landasan teoritis pelabelan

		entitas (*few-shot classification*)	bahasa kecil *(small LLMs)* melalui skenario *zero-shot* dan *few-shot prompting.*		penentu kelas berbasis referensi secara drastis menekan *hallucination*.	(*span boundary*) yang jelas dari sistem hulu sebelum pelabelan	hibrida menggunakan *small LLMs* (Llama-3) secara terpandu.
Mayhew et al.	2024	Standar evaluasi dataset multibahasa	*Universal NER*, evaluasi tingkat entitas, *Inter-Annotator Agreement*	*Universal NER*	Standar *gold standard* berdampak eksponensial pada kemampuan generalisasi model hilir.	Berfokus pada domain terbuka/umum, bukan nomenklatur spesifik teologis.	Standar referensi evaluasi komputasional (*Strict/Relaxed F1*) kualitas ekspansi dataset.
Dukes et al.	2013	Anotasi sintaksis dan morfologi teks Al-Qur'an berbahasa Arab	*Supervised annotation*, analisis linguistik tradisional Arab	*Quranic Arabic Corpus* (QAC)	QAC menyajikan detail metadata tingkat kata yang sangat presisi, termasuk label *Proper Noun* (PN).	Hanya merepresentasikan teks Arab, belum terhubung otomatis secara entitas ke teks bahasa lain.	Menjadi sumber pengetahuan terstruktur (*structured knowledge source*) yang mendukung identifikasi kandidat entitas dan proses proyeksi lintas bahasa dalam penelitian ini
Armaijn et al.	2024	Ekspansi dataset NER menggunakan LLM	*LLM-as-labeler* menggunakan model bahasa kecil *(small LLMs)* melalui teknik augmentasi data	Korpus Berita	LLM dapat memetakan dan memperbanyak korpus data latih secara efisien.	Rentan pergeseran format kelas (*format violation*) jika instruksi tidak dibatasi dengan ketat.	Menekankan efisiensi model kecil dalam mereduksi biaya komputasi dan *noise* pada *pipeline* hibrida.

			berbasis instruksi.				

3. Analisis Tren Penelitian

Berdasarkan sintesis literatur, bagian ini mengidentifikasi tren penelitian yang berkembang, antara lain:

a. **Dominasi penelitian yang berfokus pada pengembangan model NER**

   Mayoritas riset berusaha memecahkan masalah arsitektur algoritma (meningkatkan skor prediksi), namun masih sedikit yang membedah kelemahan pada sisi data pelatihannya (*dataset construction*).

b. **Meningkatnya penggunaan *Transformer* dan LLM**

   Terjadi pergeseran radikal menuju LLM, namun penggunaannya mulai bergeser dari generator mandiri menuju alat bantu kognitif (seperti fungsi validasi/penalaran).

c. **Bertambahnya penelitian mengenai pembangunan dataset**

   Terdapat urgensi global untuk mencetak *Gold/Silver Standard* yang berkualitas seiring dengan matangnya arsitektur pemodelan, terutama untuk skenario *low-resource*.

d. **Berkembangnya pendekatan *Cross-Lingual Annotation Projection***

   Pendekatan ini semakin diandalkan sebagai metode *cost-effective* untuk mereplikasi kesuksesan data bahasa kaya (seperti Inggris/Arab) menuju bahasa sumber daya terbatas.

e. **Meningkatnya perhatian terhadap kualitas anotasi melalui kombinasi pendekatan berbasis aturan dan LLM**

   Karena kelemahan masing-masing, sistem *Pipeline* hibrida yang menyatukan aturan deterministik (*Rule-based*) dengan ketangkasan

semantik (LLM) menjadi *state-of-the-art* dalam perbaikan anomali dataset.

Analisis tren ini menjadi dasar dalam memahami arah perkembangan penelitian NER serta menunjukkan posisi penelitian yang diusulkan, yaitu berfokus pada sisi hulu (kualitas dan cakupan dataset) melalui pendekatan hibrida lintas bahasa.

4. Analisis Research Gap

Hasil kajian literatur menunjukkan bahwa masih terdapat beberapa kesenjangan penelitian yang perlu mendapat perhatian. Kesenjangan tersebut meliputi keterbatasan sumber daya bahasa Indonesia pada domain Al-Qur'an, masih terbatasnya penelitian yang berfokus pada konstruksi dataset dibandingkan pengembangan model, serta belum optimalnya integrasi antara sumber pengetahuan, proyeksi lintas bahasa, penyempurnaan berbasis aturan, dan verifikasi semantik dalam satu alur konstruksi dataset.

Analisis *research gap* disajikan dalam bentuk tabel yang menghubungkan temuan penelitian terdahulu dengan kontribusi penelitian yang diusulkan.

Tabel 2 Analisis Research Gap

Research Gap	Bukti dari Literatur	Dampak	Kontribusi Penelitian
Resource Gap	Kurangnya *resource* NLP berlabel spesifik untuk bahasa Indonesia, terlebih pada domain terjemahan	Pengembangan teknologi NLP (seperti pencarian semantik atau *QA system* Al-Qur'an berbahasa Indonesia) menjadi stagnan karena	Menyediakan sumber daya berskala penuh (114 surah) sebagai infrastruktur data fundamental bagi riset *downstream* NLP Islami.

	keagamaan yang sarat makna (Tarmizi & Saad, 2025; Khairunnisa et al., 2024).	tidak ada data latih yang memadai.	
Dataset Gap	Dataset IndQNER sebagai *benchmark* perintis hanya memuat 8 dari 114 surah Al-Qur'an (Gusmita et al., 2023).	Model algoritma memiliki rasio representasi *Out-of-Vocabulary* (OOV) yang tinggi, sehingga gagal menggeneralisasi korpus Al-Qur'an secara utuh.	Memperluas cakupan dataset (*Dataset Expansion*) menuju *Extended* IndQNER *Dataset* berskala 114 surah tanpa meninggalkan kompatibilitas label aslinya.
Annotation Gap	Anotasi manual memakan biaya eksponensial (Basir et al., 2026), sedangkan LLM generatif murni rentan *hallucination* dan tidak mematuhi skema label (Li et al., 2024).	Ekspansi korpus menjadi proses yang buntu: mahal jika manual, kotor (*noisy*) jika diserahkan sepenuhnya pada komputasi generatif murni.	Mengusulkan arsitektur konstruksi dataset hibrida yang memosisikan LLM sebatas pemverifikasi (bukan generator) yang dipandu oleh *structured knowledge source*
Linguistic Gap	Divergensi sintaksis lintas bahasa (Arab-Indonesia) mempersulit transfer anotasi langsung antartoken karena	Menimbulkan ketidakakuratan penentuan batas entitas (*span boundary error*) yang menjatuhkan nilai *Strict F1-Score*.	Mengusulkan metode *Token Similarity Matching* untuk mengatasi divergensi sintaksis, dipadukan dengan ekspresi reguler (RegEx) secara deterministik

	perbedaan struktur gramatikal yang signifikan (Politov et al., 2025).		untuk mendeteksi entitas di dalam tanda kurung pada teks terjemahan.
Semantic Gap	Identifikasi entitas pada teks terjemahan tidak selalu dapat dilakukan hanya berdasarkan kemiripan permukaan karena perbedaan bentuk dan konteks semantik	Kandidat entitas dapat dipetakan ke kategori yang tidak sesuai atau menghasilkan anotasi yang tidak konsisten.	Memanfaatkan Quranic Arabic Corpus (QAC) sebagai structured knowledge source untuk menyediakan informasi linguistik dan semantik yang mendukung identifikasi serta verifikasi kandidat entitas sebelum diproyeksikan ke teks target.

5. Posisi Penelitian (State of the Art)

Posisi penelitian ini ditegaskan sebagai penelitian konstruksi dan perluasan sumber daya (*resource construction*), bukan penelitian untuk merancang arsitektur algoritma model NER baru. Berdasarkan kajian pustaka yang dilakukan, penelitian ini memosisikan diri dengan mengusulkan *pipeline* hibrida yang mengintegrasikan sumber pengetahuan terstruktur, *cross-lingual annotation projection* (melalui *token similarity matching* dan RegEx), serta pelabelan entitas menggunakan pendekatan *LLM-as-labeler* (*small LLMs*) untuk memperluas cakupan IndQNER menjadi berskala penuh.

Kebaruan penelitian ini tidak diletakkan pada penciptaan kategori entitas baru, melainkan pada perancangan *pipeline* konstruksi dataset yang secara ketat mempertahankan kompatibilitas terhadap *benchmark* awal. Secara

spesifik, posisi penelitian ini berdiri kokoh dengan menolak tiga metodologi tunggal yang memiliki kelemahan fundamental: a. Menolak pendekatan ekspansi manual murni (Gusmita et al., 2023) karena hambatan skalabilitas biaya dan waktu untuk sisa 106 surah. b. Menolak pendekatan proyeksi lintas bahasa tradisional (Politov et al., 2025) karena kerentanannya terhadap *span boundary error* akibat divergensi sintaksis Arab-Indonesia, khususnya pada gaya selingkung tanda kurung teks terjemahan. c. Menolak pelabelan LLM secara generatif murni (Armaijn et al., 2024; Li et al., 2024) karena tingginya risiko *hallucination* dan pelanggaran skema pelabelan (*format violation*).

Sebagai *state of the art* dari rancangan solusinya, penelitian ini mengawinkan keunggulan dari pendekatan-pendekatan tersebut: menggunakan *Quranic Arabic Corpus* (QAC) sebagai referensi *Proper Noun*; mengekstraksi batasan rentang entitas (*span boundary*) melalui metode *Token Similarity Matching* yang diperkuat dengan penguncian RegEx untuk kasus tanda kurung secara deterministik; dan diakhiri oleh pemetaan kategori semantik menggunakan *LLM-as-labeler* (Llama-3-8B melalui skenario *Zero-Shot/Few-Shot*) yang dipandu oleh kamus entitas.

Luaran yang ditargetkan dari *pipeline* ini adalah *Extended IndQNER Dataset* yang dianotasi secara semiotomatis. Guna membuktikan status kualitasnya secara empiris dan definitif, dataset hasil perluasan ini akan dievaluasi secara ekstrinsik (*downstream task evaluation*). Performa model NER yang dilatih menggunakan dataset perluasan tersebut akan diuji secara *apple-to-apple* terhadap 8 surah *gold standard* acuan asli IndQNER. Dengan demikian, justifikasi kualitas dataset tidak didasarkan pada asumsi teoretis, melainkan dibuktikan melalui evaluasi performa model yang terukur dan representatif.

B. Natural Language Processing (NLP)

Natural Language Processing (NLP) merupakan salah satu cabang ilmu Artificial Intelligence (AI) yang berfokus pada pengembangan metode dan sistem komputasi agar mampu memahami, memproses, menganalisis, serta menghasilkan bahasa alami yang digunakan manusia (Jurafsky & Martin, 2024). Tujuan utama NLP adalah menjembatani komunikasi antara manusia dan komputer melalui representasi bahasa yang dapat dipahami oleh mesin. Dalam implementasinya, NLP menggabungkan berbagai disiplin ilmu, seperti linguistik, ilmu komputer, statistik, dan *machine learning*, sehingga mampu mendukung berbagai aplikasi, di antaranya *machine translation, information retrieval, question answering, sentiment analysis, text summarization*, hingga *Named Entity Recognition* (NER) (Khurana et al., 2022b).

Perkembangan NLP mengalami perubahan yang signifikan seiring dengan evolusi pendekatan komputasi bahasa (Cambria & White, 2014). Pendekatan awal didominasi oleh metode berbasis aturan (rule-based) yang mengandalkan kaidah linguistik yang dirancang secara manual (Jurafsky & Martin, 2024). Seiring meningkatnya ketersediaan data digital, pendekatan tersebut mulai bergeser ke metode statistik (statistical NLP) yang memanfaatkan probabilitas untuk memodelkan hubungan antar kata (Cambria & White, 2014). Perkembangan selanjutnya ditandai dengan pemanfaatan *deep learning*, khususnya sejak diperkenalkannya arsitektur *Transformer*, yang memungkinkan model memahami hubungan kontekstual antarkata secara lebih efektif dibandingkan pendekatan sebelumnya (Khurana et al., 2022b). Kemajuan tersebut kemudian melahirkan *Large Language Model* (LLM) yang dilatih menggunakan korpus berskala besar sehingga mampu melakukan berbagai tugas NLP secara zero-shot, few-shot, maupun instruction-following (Jurafsky & Martin, 2024).

Meskipun perkembangan arsitektur model terus mengalami peningkatan, berbagai penelitian menunjukkan bahwa kualitas sistem NLP tidak hanya ditentukan oleh kompleksitas model, tetapi juga sangat dipengaruhi oleh kualitas

sumber daya bahasa (language resources) yang digunakan. Dataset yang memiliki anotasi konsisten, cakupan representatif, serta sesuai dengan karakteristik domain terbukti memberikan pengaruh yang signifikan terhadap performa model pada berbagai tugas NLP. Sebaliknya, keterbatasan dataset masih menjadi tantangan utama pada bahasa maupun domain yang tergolong *low-resource*, karena jumlah data berlabel yang tersedia relatif sedikit dan proses anotasi memerlukan biaya serta keahlian yang tinggi (Khairunnisa et al., 2024).

Kondisi tersebut mendorong berkembangnya berbagai penelitian yang berfokus pada penyediaan dan perluasan sumber daya bahasa. (Gusmita et al., 2023) memperkenalkan IndQNER, yaitu *Benchmark Dataset* NER pada teks terjemahan sebagai salah satu upaya menyediakan sumber daya untuk domain religius yang sebelumnya belum memiliki dataset standar. Sementara itu, (Khairunnisa et al., 2024) menunjukkan bahwa peningkatan kualitas dataset melalui domain transfer dan *Data Augmentation* mampu meningkatkan performa NER pada domain spesifik bahasa Indonesia. Pada konteks bahasa *low-resource,* berbagai penelitian terkini juga menunjukkan bahwa pemanfaatan *cross-lingual learning, knowledge transfer*, maupun *Large Language Model* menjadi pendekatan yang menjanjikan untuk mengatasi keterbatasan data berlabel, meskipun masih menghadapi tantangan dalam menjaga kualitas dan konsistensi anotasi (Tarmizi & Saad, 2025).

Berdasarkan perkembangan tersebut dapat dipahami bahwa fokus penelitian NLP modern tidak lagi hanya diarahkan pada pengembangan arsitektur model yang semakin kompleks, tetapi juga pada penyediaan sumber daya bahasa yang berkualitas sebagai fondasi proses pembelajaran model (Cambria & White, 2014). Bagi tugas Named Entity Recognition, keberadaan dataset yang representatif, konsisten, dan sesuai dengan karakteristik domain menjadi prasyarat penting dalam menghasilkan sistem yang memiliki kemampuan generalisasi yang baik (Gusmita et al., 2023). Oleh karena itu, penelitian ini memosisikan konstruksi dan perluasan dataset sebagai objek utama penelitian, sehingga pembahasan selanjutnya akan

difokuskan pada teori Named Entity Recognition beserta aspek-aspek yang berkaitan dengan pembangunan dataset pada domain teks terjemahan.

C. Named Entity Recognition (NER)

1. Definisi

Named Entity Recognition (NER) merupakan salah satu tugas utama dalam *Natural Language Processing* (NLP) yang bertujuan untuk mengidentifikasi serta mengklasifikasikan entitas bernama (*named entities*) dalam suatu teks ke dalam kategori tertentu, seperti nama orang (*person*), lokasi (*location*), organisasi (*organization*), waktu (*time*), maupun kategori lain yang disesuaikan dengan karakteristik domain (Jurafsky & Martin, 2024). Sebagai salah satu bentuk *sequence labeling*, NER tidak hanya menentukan jenis suatu entitas, tetapi juga mengidentifikasi batas (*boundary*) dari setiap entitas yang muncul di dalam teks sehingga informasi tersebut dapat dimanfaatkan pada berbagai tugas NLP lanjutan, seperti *information extraction*, *knowledge graph construction*, *question answering*, dan *information retrieval* (Jurafsky & Martin, 2024).

Perkembangan metode NER mengalami evolusi yang sejalan dengan perkembangan NLP secara umum. Pendekatan awal didominasi oleh metode berbasis aturan (*rule-based*) yang memanfaatkan pola linguistik dan kamus entitas (*gazetteer*) untuk mengenali entitas (Christopher D. Manning and Hinrich Schütze, 1999). Selanjutnya, pendekatan berbasis *machine learning*, seperti *Hidden Markov Model* (HMM), *Conditional Random Field* (CRF), dan *Support Vector Machine* (SVM), mulai digunakan untuk mempelajari pola anotasi berdasarkan data berlabel (Christopher D. Manning and Hinrich Schütze, 1999). Dalam beberapa tahun terakhir, pendekatan berbasis *deep learning*, khususnya *Bidirectional Long Short-Term Memory* (BiLSTM) dan arsitektur *Transformer* seperti BERT, IndoBERT, maupun *Large Language Model* (LLM), menunjukkan

peningkatan performa yang signifikan pada berbagai benchmark NER (Jurafsky & Martin, 2024). Meskipun demikian, berbagai penelitian juga menunjukkan bahwa peningkatan performa model tersebut tetap sangat bergantung pada kualitas dataset anotasi yang digunakan selama proses pelatihan dan evaluasi (Khairunnisa et al., 2024).

Karakteristik NER sangat dipengaruhi oleh domain teks yang digunakan. Pada domain umum, kategori entitas biasanya terbatas pada nama orang, lokasi, organisasi, atau waktu (Jurafsky & Martin, 2024). Sebaliknya, pada domain khusus, seperti biomedis, hukum, maupun teks religius, kategori entitas dapat berkembang sesuai kebutuhan representasi informasi dalam domain tersebut (Tarmizi & Saad, 2025). Pada teks terjemahan, misalnya, entitas yang muncul tidak hanya berupa nama tokoh atau lokasi, tetapi juga mencakup istilah religius, kelompok masyarakat, kitab suci, maupun konsep-konsep lain yang memiliki karakteristik semantik khusus (Gusmita et al., 2023). Oleh karena itu, proses anotasi pada domain religius memerlukan pedoman anotasi *(Annotation Guideline)* yang jelas agar setiap entitas diberi label secara konsisten (Tarmizi & Saad, 2025).

Selain bergantung pada definisi kategori entitas, keberhasilan sistem NER juga dipengaruhi oleh kualitas anotasi yang digunakan sebagai data pelatihan. Dataset yang memiliki inkonsistensi label, kesalahan batas entitas, atau cakupan korpus yang terbatas akan berdampak langsung terhadap kemampuan model dalam melakukan generalisasi terhadap data baru. Oleh karena itu, dalam penelitian NER modern, perhatian tidak hanya diarahkan pada pengembangan model yang semakin kompleks, tetapi juga pada penyediaan dataset yang berkualitas sebagai fondasi utama bagi proses pelatihan dan evaluasi model (Khairunnisa et al., 2024).

Berdasarkan uraian tersebut, dapat dipahami bahwa NER merupakan proses yang tidak terlepas dari kualitas sumber daya bahasa yang digunakan.

Dalam konteks penelitian ini, fokus utama tidak diarahkan pada pengembangan model NER baru, melainkan pada proses konstruksi dan perluasan dataset anotasi yang diharapkan mampu menyediakan sumber daya yang lebih representatif bagi pengembangan model NER pada domain teks terjemahan (Gusmita et al., 2023).

2. Skema Anotasi BIO (BIO tagging scheme)

Dalam tugas *sequence labeling*, setiap token pada teks perlu diberikan label yang menunjukkan apakah token tersebut merupakan bagian dari suatu entitas atau bukan. Salah satu skema anotasi yang paling banyak digunakan adalah BIO *tagging scheme* **(*Begin–Inside–Outside*)**, karena mampu merepresentasikan batas suatu entitas secara sederhana namun efektif (Tjong et al., 2003).

Pada BIO *tagging scheme*, label **B** ***(Begin)*** diberikan kepada token pertama dari suatu entitas, label **I** ***(Inside)*** diberikan kepada token berikutnya yang masih berada dalam entitas yang sama, sedangkan label **O** ***(Outside)*** digunakan untuk token yang tidak termasuk ke dalam entitas apa pun. Dengan mekanisme tersebut, model tidak hanya mempelajari jenis entitas, tetapi juga posisi awal dan akhir setiap entitas dalam sebuah kalimat (Tjong et al., 2003).

Sebagai ilustrasi, pada kalimat:

Nabi Musa diutus kepada Fir'aun.

Proses anotasi menggunakan BIO *tagging scheme* dapat direpresentasikan sebagai berikut.

Token	Label
Nabi	B-PER
Musa	I-PER

diutus	O
kepada	O
Fir’aun	B-PER

Contoh tersebut menunjukkan bahwa entitas **"Nabi Musa"** terdiri atas dua token sehingga diberi label **B-PER** dan **I-PER**, sedangkan **Fir'aun** merupakan entitas tunggal yang diberi label **B-PER**. Token lain yang tidak termasuk dalam entitas diberi label **O**.

BIO *tagging scheme* dipilih karena memiliki beberapa keunggulan, antara lain mudah diimplementasikan, kompatibel dengan berbagai algoritma *sequence labeling*, serta mampu membedakan dua entitas yang muncul secara berurutan tanpa menimbulkan ambiguitas (Jurafsky & Martin, 2024). Oleh karena itu, skema ini telah digunakan secara luas pada berbagai benchmark NER, termasuk **IndQNER**, sehingga penelitian ini juga menggunakan BIO *tagging scheme* sebagai dasar anotasi dalam proses perluasan dataset (Gusmita et al., 2023; Tjong et al., 2003).

3. Evaluasi Named Entity Recognition

Kinerja sistem NER umumnya dievaluasi dengan membandingkan hasil prediksi model terhadap anotasi acuan (*gold standard*). Proses evaluasi ini bertujuan untuk mengukur kemampuan model dalam mengenali batas entitas sekaligus mengklasifikasikan jenis entitas secara tepat (Jurafsky & Martin, 2024). Tiga metrik yang paling umum digunakan adalah ***Precision***, ***Recall***, dan ***F1-Score*** (Tjong et al., 2003).

Precision mengukur proporsi entitas yang diprediksi sebagai benar dibandingkan dengan seluruh entitas yang diprediksi oleh model.

$$Precision = \frac{TP}{TP + FP}$$

dengan:

TP (*True Positive*): jumlah entitas yang diprediksi benar,

FP (*False Positive*): jumlah entitas yang diprediksi sebagai entitas tetapi sebenarnya tidak sesuai.

Recall mengukur kemampuan model dalam menemukan seluruh entitas yang benar pada dataset.

$$Recall = \frac{TP}{TP + FN}$$

dengan:

FN (*False Negative*): jumlah entitas yang seharusnya dikenali tetapi tidak berhasil diprediksi oleh model.

Selanjutnya, *F1-Score* merupakan rata-rata harmonis antara *Precision* dan *Recall*.

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Nilai *F1-Score* banyak digunakan sebagai indikator utama dalam penelitian NER karena memberikan keseimbangan antara ketepatan prediksi dan kemampuan menemukan seluruh entitas (Jurafsky & Martin, 2024). Oleh karena itu, metrik ini digunakan secara luas pada berbagai benchmark, termasuk CoNLL dan IndQNER (Gusmita et al., 2023; Tjong et al., 2003).

Meskipun demikian, dalam konteks penelitian ini, metrik evaluasi tersebut tidak digunakan untuk membandingkan performa berbagai model NER. Sebaliknya, metrik tersebut dimanfaatkan sebagai **indikator tidak langsung** untuk mengevaluasi kualitas dataset hasil perluasan (Khairunnisa et al., 2024). Dataset yang memiliki kualitas anotasi lebih baik diharapkan mampu menghasilkan performa model yang lebih baik ketika digunakan

sebagai data pelatihan maupun evaluasi. Dengan demikian, evaluasi model NER pada penelitian ini berfungsi sebagai sarana untuk menilai efektivitas *Pipeline* konstruksi dataset yang diusulkan, bukan sebagai tujuan utama penelitian.

D. Konstruksi Dataset NER

1. Dataset sebagai Sumber Daya NLP

Dataset merupakan salah satu komponen fundamental dalam pengembangan sistem *Natural Language Processing* (NLP) (Jurafsky & Martin, 2024). Pada pendekatan berbasis *machine learning* maupun *deep learning*, model tidak lagi memperoleh pengetahuan melalui aturan yang dirancang secara eksplisit, tetapi mempelajari representasi bahasa berdasarkan pola yang terdapat pada kumpulan data berlabel (*annotated corpus*) (Holderness et al., 2025; Jurafsky & Martin, 2024). Oleh karena itu, dataset berperan sebagai sumber pengetahuan (*language resource*) yang menentukan kemampuan model dalam memahami karakteristik bahasa, mengenali hubungan antarkata, serta melakukan generalisasi terhadap data yang belum pernah diproses sebelumnya (Holderness et al., 2025).

Seiring berkembangnya model berbasis *Transformer* dan *Large Language Model* (LLM), kebutuhan terhadap dataset berkualitas semakin meningkat. Meskipun model modern telah dilatih menggunakan korpus berskala besar pada tahap *pre-training*, proses *fine-tuning* maupun evaluasi tetap memerlukan dataset yang relevan dengan karakteristik tugas dan domain yang diteliti (Jurafsky & Martin, 2024). Dengan demikian, keberhasilan suatu sistem NLP tidak hanya ditentukan oleh kompleksitas arsitektur model, tetapi juga sangat dipengaruhi oleh kualitas sumber daya bahasa yang digunakan selama proses pengembangan (Wilie et al., 2020).

Pada tugas *Named Entity Recognition* (NER), dataset menjadi media utama bagi model untuk mempelajari hubungan antara token dan kategori entitas yang menyertainya (Jurafsky & Martin, 2024). Setiap anotasi yang terdapat pada dataset merepresentasikan pengetahuan mengenai batas (*entity boundary*) dan jenis (*entity type*) suatu entitas (Holderness et al., 2025). Oleh karena itu, kesalahan anotasi, inkonsistensi pelabelan, maupun keterbatasan cakupan korpus dapat menyebabkan model mempelajari pola yang kurang tepat sehingga menurunkan kemampuan generalisasi ketika diterapkan pada data baru (Holderness et al., 2025).

2. Gold Standard Annotation

Untuk memastikan kualitas dataset, proses anotasi umumnya mengacu pada konsep *gold standard annotation* (Mayhew et al., 2024). *Gold standard* merupakan sekumpulan data yang telah melalui proses anotasi secara sistematis berdasarkan pedoman anotasi (*Annotation Guideline*) yang telah ditetapkan, sehingga dapat dianggap sebagai representasi *Ground Truth* pada suatu tugas NLP (Abdelmageed et al., 2022; Mayhew et al., 2024). Dataset ini berfungsi sebagai acuan utama dalam proses pelatihan, evaluasi, maupun validasi berbagai model yang dikembangkan (Ivanova et al., 2022).

Penyusunan *gold standard* umumnya dilakukan oleh satu atau lebih anotator yang memiliki pemahaman terhadap karakteristik domain penelitian (Abdelmageed et al., 2022). Agar hasil anotasi tetap konsisten, setiap anotator mengikuti pedoman anotasi yang mendefinisikan kategori entitas, aturan pelabelan, serta penanganan terhadap kasus-kasus ambigu. Pada beberapa penelitian, kualitas anotasi juga dievaluasi menggunakan *Inter-Annotator Agreement* (IAA) untuk mengukur tingkat kesepakatan antar anotator (Mayhew et al., 2024).

Meskipun menghasilkan kualitas anotasi yang tinggi, pendekatan anotasi manual memiliki keterbatasan dari sisi waktu, biaya, dan skalabilitas (Abdelmageed et al., 2022). Semakin besar korpus yang dianotasi, semakin besar pula sumber daya yang dibutuhkan (Ivanova et al., 2022). Kondisi tersebut mendorong berkembangnya berbagai pendekatan yang bertujuan membantu proses konstruksi dataset secara lebih efisien tanpa mengurangi kualitas anotasi yang dihasilkan (Mayhew et al., 2024).

3. Benchmark Dataset

Seiring berkembangnya penelitian, *gold standard* yang telah tervalidasi sering kali dikembangkan menjadi *Benchmark Dataset* (Tjong et al., 2003). Berbeda dengan sekadar kumpulan data berlabel, *Benchmark Dataset* menyediakan standar yang mencakup skema anotasi, kategori entitas, pedoman pelabelan, format penyimpanan data, serta protokol evaluasi yang digunakan secara konsisten oleh komunitas penelitian (Mayhew et al., 2024). Dengan demikian, *Benchmark Dataset* memungkinkan hasil penelitian dari berbagai pendekatan dapat dibandingkan secara objektif dan direproduksi oleh peneliti lain (Tjong et al., 2003).

Suatu benchmark yang baik umumnya memiliki beberapa karakteristik, antara lain kualitas anotasi yang tervalidasi, dokumentasi pedoman anotasi yang jelas, cakupan data yang representatif, serta kemudahan akses bagi komunitas penelitian (Mayhew et al., 2024). Keberadaan *Benchmark Dataset* tidak hanya mempercepat pengembangan metode baru, tetapi juga meningkatkan reliabilitas hasil penelitian karena seluruh eksperimen dilakukan pada standar yang sama (Tjong et al., 2003).

Dalam penelitian ini, IndQNER digunakan sebagai *Benchmark Dataset* utama karena menyediakan teks terjemahan yang telah dianotasi menggunakan BIO *tagging scheme* beserta kategori entitas dan pedoman anotasinya (Gusmita et al., 2023). Penelitian ini tidak bertujuan

menggantikan benchmark tersebut, melainkan memperluas cakupan korpus dengan tetap mengacu pada pedoman anotasi IndQNER sebagai standar utama. Apabila selama proses perluasan ditemukan kasus anotasi yang memerlukan penyempurnaan, penyesuaian dilakukan berdasarkan analisis linguistik dan justifikasi yang terdokumentasi sehingga tetap menjaga kompatibilitas terhadap benchmark (Gusmita et al., 2023).

4. Tantangan Perluasan Dataset

Keterbatasan jumlah data berlabel menjadi salah satu tantangan utama dalam pengembangan *Benchmark Dataset*. Untuk mengatasi permasalahan tersebut, berbagai penelitian mengembangkan pendekatan *Dataset Expansion*, yaitu proses memperluas cakupan dataset melalui penambahan data baru dengan tetap mempertahankan karakteristik dan pedoman anotasi yang telah ditetapkan. Pada tugas NER, perluasan dataset bertujuan meningkatkan representativitas korpus sehingga model mampu mempelajari variasi entitas, konteks linguistik, serta distribusi bahasa yang lebih beragam (Tarmizi & Saad, 2025).

Berbagai pendekatan telah digunakan untuk mendukung proses perluasan dataset, mulai dari anotasi manual, *Data Augmentation* (Khairunnisa et al., 2024), *Weak Supervision*, *Cross-lingual Annotation Projection* (Mayhew et al., 2024), hingga pemanfaatan Large Language Model (LLM). Setiap pendekatan memiliki kelebihan dan keterbatasan. Anotasi manual menghasilkan kualitas anotasi yang tinggi, tetapi kurang efisien pada korpus berskala besar. Sebaliknya, pendekatan otomatis menawarkan skalabilitas yang lebih baik, namun berpotensi menghasilkan kesalahan anotasi apabila tidak disertai mekanisme validasi yang memadai (Tarmizi & Saad, 2025).

Perkembangan penelitian terkini menunjukkan kecenderungan untuk mengombinasikan beberapa pendekatan dalam satu *Pipeline* konstruksi

dataset (Mayhew et al., 2024; Tarmizi & Saad, 2025). Pendekatan tersebut memungkinkan proses anotasi dilakukan secara lebih efisien tanpa mengabaikan kualitas dataset yang dihasilkan. Oleh karena itu, konstruksi dataset modern tidak lagi dipandang sebagai proses anotasi tunggal, melainkan sebagai serangkaian tahapan yang saling melengkapi untuk menghasilkan dataset yang representatif dan berkualitas.

5. Prinsip Kualitas Dataset

Keberhasilan proses konstruksi dataset tidak hanya diukur dari jumlah data yang berhasil dikumpulkan, tetapi juga dari kualitas dataset yang dihasilkan (Mayhew et al., 2024). Dataset yang memiliki jumlah data besar belum tentu mampu mendukung pengembangan model apabila anotasi yang diberikan tidak konsisten atau tidak sesuai dengan karakteristik domain (Scientific Data, 2025). Oleh karena itu, kualitas dataset menjadi aspek yang harus dipertahankan selama seluruh proses konstruksi maupun perluasan dataset (Mayhew et al., 2024; Olewniczak & Szymański, 2025).

Secara umum, kualitas dataset dapat ditinjau melalui beberapa aspek utama, yaitu correctness, consistency, completeness, traceability, dan reproducibility (Olewniczak & Szymański, 2025). Correctness menunjukkan ketepatan anotasi terhadap entitas yang sebenarnya, sedangkan consistency berkaitan dengan konsistensi penerapan pedoman anotasi pada seluruh korpus (Mayhew et al., 2024). Completeness mengacu pada kecukupan representasi entitas maupun konteks linguistik yang terdapat dalam dataset. Selanjutnya, traceability menunjukkan bahwa setiap perubahan anotasi dapat ditelusuri beserta alasan yang mendasarinya, sedangkan reproducibility memastikan bahwa proses konstruksi dataset dapat direplikasi oleh peneliti lain menggunakan prosedur yang sama (Olewniczak & Szymański, 2025).

Kelima aspek tersebut menjadi prinsip penting dalam pengembangan dataset NER karena menentukan tingkat kepercayaan terhadap dataset yang dihasilkan (Mayhew et al., 2024). Oleh karena itu, penelitian ini menjadikan kualitas dataset sebagai salah satu pertimbangan utama dalam perancangan *Pipeline* konstruksi dataset (Mayhew et al., 2024; Olewniczak & Szymański, 2025).

6. Tantangan Konstruksi Dataset pada Domain Low-Resource

Meskipun berbagai pendekatan telah dikembangkan untuk mendukung konstruksi dataset, proses tersebut masih menghadapi tantangan yang signifikan pada bahasa maupun domain yang tergolong *low-resource* (Mayhew et al., 2024). Domain religius, termasuk teks terjemahan, merupakan salah satu contoh domain yang memiliki keterbatasan sumber daya bahasa (Cahyawijaya et al., 2021), baik dari sisi jumlah dataset beranotasi (Wilie et al., 2020) maupun keberagaman konteks linguistik yang tersedia.

Selain keterbatasan jumlah data, proses anotasi pada domain religius juga dipengaruhi oleh karakteristik linguistik dan semantik yang lebih kompleks dibandingkan korpus umum. Variasi transliterasi nama, perbedaan struktur antara teks Arab dan teks terjemahan, serta keberadaan istilah-istilah keagamaan menyebabkan proses anotasi memerlukan pemahaman terhadap konteks bahasa maupun domain. Kondisi tersebut menjadikan anotasi manual membutuhkan waktu yang panjang, sedangkan pendekatan otomatis berpotensi menghasilkan inkonsistensi apabila tidak didukung oleh sumber pengetahuan yang memadai.

Berdasarkan kondisi tersebut, diperlukan suatu pendekatan konstruksi dataset yang mampu mengintegrasikan berbagai sumber informasi untuk meningkatkan efisiensi proses anotasi tanpa mengurangi kualitas dataset yang dihasilkan. Oleh karena itu, penelitian ini mengusulkan *Pipeline*

konstruksi dataset yang memanfaatkan sumber pengetahuan terstruktur, mekanisme berbasis aturan, serta validasi semantik sebagai upaya memperluas dataset NER pada teks terjemahan dengan tetap mengacu pada benchmark yang telah tersedia.

E. Named Entity Recognition pada Domain Al-Qur'an

Named Entity Recognition (NER) telah diterapkan pada berbagai domain, seperti berita, media sosial, kesehatan, hukum, dan pendidikan (Jurafsky & Martin, 2024). Meskipun tujuan utamanya tetap sama, yaitu mengidentifikasi dan mengklasifikasikan entitas bernama dalam suatu teks, karakteristik setiap domain menyebabkan tantangan yang dihadapi menjadi berbeda (Khairunnisa et al., 2024). Model yang menunjukkan performa tinggi pada korpus umum belum tentu mampu menghasilkan kinerja yang sama ketika diterapkan pada domain yang memiliki karakteristik linguistik dan semantik yang lebih spesifik (Jurafsky & Martin, 2024). Oleh karena itu, pengembangan sistem NER umumnya memerlukan dataset dan strategi anotasi yang disesuaikan dengan karakteristik domain yang menjadi objek penelitian.

Salah satu domain yang memiliki karakteristik khusus adalah teks religius, terutama Al-Qur'an (Tarmizi & Saad, 2025). Berbeda dengan korpus umum yang umumnya memuat nama orang, organisasi, lokasi, maupun ekspresi waktu dalam konteks kehidupan sehari-hari, Al-Qur'an mengandung berbagai entitas yang berkaitan dengan tokoh kenabian, malaikat, kitab suci, kaum, tempat bersejarah, serta istilah-istilah religius yang memiliki makna teologis dan kontekstual (Gusmita et al., 2023; Tarmizi & Saad, 2025). Selain itu, suatu entitas dalam Al-Qur'an sering kali muncul dalam berbagai bentuk penyebutan, baik secara eksplisit maupun implisit, sehingga proses identifikasi entitas tidak hanya bergantung pada bentuk permukaan *(surface form),* tetapi juga memerlukan pemahaman terhadap konteks ayat (Gusmita et al., 2023).

Karakteristik tersebut menjadi semakin kompleks ketika penelitian dilakukan pada teks terjemahan. Sebagai teks hasil penerjemahan, struktur kalimat dalam bahasa Indonesia tidak selalu identik dengan struktur bahasa Arab sebagai teks sumber. Perbedaan urutan kata, perubahan bentuk frasa, penggunaan sinonim, serta variasi transliterasi nama menyebabkan batas (entity boundary) dan representasi suatu entitas dapat berbeda antara teks sumber dan teks terjemahan (Politov et al., 2025). Akibatnya, proses anotasi pada teks terjemahan memerlukan perhatian khusus agar informasi semantik yang terkandung pada teks sumber tetap dapat dipertahankan secara konsisten (Gusmita et al., 2023).

Selain aspek linguistik, domain Al-Qur'an juga memiliki karakteristik semantik yang unik (Tarmizi & Saad, 2025). Sebuah istilah dapat memiliki makna yang berbeda bergantung pada konteks ayat, sedangkan beberapa entitas dapat merujuk pada konsep yang sama melalui bentuk penyebutan yang berbeda. Kondisi tersebut meningkatkan potensi terjadinya inkonsistensi anotasi apabila proses pelabelan hanya dilakukan berdasarkan kemunculan kata tanpa mempertimbangkan konteks maupun sumber pengetahuan yang mendukung (Khairunnisa et al., 2024). Oleh karena itu, penyusunan pedoman anotasi (*Annotation Guideline*) yang jelas serta pemanfaatan sumber pengetahuan eksternal *(External Knowledge Source)* menjadi faktor penting dalam menjaga kualitas dataset NER pada domain Al-Qur'an (Li et al., 2024).

Perkembangan penelitian menunjukkan bahwa penerapan NER pada domain religius masih tergolong sebagai bidang yang berkembang (emerging research area) (Tarmizi & Saad, 2025). Berbagai penelitian telah mengembangkan model NER untuk teks Arab, hadis, maupun teks terjemahan dengan memanfaatkan pendekatan berbasis aturan *(rule-based)*, *machine learning, deep learning,* hingga arsitektur *Transformer* (Tarmizi & Saad, 2025). Seiring berkembangnya *Large Language Model* (LLM), penelitian juga mulai memanfaatkan model generatif sebagai pendukung proses anotasi maupun validasi semantik (Chen et al., 2024). Meskipun demikian, sebagian besar penelitian masih berfokus pada peningkatan

performa model, sedangkan penelitian yang secara khusus membahas konstruksi dan perluasan dataset masih relatif terbatas (Tarmizi & Saad, 2025).

Pada konteks bahasa Indonesia, salah satu kontribusi penting adalah diperkenalkannya IndQNER, yaitu *Benchmark Dataset* NER yang dibangun dari teks terjemahan (Gusmita et al., 2023). Dataset tersebut menyediakan BIO *tagging scheme*, kategori entitas, serta pedoman anotasi yang menjadi acuan dalam pengembangan dan evaluasi model NER pada domain Al-Qur'an (Gusmita et al., 2023). Keberadaan IndQNER merupakan langkah awal yang signifikan dalam menyediakan sumber daya bahasa untuk penelitian NLP religius di Indonesia. Namun demikian, sebagaimana lazimnya benchmark generasi awal, cakupan korpus dan variasi konteks yang tersedia masih terbatas sehingga peluang untuk memperluas representasi entitas masih terbuka (Khairunnisa et al., 2024).

Selain keterbatasan jumlah data, penelitian-penelitian terdahulu juga menunjukkan bahwa proses anotasi pada domain Al-Qur'an masih menghadapi beberapa tantangan, antara lain keterbatasan sumber daya bahasa, inkonsistensi transliterasi nama, variasi struktur antara teks Arab dan teks terjemahan, serta belum optimalnya pemanfaatan sumber pengetahuan yang dapat membantu menjaga konsistensi anotasi (Khairunnisa et al., 2024; Tarmizi & Saad, 2025). Kondisi tersebut menyebabkan proses anotasi manual membutuhkan waktu yang cukup panjang, sedangkan pendekatan otomatis masih berpotensi menghasilkan kesalahan apabila tidak didukung oleh mekanisme validasi yang memadai.

Berdasarkan karakteristik tersebut, pengembangan dataset NER pada domain Al-Qur'an memerlukan pendekatan yang tidak hanya berorientasi pada penambahan jumlah data, tetapi juga mampu mempertahankan kualitas dan konsistensi anotasi. Salah satu pendekatan yang banyak dikembangkan adalah pemanfaatan sumber pengetahuan terstruktur *(Structured Knowledge Source)* yang dapat membantu proses identifikasi entitas, penyelarasan lintas bahasa (*Cross-lingual Alignment*), serta validasi hasil anotasi (Chen et al., 2024; Politov et al., 2025). Pendekatan ini memungkinkan proses konstruksi dataset dilakukan secara

lebih sistematis dengan tetap mengacu pada pedoman anotasi yang telah ditetapkan (Mayhew et al., 2024).

Dengan demikian, penelitian ini memandang bahwa pengembangan dataset NER pada domain Al-Qur'an tidak cukup dilakukan melalui anotasi manual maupun pendekatan otomatis secara terpisah. Diperlukan suatu *Pipeline* konstruksi dataset yang mampu mengintegrasikan benchmark yang telah tersedia dengan sumber pengetahuan eksternal untuk meningkatkan efisiensi sekaligus menjaga kualitas anotasi (Tarmizi & Saad, 2025). Berdasarkan pertimbangan tersebut, penelitian ini memanfaatkan Quranic Arabic Corpus (QAC) sebagai sumber pengetahuan utama dalam proses konstruksi dataset, yang pembahasannya disajikan pada subbab berikutnya (Gusmita et al., 2023).

Tabel 3 Posisi Sumber Data dan Perannya dalam Penelitian

Sumber	**Posisi**	**Fungsi dalam penelitian**
IndQNER	Benchmark acuan	Menjadi acuan skema anotasi, kategori entitas, pedoman, dan format dataset
Quranic Arabic Corpus (QAC)	Structured knowledge source	Menyediakan informasi linguistik dan semantik untuk mendukung identifikasi kandidat entitas

teks terjemahan	Target corpus	Menjadi korpus bahasa Indonesia yang akan diperluas anotasinya
Gold Evaluation Subset	Data evaluasi	Menjadi acuan manusia/ahli untuk mengevaluasi kualitas anotasi hasil pipeline

F. Quranic Arabic Corpus (QAC)

1. Definisi Quranic Arabic Corpus

Quranic Arabic Corpus (QAC) merupakan korpus linguistik beranotasi yang dikembangkan oleh University of Leeds untuk menyediakan representasi linguistik Al-Qur'an secara komprehensif (Dukes, 2013). Berbeda dengan korpus teks biasa, QAC tidak hanya menyajikan teks Al-Qur'an dalam bahasa Arab, tetapi juga menyediakan berbagai informasi linguistik yang telah dianotasi secara sistematis, seperti segmentasi kata, analisis morfologi, kelas kata *(part-of-speech tagging),* akar kata *(root),* lema *(lemma),* struktur sintaksis, serta hubungan antarkata dalam setiap ayat (Dukes et al., 2013).

QAC dikembangkan dengan tujuan menyediakan sumber daya bahasa (language resource) yang dapat digunakan dalam berbagai penelitian *Natural Language Processing* (NLP), linguistik Arab, maupun studi Al-Qur'an berbasis komputasi (Dukes et al., 2013). Seluruh anotasi pada QAC disusun berdasarkan pendekatan linguistik tradisional bahasa Arab yang dikombinasikan dengan analisis linguistik modern sehingga menghasilkan representasi data yang terstruktur dan mudah dimanfaatkan dalam berbagai aplikasi komputasional (Dukes & Habash, 2010).

2. Struktur Informasi pada Quranic Arabic Corpus

Salah satu keunggulan utama QAC adalah kelengkapan informasi linguistik yang tersedia pada setiap token Al-Qur'an. Setiap kata tidak hanya direpresentasikan sebagai teks, tetapi juga dilengkapi dengan berbagai atribut linguistik yang saling berkaitan (Dukes et al., 2013).

Beberapa informasi utama yang tersedia dalam QAC meliputi:

a. identitas surah dan ayat,
b. posisi token,
c. bentuk kata *(surface form),*
d. lema *(lemma),*
e. akar kata *(root),*
f. kelas kata *(part-of-speech),*
g. fitur morfologi,
h. struktur sintaksis,
i. serta relasi antarkata dalam suatu ayat (Dukes et al., 2013).

Kelengkapan informasi tersebut memungkinkan peneliti melakukan analisis linguistik secara lebih mendalam dibandingkan menggunakan korpus teks biasa (Dukes & Habash, 2010). Selain mendukung analisis morfologi bahasa Arab, struktur data pada QAC juga mempermudah proses penyelarasan (alignment) antara teks Arab dengan berbagai versi terjemahannya (Politov et al., 2025).

3. Informasi Entitas pada Quranic Arabic Corpus

Selain anotasi linguistik, QAC juga menyediakan informasi mengenai berbagai entitas yang muncul di dalam Al-Qur'an melalui integrasi dengan basis pengetahuan semantik yang dikembangkan pada proyek Quranic Studies (Dukes & Habash, 2010)Click or tap here to enter text.. Informasi

tersebut mencakup nama nabi, malaikat, lokasi, kelompok masyarakat, maupun konsep-konsep tertentu yang memiliki hubungan semantik dengan ayat terkait (Dukes et al., 2013).

Keberadaan informasi entitas tersebut menjadikan QAC tidak hanya berfungsi sebagai korpus linguistik, tetapi juga sebagai sumber pengetahuan *(Knowledge Source)* yang dapat dimanfaatkan untuk membantu proses identifikasi dan validasi entitas pada penelitian NER (Tarmizi & Saad, 2025). Dibandingkan melakukan anotasi berdasarkan teks terjemahan semata, penggunaan informasi yang berasal dari teks Arab memungkinkan proses anotasi dilakukan secara lebih konsisten karena mengacu pada representasi linguistik yang lebih mendasar (Gusmita et al., 2023).

4. Pemanfaatan Quranic Arabic Corpus pada Penelitian NLP

Sejak diperkenalkan, QAC telah dimanfaatkan dalam berbagai penelitian NLP yang berkaitan dengan Al-Qur'an (Tarmizi & Saad, 2025). Beberapa penelitian menggunakan QAC digunakan sebagai sumber pengetahuan terstruktur yang menjadi referensi dalam identifikasi kandidat entitas pada teks sumber, *part-of-speech tagging,* parsing sintaksis, pencarian semantik *(semantic search),* klasifikasi ayat, hingga pengembangan sistem tanya jawab *(question answering)* (Dukes & Habash, 2010; Tarmizi & Saad, 2025).

Dalam beberapa tahun terakhir, QAC juga mulai dimanfaatkan sebagai sumber pengetahuan pendukung (knowledge resource) pada penelitian berbasis *machine learning* maupun *deep learning* (Tarmizi & Saad, 2025). Informasi morfologi, lema, akar kata, serta struktur linguistik yang tersedia pada QAC dapat digunakan untuk meningkatkan kualitas representasi data maupun membantu proses anotasi secara semiotomatis (Gusmita et al., 2023). Hal ini menunjukkan bahwa fungsi QAC telah berkembang dari sekadar korpus linguistik menjadi salah satu sumber daya penting dalam

pengembangan aplikasi NLP pada domain Al-Qur'an (Tarmizi & Saad, 2025).

5. Relevansi Quranic Arabic Corpus terhadap Penelitian

Pada penelitian ini, Quranic Arabic Corpus tidak diposisikan sebagai dataset utama yang akan diperluas, melainkan sebagai sumber pengetahuan terstruktur *(Structured Knowledge Source)* yang mendukung proses konstruksi dataset NER pada teks terjemahan (Gusmita et al., 2023).

Informasi linguistik dan semantik yang tersedia pada QAC dimanfaatkan untuk membantu proses penyelarasan antara teks Arab dan teks terjemahan, mengidentifikasi kandidat entitas, serta mendukung proses validasi anotasi agar tetap konsisten terhadap karakteristik teks sumber (Politov et al., 2025). Dengan demikian, QAC berperan sebagai referensi utama dalam menjaga kualitas anotasi selama proses perluasan dataset (Gusmita et al., 2023).

Pendekatan tersebut berbeda dengan sebagian besar penelitian sebelumnya yang memanfaatkan QAC hanya sebagai korpus linguistik atau sumber analisis bahasa Arab (Tarmizi & Saad, 2025). Dalam penelitian ini, QAC dipandang sebagai fondasi pengetahuan yang mendukung *Pipeline* konstruksi dataset sehingga proses anotasi tidak hanya bergantung pada teks terjemahan, tetapi juga mempertimbangkan informasi linguistik dan semantik yang berasal dari teks sumber Al-Qur'an (Gusmita et al., 2023; Politov et al., 2025).

G. Cross-Lingual Annotation Projection

1. Konsep Cross-Lingual Annotation Projection

Cross-Lingual Annotation Projection merupakan salah satu pendekatan dalam *Natural Language Processing* (NLP) yang bertujuan mentransfer informasi anotasi dari bahasa sumber *(source language)* ke bahasa sasaran *(target language)* melalui korpus paralel *(Parallel Corpus)*. Pendekatan ini

dikembangkan untuk mengatasi keterbatasan dataset beranotasi pada bahasa atau domain yang tergolong *low-resource.* Dengan memanfaatkan anotasi yang telah tersedia pada bahasa sumber, proses pelabelan pada bahasa sasaran dapat dilakukan secara lebih efisien tanpa harus memulai anotasi secara manual dari awal (Hwa et al., 2005).

Pada tugas *Named Entity Recognition* (NER), informasi yang diproyeksikan umumnya berupa kategori entitas beserta batas (entity boundary) yang telah diidentifikasi pada teks sumber (Mayhew et al., 2024). Setelah hubungan antarteks berhasil diselaraskan (alignment), informasi tersebut dapat ditransfer ke teks sasaran sehingga menghasilkan kandidat anotasi yang selanjutnya dapat divalidasi atau disempurnakan (Agić et al., 2016; Politov et al., 2025). Oleh karena itu, pendekatan annotation projection banyak digunakan sebagai salah satu strategi dalam konstruksi dan perluasan dataset NER pada berbagai bahasa yang memiliki keterbatasan sumber daya (Mayhew et al., 2024; Rahimi et al., 2020).

2. Word Alignment pada Korpus Paralel

Keberhasilan *Cross-Lingual Annotation Projection* sangat bergantung pada proses word alignment, yaitu penyelarasan hubungan antara token pada bahasa sumber dan token pada bahasa sasaran (Yarowsky et al., 2001). Word alignment bertujuan mengidentifikasi pasangan kata atau frasa yang merepresentasikan makna yang sama pada dua bahasa berbeda sehingga informasi anotasi dapat dipindahkan secara tepat (Agić et al., 2016; Hwa et al., 2005).

Dalam penelitian ini, pasangan korpus yang digunakan berasal dari teks Arab Al-Qur'an sebagai bahasa sumber dan teks terjemahan sebagai bahasa sasaran (Dukes et al., 2013; Gusmita et al., 2023). Kedua korpus memiliki hubungan paralel pada tingkat surah dan ayat, sehingga setiap ayat dalam bahasa Arab memiliki pasangan langsung pada teks terjemahan (Dukes et

al., 2013). Hubungan paralel tersebut menjadi dasar dalam proses penyelarasan informasi entitas antara kedua bahasa (Politov et al., 2025).

Meskipun demikian, hubungan antartoken tidak selalu bersifat satu banding satu (one-to-one) (Yarowsky et al., 2001). Dalam proses penerjemahan, satu kata pada bahasa Arab dapat diterjemahkan menjadi beberapa kata dalam bahasa Indonesia, demikian pula sebaliknya (Gusmita et al., 2023). Selain itu, perubahan struktur kalimat dan urutan kata menyebabkan posisi entitas pada bahasa sumber tidak selalu identik dengan posisi entitas pada bahasa sasaran (Hwa et al., 2005; Rahimi et al., 2020). Oleh karena itu, proses word alignment memerlukan mekanisme yang mampu mempertimbangkan hubungan linguistik maupun konteks semantik agar anotasi yang diproyeksikan tetap akurat (Agić et al., 2016; Politov et al., 2025).

3. Tantangan Cross-Lingual Annotation Projection

Meskipun menawarkan efisiensi dalam proses anotasi, *Cross-Lingual Annotation Projection* memiliki sejumlah tantangan yang dapat memengaruhi kualitas hasil proyeksi (Mayhew et al., 2024). Salah satu tantangan utama adalah ketidaksesuaian struktur linguistik *(structural divergence)* antara bahasa sumber dan bahasa sasaran (Hwa et al., 2005). Perbedaan urutan kata, struktur frasa, maupun konstruksi kalimat dapat menyebabkan batas entitas yang terdapat pada bahasa sumber tidak selalu dapat dipindahkan secara langsung ke bahasa sasaran (Politov et al., 2025; Rahimi et al., 2020).

Selain itu, variasi transliterasi nama, penggunaan sinonim, serta perbedaan gaya penerjemahan juga berpotensi menghasilkan inkonsistensi anotasi (Mayhew et al., 2024). Pada domain Al-Qur'an, satu entitas dapat muncul dalam bentuk transliterasi yang berbeda atau diterjemahkan menggunakan istilah yang bervariasi, sehingga proses proyeksi memerlukan

mekanisme validasi tambahan agar hasil anotasi tetap sesuai dengan konteks ayat (Gusmita et al., 2023).

Tantangan lainnya berkaitan dengan propagasi kesalahan (error propagation) (Yarowsky et al., 2001). Kesalahan pada tahap penyelarasan token dapat menyebabkan kesalahan anotasi yang kemudian terbawa ke seluruh proses konstruksi dataset (Agić et al., 2016). Oleh karena itu, berbagai penelitian merekomendasikan penggunaan mekanisme verifikasi berbasis aturan (rule-based validation) maupun pemanfaatan sumber pengetahuan eksternal untuk meningkatkan kualitas hasil proyeksi (Mayhew et al., 2024; Politov et al., 2025).

4. Relevansi terhadap Penelitian Dalam penelitian ini,

Cross-Lingual Annotation Projection digunakan sebagai salah satu tahapan dalam *Pipeline* konstruksi dataset NER (Politov et al., 2025). Berbeda dengan penelitian yang melakukan transfer anotasi antarkorpus umum, penelitian ini memanfaatkan hubungan paralel antara teks Arab pada Quranic Arabic Corpus (QAC) dan teks terjemahan untuk menghasilkan kandidat anotasi entitas pada korpus sasaran (Dukes et al., 2013; Gusmita et al., 2023).

Informasi linguistik dan semantik yang tersedia pada QAC digunakan sebagai dasar dalam proses identifikasi kandidat entitas, sedangkan hasil proyeksi tidak langsung dianggap sebagai anotasi akhir (Dukes et al., 2013). Sebaliknya, anotasi hasil proyeksi akan melalui tahapan penyempurnaan menggunakan mekanisme berbasis aturan (rule-based refinement) serta validasi semantik sebelum dimasukkan ke dalam dataset akhir (Politov et al., 2025). Dengan demikian, *Cross-Lingual Annotation Projection* dalam penelitian ini berfungsi sebagai mekanisme awal untuk mempercepat proses konstruksi dataset, sementara kualitas anotasi tetap dijaga melalui tahapan validasi berikutnya (Mayhew et al., 2024; Politov et al., 2025).

H. Large Language Model sebagai Pelabel (LLM-as-Labeler)

1. Konsep Large Language Model

Large Language Model (LLM) merupakan model bahasa berbasis arsitektur *Transformer* yang dilatih menggunakan korpus teks berskala sangat besar untuk mempelajari representasi linguistik, hubungan semantik, serta pola bahasa alami (Chen et al., 2024). Berbeda dengan model NLP konvensional yang umumnya dikembangkan untuk menyelesaikan satu tugas tertentu, LLM memiliki kemampuan untuk melakukan berbagai tugas bahasa melalui mekanisme *instruction following* maupun *in-context learning* tanpa memerlukan pelatihan ulang secara khusus (Brown et al., 2020).

Kemampuan tersebut diperoleh melalui proses *pre-training* pada korpus multibahasa dan multidomain yang memungkinkan model memahami hubungan antarkata, struktur kalimat, serta makna kontekstual suatu teks (Bommasani et al., 2022). Dengan memanfaatkan pengetahuan yang dipelajari selama proses pelatihan, LLM mampu melakukan berbagai tugas NLP seperti klasifikasi teks, peringkasan, penerjemahan, ekstraksi informasi, hingga *Named Entity Recognition* (Chen et al., 2024).

2. Large Language Model pada Tugas NLP

Dalam beberapa tahun terakhir, LLM telah menjadi salah satu pendekatan utama dalam berbagai tugas NLP (Chen et al., 2024). Selain digunakan sebagai model generatif, LLM juga dimanfaatkan sebagai reasoning engine untuk membantu proses analisis teks yang memerlukan pemahaman semantik dan penalaran kontekstual (Tan et al., 2024). Berbagai penelitian menunjukkan bahwa LLM mampu mendukung tugas ekstraksi informasi, *question answering*, klasifikasi dokumen, maupun anotasi korpus melalui pendekatan berbasis *prompt* (Zheng et al., 2024).

Pada tugas *Named Entity Recognition,* pemanfaatan LLM tidak lagi terbatas sebagai model yang secara langsung menghasilkan label entitas (Mo et al., 2024). Sejumlah penelitian mulai memanfaatkan LLM sebagai komponen pendukung dalam proses anotasi, validasi hasil prediksi, identifikasi kasus ambigu, serta penyempurnaan kualitas dataset (Liu et al., 2023). Pendekatan ini menunjukkan bahwa LLM memiliki potensi tidak hanya sebagai model prediktif, tetapi juga sebagai alat bantu dalam proses konstruksi sumber daya bahasa (language resource construction) (Liu et al., 2023; White et al., 2023).

3. Large Language Model sebagai Semantic Verifier

Salah satu pemanfaatan LLM yang berkembang dalam konstruksi dataset adalah sebagai semantic verifier, yaitu mekanisme yang digunakan untuk mengevaluasi kesesuaian hasil anotasi berdasarkan pemahaman semantik terhadap suatu konteks (White et al., 2023). Berbeda dengan pendekatan berbasis aturan yang mengandalkan pola eksplisit, LLM mampu mempertimbangkan hubungan antarkalimat, makna kontekstual, serta pengetahuan yang telah dipelajari selama proses pre-training (Tan et al., 2024).

Dalam proses anotasi NER, kemampuan tersebut memungkinkan LLM membantu mengidentifikasi apakah suatu token atau frasa benar-benar merepresentasikan entitas sesuai konteks kalimat, mendeteksi anotasi yang berpotensi keliru, maupun memberikan justifikasi terhadap hasil validasi (Liu et al., 2023). Dengan demikian, LLM dapat digunakan sebagai lapisan verifikasi semantik (semantic validation layer) yang melengkapi proses anotasi otomatis maupun penyempurnaan berbasis aturan (White et al., 2023).

Namun demikian, keluaran LLM tidak dapat langsung dianggap sebagai *Ground Truth* (White et al., 2023). Respons yang dihasilkan tetap

dipengaruhi oleh kualitas prompt, pengetahuan yang dimiliki model, serta kemungkinan terjadinya *hallucination* (Chen et al., 2024). Oleh karena itu, penggunaan LLM dalam konstruksi dataset perlu dikombinasikan dengan sumber pengetahuan yang terpercaya dan mekanisme validasi lainnya agar kualitas anotasi tetap terjaga (Liu et al., 2023; White et al., 2023).

4. Prompt Engineering untuk Validasi Anotasi

Efektivitas LLM dalam melakukan verifikasi anotasi sangat dipengaruhi oleh rancangan prompt yang digunakan (Liu et al., 2023). Prompt engineering merupakan proses merancang instruksi yang jelas, spesifik, dan terstruktur agar model menghasilkan keluaran yang sesuai dengan tujuan penelitian (White et al., 2023). Pada konteks validasi anotasi NER, prompt umumnya memuat informasi mengenai kalimat yang akan dianalisis, kandidat entitas beserta kategorinya, serta instruksi untuk mengevaluasi kesesuaian anotasi berdasarkan konteks kalimat (Liu et al., 2023).

Berbagai penelitian menunjukkan bahwa penggunaan prompt yang terstruktur dapat meningkatkan konsistensi respons LLM, terutama pada tugas yang memerlukan penalaran (reasoning) dan evaluasi semantik (White et al., 2023). Selain itu, pemberian konteks tambahan, seperti definisi kategori entitas atau pedoman anotasi, juga dapat membantu model menghasilkan keputusan yang lebih konsisten (Liu et al., 2023). Oleh karena itu, prompt engineering menjadi salah satu komponen penting dalam pemanfaatan LLM sebagai alat bantu validasi anotasi (White et al., 2023).

5. Relevansi terhadap Penelitian

Dalam penelitian ini, *Large Language Model* tidak digunakan sebagai metode utama untuk melakukan anotasi maupun membangun model NER (Wang et al., 2025). Sebaliknya, LLM dimanfaatkan sebagai lapisan verifikasi semantik (semantic verification layer) setelah proses *Cross-*

Lingual Annotation Projection dan *Rule-Based Annotation Refinement* selesai dilakukan (Liu et al., 2023).

LLM berperan mengevaluasi kandidat anotasi yang telah dihasilkan dengan mempertimbangkan konteks kalimat, kategori entitas, serta kesesuaian makna pada teks terjemahan (Tan et al., 2024). Dengan demikian, keputusan anotasi tidak hanya bergantung pada penyelarasan lintas bahasa maupun aturan linguistik, tetapi juga memperoleh validasi berdasarkan pemahaman semantik yang dimiliki model bahasa (Wang et al., 2025).

Pemanfaatan LLM dalam penelitian ini tidak dimaksudkan untuk menggantikan benchmark maupun sumber pengetahuan utama seperti Quranic Arabic Corpus (QAC). Sebaliknya, LLM diposisikan sebagai komponen pendukung yang membantu meningkatkan kualitas anotasi melalui proses verifikasi semantik sebelum hasil akhir dimasukkan ke dalam dataset (Tan et al., 2024; Wang et al., 2025). Pendekatan tersebut menghasilkan *Pipeline* konstruksi dataset yang mengombinasikan *Knowledge Source*, cross-lingual projection, rule-based refinement, dan semantic verification, sehingga setiap tahapan saling melengkapi dalam menjaga kualitas dataset yang dihasilkan (Liu et al., 2023; Zheng et al., 2024).

I. Evaluasi Kualitas Dataset NER

1. Konsep Evaluasi Kualitas Dataset NER

Evaluasi merupakan tahapan penting dalam proses konstruksi dataset *Named Entity Recognition* (NER) untuk memastikan bahwa anotasi yang dihasilkan memiliki kualitas yang memadai sebelum digunakan sebagai data pelatihan maupun evaluasi model (Mayhew et al., 2024). Berbeda dengan evaluasi model pembelajaran mesin yang berfokus pada

kemampuan prediksi, evaluasi pada konstruksi dataset bertujuan menilai kualitas anotasi, konsistensi pelabelan, serta kesesuaian antara anotasi yang dihasilkan dengan *gold standard* atau pedoman anotasi yang digunakan (Mayhew et al., 2024).

Pada penelitian konstruksi dataset, kualitas anotasi dipengaruhi oleh berbagai faktor, seperti kejelasan pedoman anotasi (*Annotation Guideline*), konsistensi penerapan kategori entitas, ketepatan batas entitas (entity boundary), serta mekanisme validasi yang diterapkan selama proses anotasi. Oleh karena itu, evaluasi dataset tidak hanya dilakukan melalui pengukuran kuantitatif, tetapi juga didukung oleh proses validasi yang bertujuan memastikan bahwa anotasi telah merepresentasikan informasi semantik secara akurat (Mayhew et al., 2024).

Dalam penelitian NER modern, evaluasi kualitas dataset umumnya dilakukan menggunakan pendekatan entity-level evaluation. Pendekatan ini menilai kesesuaian hasil anotasi berdasarkan entitas secara utuh, sehingga mempertimbangkan ketepatan kategori sekaligus batas entitas (Tjong et al., 2003). Pendekatan tersebut dinilai lebih representatif dibandingkan evaluasi pada tingkat token karena mampu menggambarkan kualitas anotasi sesuai dengan tujuan utama tugas NER (Wen et al., 2020).

2. Evaluasi Berbasis Entity-Level

Evaluasi berbasis entity-level merupakan pendekatan yang paling umum digunakan dalam penelitian NER (Tjong et al., 2003). Pada pendekatan ini, suatu entitas dinyatakan benar (true positive) apabila kategori entitas dan seluruh batas entitas sesuai dengan anotasi referensi *(gold standard)* (Tjong et al., 2003). Sebaliknya, apabila kategori entitas benar tetapi batas entitas tidak sesuai, atau sebaliknya, maka anotasi dianggap sebagai kesalahan sesuai dengan skema evaluasi yang digunakan.

Pendekatan ini memberikan gambaran yang lebih realistis mengenai kualitas hasil anotasi karena mempertimbangkan integritas suatu entitas

sebagai satu kesatuan makna (Wen et al., 2020). Sebagai contoh, frasa Masjidil Haram harus dikenali sebagai satu entitas lokasi secara utuh. Apabila hanya salah satu token yang berhasil dianotasi, maka hasil tersebut belum dapat dianggap benar pada evaluasi entity-level (Tjong et al., 2003).

Dalam penelitian ini, evaluasi entity-level dipilih karena sesuai dengan tujuan penelitian, yaitu menghasilkan dataset NER yang memiliki anotasi konsisten dan siap digunakan sebagai benchmark maupun data pelatihan model (Mayhew et al., 2024).

3. Precision, Recall, dan F1-Score

Untuk mengukur kualitas hasil anotasi, penelitian NER umumnya menggunakan tiga metrik utama, yaitu Precision, Recall, dan *F1-Score* (Jurafsky & Martin, 2024; Wen et al., 2020).

Precision menunjukkan proporsi entitas yang berhasil dianotasi dengan benar dibandingkan seluruh entitas yang diprediksi. Nilai precision yang tinggi menunjukkan bahwa sebagian besar anotasi yang dihasilkan merupakan anotasi yang benar (Jurafsky & Martin, 2024).

Recall menunjukkan proporsi entitas yang berhasil ditemukan dibandingkan seluruh entitas yang terdapat pada *gold standard*. Nilai recall yang tinggi menunjukkan bahwa sebagian besar entitas berhasil diidentifikasi (Jurafsky & Martin, 2024).

F1-Score merupakan rata-rata harmonik antara precision dan recall yang digunakan untuk memberikan gambaran keseimbangan antara ketepatan dan kelengkapan anotasi (Jurafsky & Martin, 2024). Dalam penelitian NER, *F1-Score* sering digunakan sebagai metrik utama karena mampu merepresentasikan performa sistem secara lebih komprehensif (Wen et al., 2020).

Pada penelitian ini, ketiga metrik tersebut digunakan untuk mengevaluasi kualitas dataset hasil perluasan dengan membandingkan anotasi yang

dihasilkan terhadap anotasi referensi sesuai pedoman IndQNER (Tjong et al., 2003).

Catatan: Saya menyarankan rumus Precision, Recall, dan F1 tidak ditulis di sini jika kampus Anda lebih menyukai penjelasan konseptual. Namun jika pedoman penulisan mengharuskan, rumus dapat ditambahkan pada bagian ini.

4. Validasi Kualitas Anotasi

Selain evaluasi kuantitatif, kualitas dataset juga dipengaruhi oleh konsistensi proses anotasi. Oleh karena itu, berbagai penelitian merekomendasikan penerapan mekanisme validasi selama proses konstruksi dataset untuk meminimalkan kesalahan anotasi dan menjaga konsistensi antarentitas (Mayhew et al., 2024).

Validasi dapat dilakukan melalui pemeriksaan berbasis aturan (rule-based validation), pemanfaatan sumber pengetahuan eksternal *(Knowledge Source)*, maupun peninjauan oleh anotator (Wen et al., 2020). Dalam beberapa tahun terakhir, *Large Language Model* juga mulai dimanfaatkan sebagai alat bantu verifikasi semantik untuk mengevaluasi kesesuaian anotasi berdasarkan konteks kalimat. Meskipun demikian, hasil verifikasi LLM tetap memerlukan konfirmasi terhadap pedoman anotasi dan tidak menggantikan *gold standard* (Mayhew et al., 2024).

Dengan mengombinasikan evaluasi kuantitatif dan validasi anotasi, kualitas dataset dapat dinilai secara lebih komprehensif, baik dari aspek ketepatan pelabelan maupun konsistensi semantik (Mayhew et al., 2024).

5. Relevansi terhadap Penelitian

Dalam penelitian ini, evaluasi kualitas dataset dilakukan untuk menilai hasil perluasan dataset IndQNER yang diperoleh melalui *Cross-Lingual Annotation Projection, Rule-Based Annotation Refinement,* dan *Large Language Model-based Semantic Verification*. Evaluasi dilakukan pada

tingkat entitas (entity-level evaluation) menggunakan metrik *Precision, Recall*, dan *F1-Score* dengan mengacu pada pedoman anotasi IndQNER sebagai *benchmark* (Tjong et al., 2003; Wen et al., 2020).

Selain pengukuran kuantitatif, penelitian ini juga menerapkan mekanisme validasi anotasi untuk memastikan bahwa entitas yang ditambahkan memiliki konsistensi kategori, batas entitas, dan kesesuaian semantik dengan konteks ayat. Pendekatan ini diharapkan menghasilkan dataset yang tidak hanya bertambah dari sisi kuantitas, tetapi juga tetap mempertahankan kualitas anotasi sehingga layak digunakan sebagai sumber daya bahasa untuk penelitian NER pada domain Al-Qur'an (Mayhew et al., 2024).

J. Kerangka Berpikir Penelitian

Kerangka berpikir merupakan representasi konseptual yang menggambarkan hubungan antara permasalahan penelitian, landasan teori, pendekatan yang digunakan, hingga luaran yang diharapkan. Dalam penelitian ini, kerangka berpikir disusun untuk menjelaskan bagaimana pemanfaatan **Quranic Arabic Corpus (QAC)** sebagai *Knowledge Source*, dikombinasikan dengan ***Cross-Lingual Annotation Projection***, ***Rule-Based Annotation Refinement***, dan ***Large Language Model-based Semantic Verification***, dapat digunakan untuk mendukung proses perluasan dataset NER pada teks terjemahan.

Kerangka berpikir ini dibangun berdasarkan hasil sintesis penelitian terdahulu yang menunjukkan bahwa konstruksi dataset NER masih menghadapi tantangan berupa keterbatasan data beranotasi, tingginya biaya anotasi manual, serta perlunya mekanisme validasi untuk menjaga kualitas anotasi. Oleh karena itu, penelitian ini mengusulkan sebuah *Pipeline* konstruksi dataset yang mengintegrasikan beberapa pendekatan sehingga proses perluasan dataset dapat dilakukan secara lebih sistematis tanpa mengabaikan kualitas hasil anotasi.

Berdasarkan identifikasi permasalahan yang telah diuraikan pada Bab I dan landasan teori pada Bab II, penelitian ini berangkat dari keterbatasan ketersediaan dataset NER pada domain Al-Qur'an berbahasa Indonesia. Meskipun telah tersedia **IndQNER** sebagai salah satu *benchmark*, jumlah data dan cakupan entitas yang dimiliki masih terbatas sehingga belum sepenuhnya mendukung pengembangan model NER yang lebih robust pada domain tersebut.

Untuk mengatasi permasalahan tersebut, penelitian ini memanfaatkan **Quranic Arabic Corpus (QAC)** sebagai sumber pengetahuan (*Knowledge Source*) yang menyediakan informasi linguistik dan anotasi entitas pada teks Arab Al-Qur'an. Informasi tersebut kemudian diproyeksikan ke dalam teks terjemahan melalui pendekatan ***Cross-Lingual Annotation Projection***, sehingga dihasilkan kandidat anotasi pada korpus sasaran.

Selanjutnya, kandidat anotasi yang diperoleh tidak langsung dijadikan anotasi akhir. Penelitian ini menerapkan ***Rule-Based Annotation Refinement*** untuk memperbaiki ketidaksesuaian kategori maupun batas entitas berdasarkan aturan yang disusun mengacu pada pedoman anotasi dan karakteristik linguistik teks terjemahan. Tahap ini bertujuan meningkatkan konsistensi anotasi sekaligus mengurangi kesalahan yang mungkin muncul akibat proses proyeksi lintas bahasa.

Sebagai lapisan validasi tambahan, penelitian ini memanfaatkan ***Large Language Model*** **(LLM)** untuk melakukan ***semantic verification*** terhadap hasil anotasi. LLM digunakan untuk mengevaluasi apakah kandidat entitas yang dihasilkan telah sesuai dengan konteks semantik ayat dan kategori entitas yang diharapkan. Namun demikian, hasil verifikasi LLM tidak diperlakukan sebagai *Ground Truth*, melainkan sebagai mekanisme pendukung dalam proses validasi anotasi.

Melalui integrasi keempat komponen tersebut, penelitian ini diharapkan menghasilkan dataset NER hasil perluasan yang memiliki kualitas anotasi lebih baik, tetap kompatibel dengan benchmark IndQNER, serta dapat dimanfaatkan

sebagai sumber daya bahasa (*language resource*) bagi penelitian NER pada domain Al-Qur'an di masa mendatang.

BAB III
METODOLOGI PENELITIAN

Metodologi penelitian ini dirancang untuk menghasilkan perluasan dataset *Extended IndQNER* dari skala terbatas (8 surah) menjadi skala penuh (114 surah) melalui pendekatan hibrida sekuensial. Pipeline otomatisasi ini mengintegrasikan ekstraksi berbasis data sintaksis, penyelarasan lintas bahasa, pelabelan berbasis kamus dan *Large Language Models* (LLM), serta diakhiri dengan evaluasi kualitas dataset secara empiris.

A. Tahapan Penelitian *(Pipeline)*

Tahapan pembangunan dan perluasan dataset *Extended IndQNER* dilakukan secara sekuensial melalui lima tahapan utama yang membentuk satu kesatuan *pipeline* sistematis:

1. **Persiapan Dataset**

   Menyiapkan teks *Quranic Arabic Corpus* (QAC) sebagai sumber pengetahuan terstruktur, teks terjemahan sebagai korpus target (114 surah), serta pedoman anotasi dari *benchmark* IndQNER.

   Melakukan ekstraksi data sintaksis dari *Quranic Arabic Corpus* (QAC) sebagai korpus sumber, mengintegrasikan teks Al-Qur'an bahasa Indonesia (selanjutnya disebut **"teks"**), serta memosisikan *Annotation Guideline* IndQNER sebagai standar acuan utama (*gold standard*).

2. ***Cross-Lingual Alignment***

   Melakukan penyelarasan lintas bahasa dengan mengekstraksi kandidat entitas (berdasarkan label *Proper Noun*) dari teks Arab QAC dan memproyeksikannya ke dalam korpus teks terjemahan untuk menghasilkan daftar entitas di teks.

3. Pelabelan entitas

Melabeli setiap entitas dengan label relevan. Caranya, menggunakan kamus entitas dan label IndQNER. Jika sebuah nama tidak muncul di kamus IndQNER, maka pipeline akan memanfaatkan LLM (LLM-as-labeler). Hal ini dilakukan dengan dua skenario, yakni zero-shot dan few-shot prompt ke LLM. LLM yang akan digunakan adalah open-source dan small LLMs, seperti Llama-3-8B. Big LLMs: QWEN 2.5, Llama-3-70B.

4. **Evaluasi Kualitas Dataset**

Mengukur validitas hasil perluasan secara empiris pada tingkat entitas (*entity-level*) terhadap *Gold Reference* independen yang dianotasi manual dan divalidasi pakar, serta melakukan pengujian performa model NER secara terbatas pada 8 surah awal untuk menghasilkan dataset final **Extended IndQNER**.

B. Sumber Data Penelitian

Penelitian ini memanfaatkan tiga sumber data utama yang memiliki fungsi berbeda dalam proses konstruksi dataset *Named Entity Recognition* (NER) pada domain Al-Qur'an berbahasa Indonesia. Setiap sumber data dipilih berdasarkan kesesuaiannya dengan tujuan penelitian, yaitu menghasilkan perluasan dataset yang tetap mempertahankan kompatibilitas terhadap benchmark IndQNER. Secara umum, sumber data terdiri atas **IndQNER** sebagai benchmark anotasi, **Quranic Arabic Corpus (QAC)** sebagai *Knowledge Source*, dan teks terjemahan sebagai korpus target untuk proses anotasi. Hubungan dan peran antar sumber data dalam penelitian ini ditunjukkan pada gambar berikut.

1. IndQNER sebagai Benchmark

IndQNER digunakan sebagai ***benchmark*** dalam penelitian ini. Dataset ini menyediakan pedoman anotasi, BIO *tagging scheme* (*Begin–Inside–Outside*), serta kategori entitas yang menjadi acuan selama proses konstruksi dataset. Seluruh hasil anotasi yang dihasilkan dalam penelitian ini disusun agar tetap kompatibel dengan struktur dan format IndQNER

sehingga dapat digunakan secara langsung pada penelitian lanjutan tanpa memerlukan proses konversi tambahan.

Selain berfungsi sebagai acuan anotasi, IndQNER juga digunakan sebagai dasar evaluasi kompatibilitas dataset hasil penelitian. Dengan demikian, perluasan dataset yang dihasilkan tidak mengubah struktur dasar benchmark, melainkan memperluas cakupan data yang tersedia.

2. Quranic Arabic Corpus sebagai *Knowledge Source*

Quranic Arabic Corpus (QAC) digunakan sebagai sumber pengetahuan *(Knowledge Source)* dalam penelitian ini. QAC menyediakan informasi linguistik yang terstruktur mengenai teks Al-Qur'an, termasuk informasi morfologi, lema, struktur sintaksis, serta anotasi entitas yang menjadi referensi dalam proses penyelarasan lintas bahasa.

Berbeda dengan IndQNER, QAC **tidak digunakan sebagai dataset target**, melainkan sebagai sumber informasi untuk membantu proses identifikasi kandidat entitas selama tahap *Cross-Lingual Annotation Projection*. Dengan memanfaatkan informasi linguistik dari QAC, penelitian ini diharapkan mampu meningkatkan akurasi anotasi awal sebelum dilakukan penyempurnaan melalui *Rule-Based Annotation Refinement* dan LLM *Semantic Verification*.

Dalam penelitian ini, informasi yang dimanfaatkan dari QAC terutama berupa anotasi morfologi dalam format XML, meliputi lokasi token (surah, ayat, kata, subkata), lema, akar kata, kategori morfologi, serta token dengan label *Proper Noun* (PN). Informasi tersebut menjadi dasar pembentukan Location Index yang digunakan pada proses *Cross-Lingual Annotation Projection.*

3. Teks Terjemahan

Teks terjemahan digunakan sebagai **korpus target** dalam penelitian ini. Seluruh proses anotasi dilakukan terhadap teks terjemahan karena tujuan

utama penelitian adalah memperluas dataset NER pada domain Al-Qur'an berbahasa Indonesia.

Pemilihan terjemahan resmi Kementerian Agama didasarkan pada penggunaannya yang luas dalam lingkungan akademik dan konsistensi terjemahan yang dipertahankan melalui proses penyuntingan resmi. Korpus ini menjadi media utama tempat informasi entitas yang diperoleh dari Quranic Arabic Corpus diproyeksikan dan disempurnakan melalui tahapan metodologi yang diusulkan.

4. Peran Sumber Data dalam Penelitian

Setiap sumber data yang digunakan dalam penelitian ini memiliki peranan spesifik dalam mendukung keberhasilan *pipeline* hibrida. Peran masing-masing sumber data dirangkum pada tabel dibawah ini.

Tabel 4 Peran Sumber Data Penelitian

No	Sumber Data	Format / Wujud	Peran dalam Penelitian
1	*Quranic Arabic Corpus* (QAC)	TSV / Raw Text Treebank	*Structured Knowledge Source* untuk ekstraksi kandidat *Proper Noun* (PN) beserta metadata morfologi dan terjemahan harfiahnya.
2	Terjemahan Al-Qur'an Kemenag RI	Teks Terstruktur (Surah & Ayat)	Teks Target yang akan diproyeksikan dan dianotasi menjadi *Extended IndQNER Dataset* (114 Surah).
3	*Benchmark Dataset* IndQNER	Text (BIO Tagging) / HuggingFace	Acuan skema pelabelan, penyedia kamus entitas referensi, dan *gold standard* awal (8 surah).

4	Pedoman Pelabelan IndQNER	Dokumen PDF (*Annotation Guideline*)	Acuan aturan pelabelan entitas dan pemetaan 18 kategori kelas entitas.

C. Perangkat Penelitian

Penelitian ini menggunakan dukungan perangkat keras dan perangkat lunak untuk menjalankan keseluruhan tahapan *pipeline* konstruksi dataset. Pemilihan spesifikasi perangkat disesuaikan dengan kebutuhan beban komputasi (*computational workload*), khususnya untuk tahap penyelarasan berbasis *Token Similarity Matching*, inferensi modul *LLM-as-labeler* (Llama-3-8B), serta proses pelatihan (*fine-tuning*) pada evaluasi ekstrinsik model NER.

1. Perangkat Keras

Perangkat keras yang digunakan dipastikan mampu menangani proses komputasi paralel untuk *deep learning* dan *Large Language Model*. Rincian perangkat keras ditunjukkan pada tabel dibawah ini.

Tabel 5 Perangkat Keras Penelitian

Komponen	**Spesifikasi Minimum**
Processor	Intel Core i5 / AMD Ryzen 5
RAM	Minimal 16 GB
Storage	SSD minimal 512 GB
GPU	layanan *Cloud GPU* (Google Colab Pro / Kaggle)
Internet	Koneksi internet stabil untuk pengunduhan *pre-trained model*, akses repositori Hugging Face, dan eksekusi *cloud*.

2. Perangkat Lunak

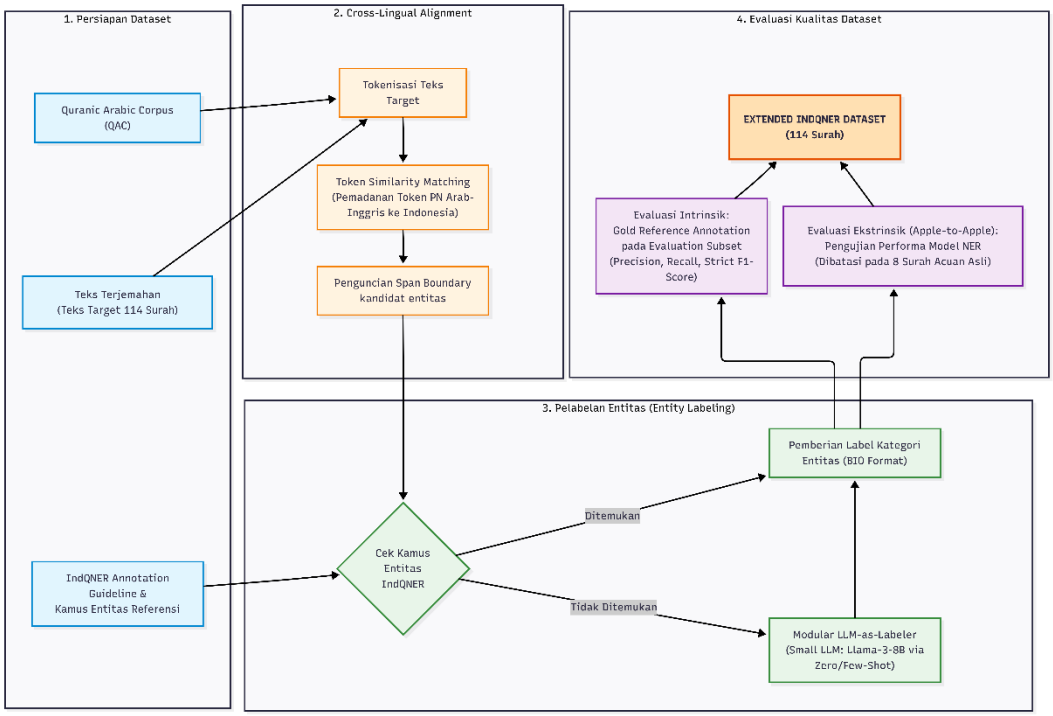
Perangkat lunak yang digunakan terdiri atas lingkungan pengembangan (*development environment*) dan pustaka (*library*) khusus NLP berbasis Python. Rincian perangkat lunak ditunjukkan pada tabel dibawah ini.

Tabel 6 Perangkat Lunak Penelitian

Perangkat Lunak / *Library*	**Fungsi dalam Penelitian**
Python 3.10+	Bahasa pemrograman utama untuk seluruh eksekusi *pipeline*.
Visual Studio Code & Jupyter Notebook	Lingkungan penulisan kode (IDE) dan pencatatan eksperimen (*notebook*).
pandas & NumPy	Pemrosesan, manipulasi, dan komputasi numerik struktur data tabular (dataset).
Levenshtein / Sentence-Transformers	Modul komputasi jarak leksikal dan *embedding* untuk tahap *Token Similarity Matching*.
Hugging Face Transformers & Accelerate	Modul utama untuk memuat, menjalankan inferensi *small LLM* (Llama-3-8B), serta model bahasa evaluasi.
PyTorch	*Framework Deep Learning yang mendasari proses inferensi LLM dan pelatihan model NER (IndoBERT/BiLSTM-CRF).*
seqeval	Pustaka komputasi metrik evaluasi tingkat entitas (*Precision, Recall, Strict F1-Score*) untuk skema BIO.
Git & GitHub	Sistem kontrol versi (*version control*) untuk dokumentasi dan pencadangan kode sumber.

D. Arsitektur Metodologi Penelitian

Arsitektur metodologi penelitian ini menggambarkan alur kerja sistematis dalam mengolah *raw data* menjadi *Extended IndQNER Dataset*. Diagram arsitektur metodologi ditunjukkan pada gambar dibawah ini.



Gambar 1 Arsitektur Metodologi Penelitian

Penjelasan rinci mengenai diagram arsitektur metodologi di atas adalah sebagai berikut:

1. **Persiapan Dataset**

   Memproses file *treebank* QAC untuk mengisolasi token ber-tag morfologi *Proper Noun* (PN) beserta makna terjemahan harfiahnya. Pada saat bersamaan, teks terjemahan Kemenag RI disiapkan sebagai teks target dan *Annotation Guideline* IndQNER diimpor sebagai landasan aturan.

2. **Penyelarasan Lintas Bahasa (*Cross-Lingual Alignment*)**

   Teks target bahasa Indonesia ditokenisasi. Selanjutnya, kandidat entitas PN dipadankan batas rentang teksnya (*span boundary*) ke dalam teks terjemahan Indonesia menggunakan metode *Token Similarity Matching* berbasis kemiripan leksikal dan vektor kata.

3. **Pelabelan Entitas (*Entity Labeling*)**

Kandidat entitas yang telah terkunci batasannya diperiksa terlebih dahulu ke dalam Kamus Entitas IndQNER. Jika kata tersebut terdaftar dalam kamus, label kategori langsung diberikan secara deterministik. Apabila tidak ditemukan dalam kamus, entitas diteruskan ke modul *LLM-as-labeler* menggunakan model bahasa kecil (*small LLM*, Llama-3-8B) melalui skenario *Zero-Shot* dan *Few-Shot prompting* yang dipandu oleh definisi kategori IndQNER.

4. **Evaluasi Kualitas Dataset**

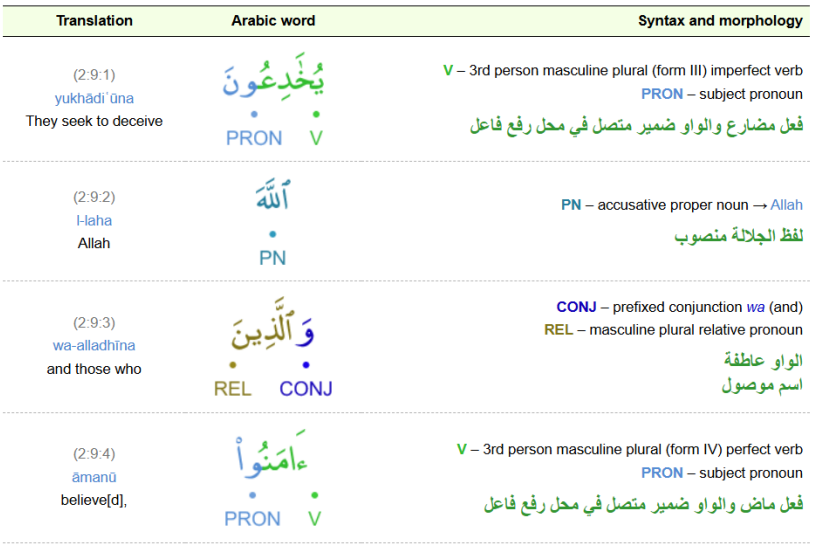
   Kualitas anotasi hasil *pipeline* diuji secara intrinsik (*entity-level matching* terhadap *Gold Reference*) dan ekstrinsik (pengujian performa model NER pada 8 surah *gold standard* IndQNER asli) sebelum diterbitkan sebagai *Extended IndQNER Dataset*.

E. Persiapan Dataset

Tahap pertama berfokus pada ekstraksi dan penyelarasan struktur data mentah dari dua sumber data utama, yaitu *Quranic Arabic Corpus* (QAC) dan Teks Terjemahan Al-Qur'an Kemenag RI, serta adopsi pedoman anotasi resmi.

1. Ekstraksi Data Syntax dan Morphology QAC

File mentah QAC berformat TSV (*Tab-Separated Values*) diparsing untuk membaca kolom lokasi (Surah, Ayat, Word, Segment), kata Arab, fitur morfologi, serta kelas *Part-of-Speech* (POS). Sistem melakukan pemfilteran kaku untuk hanya mengambil token yang memiliki label gramatikal POS=PN (*Proper Noun*).



Translation	Arabic word	Syntax and morphology
(2:9:1) yukhādiʿūna They seek to deceive	يُخَٰدِعُونَ PRON V	V – 3rd person masculine plural (form III) imperfect verb PRON – subject pronoun فعل مضارع والواو ضمير متصل في محل رفع فاعل
(2:9:2) l-laha Allah	ٱللَّهَ PN	PN – accusative proper noun → Allah لفظ الجلالة منصوب
(2:9:3) wa-alladhīna and those who	وَٱلَّذِينَ REL CONJ	CONJ – prefixed conjunction *wa* (and) REL – masculine plural relative pronoun الواو عاطفة اسم موصول
(2:9:4) āmanū believe[d],	ءَامَنُوا۟ PRON V	V – 3rd person masculine plural (form IV) perfect verb PRON – subject pronoun فعل ماض والواو ضمير متصل في محل رفع فاعل

Gambar 2 *Tab-Separated Value*s pada QAC

Sebagai contoh konkret, pada **Surah Al-Baqarah ayat 9 (2:9)**, segmen kata kedua memiliki entri morfologi sebagai berikut:

a. *Location Index*: (2:9:2:1)

b. *Arabic Segment:* ٱللَّهَ (*Allāha*)

c. *Syntax and Morphology:* POS=PN, PRON=*masculine singular*, *Case=accusative*

d. *English Translation*: *"Allah"*

Sistem menyimpan token ٱللَّهَ beserta lokasi (2:9:2) dan terjemahan harfiah bahasa Inggrisnya (*"Allah"*) sebagai kandidat entitas bernama tingkat akar (*gold candidate*).

2. Pemrosesan Teks Terjemahan

Teks terjemahan untuk 114 surah dibersihkan dari karakter kontrol non-teks dan dipetakan indeks lokasinya berdasarkan [Surah:Ayat]. Teks ini diposisikan sebagai **Teks Target** tempat proyeksi entitas akan diterapkan.



Gambar 3 Laman quran.kemenag.go.id

3. *Adopsi Pedoman Anotasi* (Annotation Guideline)

Penelitian ini secara penuh mengadopsi dokumen Annotation guideline in Indonesian.pdf yang dikembangkan oleh (Gusmita et al., 2023) sebagai *gold standard guideline*. Dokumen ini memuat definisi operasional, batasan, dan contoh konkret dari **18 kategori kelas entitas** IndQNER (seperti *Person*, *Location*, *Group*, *Religion*, *Event*, dll.) serta aturan penerapannya pada skema penandaan BIO (*Beginning-Inside-Outside*).

F. Penyelarasan Lintas Bahasa (*Cross-Lingual Alignment*)

Tahap kedua bertujuan untuk memindahkan penanda entitas PN dari bahasa Arab ke dalam Teks Target bahasa Indonesia tanpa kehilangan batasan teks yang presisi.

1. Tokenisasi Teks Target

Teks terjemahan bahasa Indonesia pada ayat target dipotong menjadi urutan token (*tokenization*) menggunakan teknik tokenisasi leksikal berbasis *word-level*. Setiap token menyimpan informasi indeks posisi karakter awal dan akhir (*character offsets*) di dalam kalimat.

2. Pengukuran Kemiripan Token (*Token Similarity Matching*)

Untuk menentukan token mana pada teks terjemahan bahasa Indonesia yang merujuk pada kandidat entitas PN Arab, sistem memanfaatkan terjemahan harfiah bahasa Inggris dari QAC sebagai jembatan *similarity*.

Proses pemadanan dilakukan melalui metode *Token Similarity Matching*, yang mengombinasikan dua pendekatan:

a. **Leksikal & Transliterasi Matching:** Menghitung kemiripan jarak penyuntingan (*Levenshtein distance* / *Jaro-Winkler*) antara bentuk transliterasi nama Arab/Inggris (misalnya *"Allah"*, *"Moses"*, *"Pharaoh"*) dengan token-token pada teks terjemahan Indonesia (*"Allah"*, *"Musa"*, *"Firaun"*).

b. **Semantic Embedding Matching:** Menghitung *cosine similarity* antar-vektor token menggunakan *multilingual embedding model* untuk menangani entitas yang diterjemahkan secara deskriptif.

Token bahasa Indonesia yang memiliki nilai kemiripan tertinggi terhadap kandidat PN akan dikunci batas rentang teksnya (*span boundary*).

G. Pelabelan Entitas (*Entity Labeling*)

Setelah batasan rentang teks entitas (*span boundary*) pada kalimat terjemahan Indonesia berhasil dikunci, tahap ketiga bertugas menentukan kelas kategori entitas (misalnya: PERSON, LOCATION, GOD, dll.) dan mengonversinya ke format penandaan BIO.

1. Pencocokan Kamus Entitas IndQNER *(Dictionary Lookup)*

Sistem terlebih dahulu mengecek kata/frasa entitas terdeteksi ke dalam **Kamus Entitas IndQNER** (direkonstruksi dari 2.475 entitas pada 8 surah IndQNER asli).

a. **Jika Ditemukan:** Kategori kelas entitas langsung ditetapkan sesuai label pada kamus secara deterministik (misalnya, kata *"Allah"* otomatis diberi label GOD).

b. **Jika Tidak Ditemukan:** Entitas dikategorikan sebagai kandidat entitas baru (*unmapped entity*) dan diproses ke sub-sistem berikutnya.

2. Pendekatan Modular *LLM-as-Labeler*

Untuk kandidat entitas baru yang tidak terdaftar dalam kamus, sistem menggunakan modul *LLM-as-labeler*. Penelitian ini memanfaatkan model

bahasa kecil (*small LLM*) **Llama-3-8B** yang dijalankan secara lokal/terkendali.

LLM tidak diberi kebebasan menghasilkan teks (*generative pure*), melainkan ditugaskan secara eksklusif sebagai pemeta kelas (*classifier*) melalui teknik *Prompt Engineering*:

a. ***Zero-Shot Prompting*:** Diberikan kalimat terjemahan, frasa entitas terisolasi, dan daftar 18 definisi kategori IndQNER, lalu LLM diminta memilih satu kode kelas yang paling tepat.

b. ***Few-Shot Prompting*:** Jika klausa kalimat memiliki ambiguitas tinggi, *prompt* dilengkapi dengan 3–5 contoh pasangan kalimat dan label acuan dari pedoman anotasi.

Hasil prediksi kategori dari LLM kemudian diformat secara otomatis menjadi tag BIO (misalnya B-PERSON, I-PERSON, O).

H. Evaluasi Kualitas Dataset

Evaluasi dilakukan untuk menguji keandalan dan validitas dataset *Extended IndQNER* secara empiris, baik dari sisi presisi anotasi internal maupun dampaknya terhadap model pembelajaran mesin.

1. Evaluasi Intrinsik (Entity-Level Annotation Matching)

Pengujian kualitas anotasi langsung dilakukan menggunakan *Evaluation Subset* (300–500 ayat) yang dibangun secara independen melalui *Human Annotation* (2 anotator) dan *Expert Validation* guna menghasilkan *Gold Reference Annotation*.

Anotasi hasil *pipeline* dibandingkan terhadap *Gold Reference* menggunakan metrik pencocokan ketat (*strict matching*):

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{Strict F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

2. Evaluasi Ekstrinsik / *Downstream Task Evaluation* (Pengujian Performa Model NER)

Untuk membuktikan bahwa *Extended IndQNER Dataset* secara nyata meningkatkan kemampuan generalisasi model AI, dilakukan pengujian performa fine-tuning model NER (misalnya IndoBERT / BiLSTM-CRF).

Ketentuan Evaluasi *Apple-to-Apple*:

Guna menjamin validitas ilmiah dan pembandingan kinerja model yang adil (*apple-to-apple*), evaluasi ekstrinsik model NER yang dilatih dengan dataset *Extended IndQNER* **secara kaku dibatasi dan diuji pada data uji (*test set*) dari 8 surah yang ada pada IndQNER asli**.

Dengan membatasi *test set* hanya pada 8 surah *gold standard* acuan awal, hasil pengujian model baru dapat dibandingkan secara langsung dengan skor *baseline* penelitian Gusmita et al. (2023) tanpa menimbulkan bias perbedaan distribusi data uji.

DAFTAR PUSTAKA

Abdelmageed, N., Löffler, F., Feddoul, L., Algergawy, A., Samuel, S., Gaikwad, J., Kazem, A., & König-Ries, B. (2022). BiodivNERE: Gold standard corpora for named entity recognition and relation extraction in the biodiversity domain. *Biodiversity Data Journal*, *10*. https://doi.org/10.3897/BDJ.10.e89481

Agić, Ž., Johannsen, A., Plank, B., Alonso, H. M., Schluter, N., & Søgaard, A. (2016). Multilingual Projection for Parsing Truly Low-Resource Languages. *Transactions of the Association for Computational Linguistics*, *4*, 301–312. https://doi.org/10.1162/tacl_a_00100

Armaijn, L., Darmayanti, D., Sonia, B., & Rochmat, H. (2024). PENINGKATAN KINERJA NAMED ENTITY RECOGNITION BAHASA INDONESIAMELALUI AUGMENTASI DATA BERBASIS LARGE LANGUAGE MODELS. *Jurnal Informatika Teknologi Dan Sains (JINTEKS)*, *2*(2005), 306–312.

Basir, N., Qabulio, M., Memon, M. S., Arain, D. N., Nizamani, S. B., & Nizamani, S. (2026). Expanded Entity Coverage and Machine-Annotated Pre-Training for Urdu Named Entity Recognition. *The Asian Bulletin of Big Data Management*, *6*(1), 77–93. https://doi.org/10.62019/gypnn177

Basir, N., Vighio, R. A., Ansari, B., Patoli, N., Arain, D. N., & Ali, A. (2026). Low-Resource Balochi Named Entity Recognition: Corpus Construction and Multilingual Transformer Evaluation. *The Asian Bulletin of Big Data Management*, *6*(1), 153–167. https://abbdm.com/index.php/Journal/article/view/462

Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., Bernstein, M. S., Bohg, J., Bosselut, A., Brunskill, E., Brynjolfsson, E., Buch, S., Card, D., Castellon, R., Chatterji, N., Chen, A., Creel, K., Davis, J. Q., Demszky, D., … Liang, P. (2022). *On the Opportunities and Risks of Foundation Models*. 1–211. http://arxiv.org/abs/2108.07258

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., … Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, *2020-Decem*. https://doi.org/10.65525/svup.9788199778009.2026.224-230

Cahyawijaya, S., Winata, G. I., Wilie, B., Vincentio, K., Li, X., Kuncoro, A., Ruder, S., Lim, Z. Y., Bahar, S., Khodra, M. L., Purwarianti, A., & Fung, P. (2021). IndoNLG: Benchmark and Resources for Evaluating Indonesian Natural Language Generation. *EMNLP 2021 - 2021 Conference on Empirical Methods in Natural Language Processing, Proceedings*, 8875–8898. https://doi.org/10.18653/v1/2021.emnlp-main.699

Cambria, E., & White, B. (2014). Jumping NLP curves: A review of natural language processing research. In *IEEE Computational Intelligence Magazine* (Vol. 9, Number 2, pp. 48–57). Institute of Electrical and Electronics Engineers Inc. https://doi.org/10.1109/MCI.2014.2307227

Chen, W., Zhao, L., Zheng, Z., Xu, T., Wang, Y., & Chen, E. (2024). Double-Checker: Large Language Model as a Checker for Few-shot Named Entity Recognition. *EMNLP 2024 - 2024 Conference on Empirical Methods in Natural Language Processing, Findings of EMNLP 2024*, 3172–3181. https://doi.org/10.18653/v1/2024.findings-emnlp.180

Christopher D. Manning and Hinrich Schütze. (1999). *Foundations of Statistical Natural Language Processing*. The MIT Press Cambride, Massachusetts London, England.

Ding, B., Qin, C., Zhao, R., Luo, T., Li, X., Chen, G., Xia, W., Hu, J., Luu, A. T., & Joty, S. (2024). *Data Augmentation using Large Language Models: Data Perspectives, Learning Paradigms and Challenges*. http://arxiv.org/abs/2403.02990

Drozdov, I., & Pavlyshenko, B. (2025). NAMED ENTITY RECOGNITION USING GENERATIVE TRANSFORMER MODELS WITH SENTENCE-LEVEL DATA AUGMENTATION APPROACHES. *Electronics and Information Technologies*, *31*. https://doi.org/10.30970/eli.31.1

Dukes, K., Atwell, E., & Habash, N. (2013). Supervised collaboration for syntactic annotation of Quranic Arabic. *Language Resources and Evaluation*, *47*(1), 33–62. https://doi.org/10.1007/s10579-011-9167-7

Dukes, K., & Habash, N. (2010). Morphological annotation of quranic Arabic. *Proceedings of the 7th International Conference on Language Resources and Evaluation, LREC 2010*, 2530–2536. https://doi.org/10.63317/4b87kwj4mt83

Gusmita, R. H., Abshar, M. F. A., Moussallem, D., & Ngomo, A. C. N. (2024). IndEL: Indonesian Entity Linking Benchmark Dataset for General and Specific Domains. *Lecture Notes in Computer Science*, *14762 LNCS*, 500–513. https://doi.org/10.1007/978-3-031-70239-6_34

Gusmita, R. H., Firmansyah, A. F., Moussallem, D., & Ngonga Ngomo, A. C. (2023). IndQNER: Named Entity Recognition Benchmark Dataset from the Indonesian Translation of the Quran. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, *13913 LNCS*, 170–185. https://doi.org/10.1007/978-3-031-35320-8_12

Gusmita, R. H., Firmansyah, A. F., Zahera, H. M., & Ngonga Ngomo, A. C. (2026). ELEVATE-ID: Extending Large Language Models for End-to-End Entity Linking Evaluation in Indonesian. *Data and Knowledge Engineering*, *161*, 102504. https://doi.org/10.1016/j.datak.2025.102504

Holderness, E., Atwood, B., Verhagen, M., Shinn, A. K., Cawkwell, P., Cerruti, H., Pustejovsky, J., & Hall, M. H. (2025). Machine learning in psychiatric health records: A gold standard approach to trauma annotation. *Translational Psychiatry*, *15*(1). https://doi.org/10.1038/s41398-025-03487-0

Hwa, R., Resnik, P., Weinberg, A., Cabezas, C., & Kolak, O. (2005). Bootstrapping parsers via syntactic projection across parallel texts. *Natural Language Engineering*, *11*(3), 311–325. https://doi.org/10.1017/S1351324905003840

Idi Mohammed, & Habiba Idi Idriss. (2026). Transformer-Based Model for Named Entity Recognition in Hausa Language Texts. *International Journal of Latest Technology in Engineering Management & Applied Science*, *15*(5), 2840–2856. https://doi.org/10.51583/ijltemas.2026.150500232

Ivanova, R. V., Kirrane, S., & van Erp, M. (2022). Comparing Annotated Datasets for Named Entity Recognition in English Literature. *2022 Language Resources and Evaluation Conference, LREC 2022*, (June), 3788–3797. https://doi.org/10.63317/2moyzgso4j5s

Jurafsky, D., & Martin, J. H. (n.d.). *Speech and Language Processing An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models Third Edition draft*.

Jurafsky, D., & Martin, J. H. (2024). *Speech and Language Processing An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models Third Edition draft*.

Khairunnisa, S. O., Chen, Z., & Komachi, M. (2024). Improving Domain-Specific NER in the Indonesian Language Through Domain Transfer and Data Augmentation. *Journal of Advanced Computational Intelligence and*

Intelligent Informatics, *28*(6), 1299–1312. https://doi.org/10.20965/jaciii.2024.p1299

Khurana, D., Koli, A., Khatter, K., & Singh, S. (2022a). *Natural Language Processing: State of The Art, Current Trends and Challenges*.

Khurana, D., Koli, A., Khatter, K., & Singh, S. (2022b). *Natural Language Processing: State of The Art, Current Trends and Challenges*.

Li, J., Chen, J., Ren, R., Cheng, X., Zhao, W. X., Nie, J. Y., & Wen, J. R. (2024). The Dawn After the Dark: An Empirical Study on Factuality Hallucination in Large Language Models. *Proceedings of the Annual Meeting of the Association for Computational Linguistics*, *1*, 10879–10899. https://doi.org/10.18653/v1/2024.acl-long.586

Liu, P., Yuan, W., Fu, J., Jiang, Z., Hayashi, H., & Neubig, G. (2023). Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing. *ACM Computing Surveys*, *55*(9), 1–46. https://doi.org/10.1145/3560815

Mayhew, S., Blevins, T., Liu, S., Šuppa, M., Gonen, H., Imperial, J. M., Karlsson, B. F., Lin, P., Ljubešić, N., Miranda, L. J., Plank, B., Riabi, A., & Pinter, Y. (2024). Universal NER: A Gold-Standard Multilingual Named Entity Recognition Benchmark. *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL 2024*, *1*, 4322–4337. https://doi.org/10.18653/v1/2024.naacl-long.243

Mo, Y., Yang, J., Liu, J., Wang, Q., Chen, R., Wang, J., & Li, Z. (2024). MCL-NER: Cross-Lingual Named Entity Recognition via Multi-View Contrastive Learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, *38*(17), 18789–18797. https://doi.org/10.1609/aaai.v38i17.29843

Olewniczak, S., & Szymański, J. (2025). Gold standard, multi-genre dataset for named entity recognition and linking. *Scientific Data* , *12*(1), 1–22. https://doi.org/10.1038/s41597-025-05274-4

Politov, A., Shkalikov, O., Jäkel, R., & Färber, M. (2025). Revisiting Projection-based Data Transfer for Cross-Lingual Named Entity Recognition in Low-Resource Languages. *Center for Scalable Data Analytics and Artificial Intelligence (ScaDS.AI)*. http://arxiv.org/abs/2501.18750

Rahimi, A., Li, Y., & Cohn, T. (2020). Massively multilingual transfer for NER. *ACL 2019 - 57th Annual Meeting of the Association for Computational*

Linguistics, Proceedings of the Conference, 151–164. https://doi.org/10.18653/v1/p19-1015

Tan, Z., Li, D., Wang, S., Beigi, A., Jiang, B., Bhattacharjee, A., Karami, M., Li, J., Cheng, L., & Liu, H. (2024). Large Language Models for Data Annotation and Synthesis: A Survey. *EMNLP 2024 - 2024 Conference on Empirical Methods in Natural Language Processing, Proceedings of the Conference*, 930–957. https://doi.org/10.18653/v1/2024.emnlp-main.54

Tarmizi, S. A., & Saad, S. (2025). Named Entity Recognition on Islamic Texts: A Systematic Review. *International Journal of Advanced Science Computing and Engineering*, *7*(3), 98–111. https://doi.org/10.62527/ijasce.7.3.265

Tjong, E. F., Sang, K., & De Meulder, F. (2003). *Introduction to the CoNLL-2003 Shared Task: Language-Independent Named Entity Recognition*. http://lcg-www.uia.ac.be/conll2003/ner/

Wang, S., Wang, X., Mei, J., Xie, Y., Muarray, S., Li, Z., Wu, L., Chen, S. Q., & Xiong, W. (2025). Developing a Reliable, Fast, General-Purpose Hallucination Detection and Mitigation Service. *Proceedings of the 2025 Annual Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies: Long Papers, NAACL-HLT 2025*, *3*, 971–978. https://doi.org/10.18653/v1/2025.naacl-industry.72

Wen, Y., Fan, C., Chen, G., Chen, X., & Chen, M. (2020). A Survey on Named Entity Recognition. *Lecture Notes in Electrical Engineering*, *571 LNEE*(1991), 1803–1810. https://doi.org/10.1007/978-981-13-9409-6_218

White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., Elnashar, A., Spencer-Smith, J., & Schmidt, D. C. (2023). *A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT*. http://arxiv.org/abs/2302.11382

Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., & Purwarianti, A. (2020). IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding. *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing, AACL-IJCNLP 2020*, 843–857. https://doi.org/10.18653/v1/2020.aacl-main.85

Yarowsky, D., Ngai, G., & Wicentowski, R. (2001). *Inducing multilingual text analysis tools via robust projection across aligned corpora*. 1–8. https://doi.org/10.3115/1072133.1072187

Ye, J., Xu, N., Wang, Y., Zhou, J., Zhang, Q., Gui, T., & Huang, X. (2024). LLM-DA: Data Augmentation via Large Language Models for Few-Shot Named Entity Recognition. *ArXiv*. http://arxiv.org/abs/2402.14568

Zheng, Y., Gan, W., Chen, Z., Qi, Z., Liang, Q., & Yu, P. S. (2024). Large language models for generative information extraction: a survey. *Frontiers of Computer Science*, *18*(6).